

# PREVISÃO DA CARGA DE CASOS DO PROGRAMA BOLSA FAMÍLIA

*Redes neurais construídas do zero, covariáveis de  
demografia e emprego, um benchmark fora do tempo  
e uma projeção até 2028*

**Leonardo Chalhoub • Alexandre Maciel Rolim**  
**Luis Fernando Kranz • Jefferson Korte**

Todos os autores atuam como **pesquisadores independentes**, Brasil.

*Leonardo Chalhoub* — Expert Data Engineer; Mestre em Administração (Finanças), UFRGS;  
graduando em Engenharia de Software, Universidade Estácio de Sá. Rio de Janeiro, RJ. ORCID:  
0000-0003-0484-158X.

*Alexandre Maciel Rolim* — Tecnólogo em Radiologia; Mestre em Proteção Radiológica, IFSC.  
Florianópolis, SC. ORCID: 0009-0000-3983-4713.

*Luis Fernando Kranz* — Tecnólogo em Radiologia; Mestre em Administração, UFRGS. Porto Alegre,  
RS. ORCID: 0009-0009-6015-3141.

*Jefferson Korte* — Estudante de Ciência da Computação, UTFPR. Curitiba, PR. ORCID:  
0009-0006-9466-9830.

**Correspondência:** Leonardo Chalhoub • leochalhoub@hotmail.com

*Quantos núcleos familiares o maior programa de transferência condicionada de renda da América Latina atenderá nos próximos anos, e o que governa essa demanda? Tratamos a carga de casos (o número de famílias beneficiárias) como uma série temporal em painel e a prevemos com redes neurais implementadas inteiramente do zero em C++17. Sobre 5.542 municípios e 156 meses (2013–2025), comparamos modelos univariados (apenas o próprio histórico) a modelos multivariados alimentados por covariáveis anuais de população (IBGE) e de emprego formal (RAIS), sob avaliação rigorosa fora do tempo, e projetamos a trajetória nacional até dezembro de 2028. Dois achados organizam o artigo: a profundidade só compensa quando a estrutura do sinal a recompensa; e as covariáveis de demografia e mercado de trabalho carregam sinal real, cujo valor cresce com o horizonte de previsão.*

## RESUMO

Este artigo formula a previsão da carga de casos do Programa Bolsa Família — o número de famílias beneficiárias — como um problema de previsão de séries temporais em painel e o resolve com redes neurais construídas inteiramente do zero em C++17, sem bibliotecas de aprendizado profundo. A partir de uma camada bruta de 2.533.885.299 pagamentos do Portal da Transparência da Controladoria-Geral da União (CGU), mineramos um painel município  $\times$  mês com 5.542 municípios e 156 meses (2013–2025) e o enriquecemos com duas covariáveis anuais — população residente (IBGE) e emprego formal ativo (RAIS/PDET) —, reconciliadas ao código municipal do painel por um *crosswalk* com 99,5% de cobertura. Treinamos um único modelo global e o avaliamos sob protocolo honesto: padronização com meses de treino apenas (sem vazamento), covariáveis defasadas (sem peeking), partição *fora do tempo* (alvos anteriores a janeiro de 2025 treinam; janeiro a dezembro de 2025 testam,  $\approx 66.504$  previsões por horizonte) e linha de base ingênua forte (persistência). Comparamos cinco modelos — persistência, autorregressão linear, perceptron multicamadas profundo ( $14 \rightarrow 64 \rightarrow 32 \rightarrow 1$ ) e as versões *com covariáveis* de ambos ( $16 \rightarrow \dots$ ) — em quatro horizontes ( $H \in \{1, 3, 6, 12\}$  meses) com MAE, MAPE, RMSE e  $R^2$ , e inferimos significância por bootstrap pareado, teste de Wilcoxon e taxa de vitória. Achados: (i) a um mês a carga de casos é quase um passeio aleatório e nenhum modelo aprendido supera a persistência; (ii) em horizontes de planejamento (6 meses) a autorregressão reduz o MAE em 27% sobre a ingênua, com vantagem grande e robusta; (iii) a profundidade é *dominada* pela autorregressão em todo horizonte, mesmo com covariáveis; (iv) as covariáveis de demografia e emprego carregam sinal real cujo valor *cresce com o horizonte*: irrelevantes ou prejudiciais a curto prazo, elevam o modelo linear em 12 meses de +10% para +17% de redução de MAE, tornando o modelo linear com covariáveis o melhor preditor de longo prazo; (v) a projeção nacional indica que a carga de casos atingiu o pico em 2022–2023 e recua, com erro agregado de backtest inferior a 4,7% em 12 meses. Documentamos ainda uma forte relação estrutural entre cobertura do programa e emprego formal nos municípios (correlação log-log de  $-0,66$  em 2024) e, indo além da associação, *identificamos seu efeito causal* por um instrumento *shift-share* (Bartik): o emprego formal reduz a demanda por transferência, com efeito 2SLS de  $-0,63$  (IC 95%  $[-1,20; -0,06]$ , primeiro estágio  $F > 26$ ), maior em magnitude que o de MQO — sinal de atenuação. Em previsão, a autorregressão linear global supera não só a persistência como os benchmarks clássicos ETS e SARIMA em todos os horizontes (4,7% vs.  $\sim 10\%$  de MAPE nacional em 12 meses). Conclui-se que, sob ausência de novo choque institucional, a demanda estrutural é plana ou declinante e que o custo futuro — cuja parcela estrutural um erro de 4,7% projeta com desvio da ordem de R\$ 7 bilhões/ano — é governado pelo *valor* do benefício, uma escolha de política, não por uma carga de casos em expansão.

**Palavras-chave:** identificação causal; instrumento shift-share; variável instrumental; previsão de séries temporais; redes neurais artificiais; perceptron multicamadas; covariáveis exógenas; Programa Bolsa Família; emprego formal; RAIS; demografia; avaliação fora do tempo; C++.

## ABSTRACT

This paper frames forecasting the Bolsa Família caseload — the number of beneficiary families — as a panel time-series problem and solves it with neural networks built entirely from scratch in C++17. From a bronze layer of 2.533.885.299 payment records (CGU), we mine a municipality  $\times$  month panel of 5.542 municipalities and 156 months (2013–2025) and enrich it with two annual covariates — resident population (IBGE) and active formal employment (RAIS) — reconciled to the panel’s municipal code by a crosswalk covering 99.5% of municipalities. A single global model is trained and evaluated honestly: leakage-free standardisation, lagged covariates, an out-of-time split (targets before January 2025 train; January to December 2025 test,  $\approx 66,504$  forecasts per horizon), and a strong naive baseline. We compare five models — persistence, a linear autoregression, a deep MLP, and the covariate-augmented versions of both — across four horizons, with significance from paired bootstrap, Wilcoxon tests and win rates. We find that at one month no learned model beats persistence; at planning horizons the linear autoregression cuts MAE by 27% over naive; depth is dominated by the linear model everywhere, even with covariates; and the covariates carry real signal whose value grows with the horizon — negligible or harmful in the short run, they lift the 12-month linear model from +10% to +17% MAE reduction. The national projection shows the caseload peaked in 2022–2023 and is declining, with aggregate backtest error below 4.7% at twelve months. We also document a strong structural relationship between program coverage and formal-employment intensity across municipalities (log-log correlation  $-0.66$  in 2024). We conclude that structural demand is flat-to-falling, so future cost is governed by the benefit level — a policy choice.

**Keywords:** time-series forecasting; artificial neural networks; multilayer perceptron; exogenous covariates; Bolsa Família; formal employment; out-of-time evaluation; C++.

## Sumário

|          |                                                                                 |           |
|----------|---------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introdução</b>                                                               | <b>6</b>  |
| 1.1      | Contribuições . . . . .                                                         | 6         |
| 1.2      | Organização . . . . .                                                           | 7         |
| <b>2</b> | <b>O programa e a carga de casos</b>                                            | <b>7</b>  |
| <b>3</b> | <b>Dados</b>                                                                    | <b>8</b>  |
| 3.1      | Três fontes . . . . .                                                           | 8         |
| 3.2      | Reconciliação de códigos municipais . . . . .                                   | 8         |
| 3.3      | Panorama descritivo . . . . .                                                   | 9         |
| 3.4      | Qualidade e limitações dos dados . . . . .                                      | 14        |
| <b>4</b> | <b>Materiais e métodos: pipeline de dados e reprodutibilidade</b>               | <b>14</b> |
| 4.1      | Arquitetura medallion . . . . .                                                 | 14        |
| 4.2      | A escala da camada bruta . . . . .                                              | 15        |
| 4.3      | Governança de dados . . . . .                                                   | 15        |
| 4.4      | Fontes abertas e reprodutibilidade . . . . .                                    | 16        |
| <b>5</b> | <b>Fundamentos</b>                                                              | <b>17</b> |
| 5.1      | Previsão e a tirania da linha de base ingênua . . . . .                         | 17        |
| 5.2      | Medidas de erro e validação temporal . . . . .                                  | 17        |
| 5.3      | Redes neurais como aproximadores de funções . . . . .                           | 17        |
| 5.4      | Por que covariáveis exógenas? . . . . .                                         | 18        |
| 5.5      | Modelos globais e aprendizado profundo para previsão . . . . .                  | 18        |
| <b>6</b> | <b>Tarefa de previsão e protocolo de avaliação</b>                              | <b>18</b> |
| 6.1      | Definição formal . . . . .                                                      | 18        |
| 6.2      | Engenharia de atributos univariados . . . . .                                   | 19        |
| 6.3      | Covariáveis e sua defasagem causal . . . . .                                    | 19        |
| 6.4      | Modelo global único . . . . .                                                   | 19        |
| 6.5      | Protocolo de avaliação honesto . . . . .                                        | 20        |
| 6.6      | Decisões de desenho . . . . .                                                   | 20        |
| <b>7</b> | <b>Modelos</b>                                                                  | <b>20</b> |
| 7.1      | Persistência . . . . .                                                          | 20        |
| 7.2      | Autorregressão linear, perceptron profundo e suas versões com covariáveis . . . | 21        |
| 7.3      | Inicialização sensível à variância . . . . .                                    | 21        |
| 7.4      | Perda e retropropagação . . . . .                                               | 22        |
| 7.5      | Otimizador: AdamW . . . . .                                                     | 22        |

|           |                                                                                 |           |
|-----------|---------------------------------------------------------------------------------|-----------|
| 7.6       | Parada antecipada . . . . .                                                     | 22        |
| 7.7       | Algoritmo de treino . . . . .                                                   | 23        |
| 7.8       | Um passo de treino, em números . . . . .                                        | 23        |
| 7.9       | Complexidade e número de parâmetros . . . . .                                   | 24        |
| 7.10      | Implementação do zero em C++17 . . . . .                                        | 24        |
| <b>8</b>  | <b>Métricas e inferência</b>                                                    | <b>25</b> |
| 8.1       | Métricas de erro . . . . .                                                      | 25        |
| 8.2       | Comparação pareada de modelos . . . . .                                         | 25        |
| <b>9</b>  | <b>Resultados: acurácia fora do tempo</b>                                       | <b>25</b> |
| <b>10</b> | <b>O efeito das covariáveis</b>                                                 | <b>28</b> |
| <b>11</b> | <b>Significância estatística</b>                                                | <b>29</b> |
| 11.1      | Síntese e robustez . . . . .                                                    | 32        |
| 11.2      | Comparação com o arsenal clássico (ETS e SARIMA) . . . . .                      | 32        |
| <b>12</b> | <b>Interpretação: quando ajudam a profundidade e as covariáveis?</b>            | <b>33</b> |
| 12.1      | Por que a profundidade não paga . . . . .                                       | 33        |
| 12.2      | Uma leitura formal: viés, variância e horizonte . . . . .                       | 34        |
| 12.3      | Por que o valor das covariáveis cresce com o horizonte . . . . .                | 34        |
| <b>13</b> | <b>Identificação causal: o emprego formal reduz a demanda por transferência</b> | <b>34</b> |
| 13.1      | O instrumento de Bartik . . . . .                                               | 35        |
| 13.2      | Primeiro estágio e efeito causal . . . . .                                      | 35        |
| 13.3      | Interpretação e cautelas . . . . .                                              | 37        |
| <b>14</b> | <b>Projeção 2026–2028</b>                                                       | <b>37</b> |
| 14.1      | Procedimento e o porquê de o agregado ser mais fácil . . . . .                  | 37        |
| 14.2      | Propagação de erro na recursão . . . . .                                        | 38        |
| 14.3      | Resultados da projeção . . . . .                                                | 39        |
| 14.4      | Banda calibrada por predição conforme . . . . .                                 | 40        |
| 14.5      | Leitura fiscal . . . . .                                                        | 41        |
| 14.6      | Do caseload ao custo: como usar a projeção . . . . .                            | 41        |
| <b>15</b> | <b>Limitações</b>                                                               | <b>42</b> |
| <b>16</b> | <b>Extensões</b>                                                                | <b>42</b> |
| <b>17</b> | <b>Conclusões</b>                                                               | <b>43</b> |
| 17.1      | Método aberto e o sentido das duas perguntas . . . . .                          | 44        |

|                                                    |           |
|----------------------------------------------------|-----------|
| <b>Apêndice A – Métricas completas</b>             | <b>45</b> |
| <b>Apêndice B – Comparações pareadas completas</b> | <b>46</b> |
| <b>Referências</b>                                 | <b>47</b> |

# 1 INTRODUÇÃO

A pergunta que este artigo responde é operacional e mensurável: *dado o histórico do maior programa de transferência condicionada de renda da América Latina, qual é a projeção mais defensável do número de famílias beneficiárias nos próximos anos, com que acurácia tal previsão pode ser feita, e que informação — o próprio passado da série, a demografia, o mercado de trabalho — de fato a melhora?* A resposta tem implicação direta de política pública, porque o custo total de um programa de transferência de renda é, em primeira aproximação, o produto de duas grandezas:

$$\text{custo} \approx \underbrace{\text{carga de casos}}_{\text{demanda estrutural}} \times \underbrace{\text{benefício médio}}_{\text{alavanca de política}}. \quad (1)$$

O valor do benefício é uma *escolha* discricionária do gestor; a carga de casos — *caseload*, o número de núcleos familiares na folha de pagamento — é demanda estrutural, governada por dinâmicas demográficas, de mercado de trabalho e de elegibilidade que nenhum decreto altera no curto prazo. Uma previsão crível da carga de casos isola a parcela do gasto futuro que *não* é decisão discricionária. É essa parcela que tratamos aqui.

A escolha de objeto não é trivial. Diferentemente do gasto nominal — que exige deflação e mistura mudanças de preço e de quantidade —, a contagem de famílias é uma grandeza física, robusta a regimes institucionais e que não requer correção monetária. É a base limpa sobre a qual qualquer projeção de custo deve ser erguida. E, por ser uma série genuína — com tendência, sazonalidade e forte autocorrelação —, é também um banco de provas ideal para duas perguntas metodológicas de interesse independente: *quando a profundidade compensa?* e *quanto valem covariáveis exógenas de contexto, e em que horizonte?*

## 1.1 Contribuições

Este trabalho oferece cinco contribuições.

**Primeira, empírica.** Construímos, de uma camada bruta de 2.533.885.299 registros, um painel município  $\times$  mês de 5.542 municípios e 156 meses (2013–2025) e produzimos com ele uma projeção da carga de casos até dezembro de 2028 cuja incerteza é quantificada por reamostragem fora do tempo, e não assumida.

**Segunda, de integração de dados.** Enriquecemos o painel com duas covariáveis municipais anuais — população (IBGE) e emprego formal ativo (RAIS/PDET) —, reconciliando três sistemas de codificação municipal distintos (SIAFI, IBGE de 7 e de 6 dígitos) por um *crosstalk* de 99,5% de cobertura, e descrevemos a relação estrutural entre cobertura do programa e mercado de trabalho.

**Terceira, metodológica.** Implementamos as redes *do zero* em C++17 — inicialização de He, ReLU, retropropagação explícita, AdamW — sem qualquer biblioteca de aprendizado profundo, seguindo o roteiro de CHEN e GUPTA [7]. Cada operação aritmética é auditável.

**Quarta, inferencial.** Submetemos toda comparação a protocolo *honesto*: padronização

sem vazamento, covariáveis defasadas, partição estritamente fora do tempo, e significância por bootstrap, Wilcoxon e taxa de vitória município a município, reconhecendo que, com  $n \approx 66.504$  por horizonte, um valor- $p$  isolado é desinformativo.

**Quinta, conceitual.** Documentamos dois fatos: a *autorregressão linear domina a rede profunda* em todo horizonte, mesmo alimentada com covariáveis; e as covariáveis carregam sinal *cujo valor cresce com o horizonte* — negligível a um mês, decisivo a doze. O modelo do tamanho certo, com a informação certa, generaliza melhor que o modelo de maior capacidade.

## 1.2 Organização

A Seção 2 situa o programa e a carga de casos. A Seção 3 descreve as três fontes de dados, o *crosswalk* municipal e um panorama descritivo das relações entre caseload, população e emprego. A Seção 4 apresenta os materiais e métodos de engenharia de dados — o pipeline, a governança e a reprodutibilidade. A Seção 5 revisa os fundamentos de previsão e de redes neurais. A Seção 6 formaliza a tarefa e o protocolo. A Seção 7 deriva os cinco modelos, com toda a matemática. A Seção 8 define métricas e inferência. As Seções 9 a 11 apresentam a acurácia, o efeito das covariáveis e sua significância. A Seção 12 interpreta *quando* a profundidade e as covariáveis ajudam. A Seção 14 traz a projeção 2026–2028. As Seções 15 a 17 discutem limitações, extensões e conclusões.

## 2 O PROGRAMA E A CARGA DE CASOS

O Programa Bolsa Família foi instituído pela Lei n.º 10.836, de 9 de janeiro de 2004 [1], unificando programas de transferência de renda anteriores em uma transferência condicionada à frequência escolar e ao acompanhamento de saúde. Entre 2021 e 2023 passou por duas reconfigurações: foi substituído pelo Auxílio Brasil (Medida Provisória n.º 1.061/2021, convertida na Lei n.º 14.284, de 29 de dezembro de 2021 [2]) e retornou como Bolsa Família (Medida Provisória n.º 1.164/2023, convertida na Lei n.º 14.601, de 19 de junho de 2023 [3]). Essas transições alteraram regras e nomenclatura, mas a grandeza que rastreamos — o número de famílias na folha mês a mês — permanece comparável por ser contagem física, não valor monetário. A Figura 20 exibe as três faixas institucionais sobre a série completa.

A *carga de casos* é a contagem de núcleos familiares distintos que recebem ao menos uma parcela em um mês de competência — uma medida de *demanda atendida*, que combina demanda potencial, capacidade administrativa de cadastro e política de revisão de elegibilidade. Sua dinâmica responde a forças lentas — transições no mercado de trabalho, fluxos do Cadastro Único, recadastramentos — e a choques institucionais discretos. Essa combinação de inércia forte com saltos ocasionais torna a série ao mesmo tempo previsível em horizontes curtos e vulnerável a rupturas que nenhum modelo univariado pode antecipar (Seção 15).

A leitura econômica da equação (1) orienta o artigo: se a carga de casos for plana ou declinante, a trajetória do custo é governada pela alavanca de política, não pela demanda. Esta-



belecer empiricamente em que regime a série se encontra — crescimento, platô ou recuo — é insumo direto para o planejamento orçamentário.

### 3 DADOS

#### 3.1 Três fontes

O estudo cruza três bases públicas oficiais (Tabela 1). A primeira é a camada bruta de pagamentos do Bolsa Família do Portal da Transparência da CGU [4], com grão de pagamento  $\times$  mês e 2.533.885.299 registros, da qual mineramos a carga de casos municipal,

$$f_{c,t} = |\{ \text{NIS favorecidos distintos em } (c, t) \}|, \quad (2)$$

para cada município  $c$  e mês  $t$ . A segunda é a estimativa anual de população residente por município do IBGE [5]. A terceira é a Relação Anual de Informações Sociais (RAIS), do Programa de Disseminação das Estatísticas do Trabalho (PDET/MTE) [6] — uma base de 2.060.910.061 vínculos formais (1985–2024) —, de onde extraímos o estoque municipal de vínculos ativos por ano.

**Tabela 1** – Fontes, grão e cobertura

| Fonte                         | Conteúdo            | Grão                   | Registros     |
|-------------------------------|---------------------|------------------------|---------------|
| CGU – Portal da Transparência | pagamentos PBF      | pagamento $\times$ mês | 2.533.885.299 |
| ↪ painel derivado             | carga de casos      | município $\times$ mês | 848.526       |
| RAIS – PDET/MTE               | vínculos formais    | vínculo $\times$ ano   | 2.060.910.061 |
| ↪ painel derivado             | emprego formal/ano  | município $\times$ ano | 83.537        |
| IBGE                          | população residente | município $\times$ ano | 66.840        |


Fontes oficiais. Camadas brutas: pagamentos PBF (2.533.885.299) e vínculos RAIS (2.060.910.061, 1985–2024) somam  $\approx$  4,6 bilhões de linhas. O painel PBF cobre 156 meses (2013–2025); as covariáveis usadas, 2010–2024.

#### 3.2 Reconciliação de códigos municipais

As três fontes usam codificações municipais distintas: o painel da CGU identifica municípios pelo código SIAFI de 4–6 dígitos; o IBGE, pelo código de 7 dígitos; a RAIS, pelo código de 6 dígitos (IBGE sem o dígito verificador). Construímos um *crosswalk* SIAFI  $\rightarrow$  IBGE por correspondência de (*UF, nome do município normalizado*) — removendo acentuação, caixa e pontuação —, e ligamos o código de 6 dígitos da RAIS truncando o de 7 do IBGE. A correspondência cobre 5.542 de 5.571 municípios (99,5%); os 29 sem casamento — em geral grafias divergentes — são excluídos da amostra multivariada. Para que os modelos univariado e multivariado sejam comparados sobre exatamente os mesmos exemplos, *toda* a análise restringe-se aos municípios com covariáveis disponíveis.


### 3.3 Panorama descritivo

Antes de modelar, vale ver o que os dados dizem. A Figura 1 indexa as três séries nacionais a 2013: a carga de casos oscila com a política (salta na pandemia, recua na revisão dos cadastros), enquanto população e, sobretudo, emprego formal seguem trajetórias mais suaves e ascendentes. A Figura 2 converte isso em uma *taxa de cobertura* nacional (famílias por 100 habitantes), que subiu, atingiu o pico e recua — o mesmo padrão da carga absoluta, agora normalizado pela demografia.



Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

**Figura 1 – Contexto nacional indexado (2013 = 100).** A carga de casos é volátil e ligada à política; população e emprego formal crescem de forma mais suave. As três séries não se movem em sincronia — condição para que as covariáveis acrescentem informação.



Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.


**Figura 2 – Taxa de cobertura nacional.** Famílias beneficiárias por 100 habitantes; o pico e o recuo recente persistem após normalizar pela população, indicando que o movimento não é mero efeito demográfico.

A relação mais informativa, porém, é municipal e estrutural. A Figura 3 cruza, para os 5.542 municípios em 2024, a cobertura do programa (famílias por habitante) com a intensidade de emprego formal (vínculos RAIS por habitante). A relação é nitidamente negativa — correlação log-log de  $-0,66$  — e a mediana por decil decresce de forma monótona: onde há mais emprego formal *per capita*, há menos dependência do Bolsa Família. É a assinatura empírica do programa como rede de proteção contracíclica, e a razão teórica para esperar que o emprego formal ajude a prever a carga de casos.


Essa associação *não* é mero artefato de escala. Controlando pela população municipal, a correlação log-log permanece praticamente inalterada ( $-0,67$ ); e mesmo *dentro* de cada unidade da federação — comparando municípios do mesmo estado, o que absorve a geografia histórica da pobreza por efeitos fixos —, a relação persiste, com correlação de  $-0,39$  e inclinação de  $-0,36$  numa regressão com efeitos fixos de UF ( $R^2 = 0,71$ ); essa inclinação é estatisticamente robusta a erro-padrão clusterizado por UF (EP = 0,064,  $t = -5,7$ , 27 clusters). Parte do  $-0,66$  bruto reflete, portanto, o contraste *entre* estados (Norte/Nordeste vs. Sul/Sudeste), mas uma parcela substancial e robusta sobrevive *intra*-estado. Ainda assim, correlação não é causalidade: para *identificar* o efeito do emprego formal sobre a demanda por transferência — isolando confundidores como nível de desenvolvimento e composição setorial —, recorreremos a um instrumento *shift-share* (Bartik), apresentado na Seção 13.

A Figura 4 mostra o mesmo par em níveis absolutos (escala log-log): caseload e emprego crescem juntos em escala — ambos refletem o tamanho do município —, mas a maioria dos

pontos fica acima da paridade, isto é, há mais famílias no PBF do que vínculos formais em muitos municípios pequenos.



**Figura 3 – Cobertura do PBF vs. intensidade de emprego formal, municípios em 2024.** Relação negativa e monótona (mediana por decil em vermelho); correlação log-log de  $-0,66$ . Mais emprego formal por habitante associa-se a menor cobertura do programa.



**Figura 4 – Carga de casos vs. emprego formal, municípios em 2024 (log-log).** As grandezas escalam juntas com o tamanho do município; a linha pontilhada é a paridade 1:1.

A Tabela 2 consolida as três séries em números anuais. Dois fatos saltam. Primeiro, o salto da carga de casos em 2022 — de  $\approx 14$  para  $\approx 21$  milhões de famílias —, coincidente com a expansão do Auxílio Brasil. Segundo, a descontinuidade demográfica de 2022, ano do Censo, que revisou a população nacional para baixo; por isso a taxa de cobertura de 2022 combina o

salto do numerador com a correção do denominador. O emprego formal, por sua vez, cresce de forma quase monótona, de 48,9 para 57,7 milhões de vínculos (2013–2024).


**Tabela 2** – Séries nacionais anuais (2013–2024)

| Ano  | Famílias<br>(mi) | População<br>(mi) | Vínculos<br>(mi) | Cobertura<br>(fam./100 hab.) | Emprego<br>(vínc./100 hab.) |
|------|------------------|-------------------|------------------|------------------------------|-----------------------------|
| 2013 | 14,04            | 200,6             | 48,9             | 7,0                          | 24,4                        |
| 2014 | 13,95            | 202,4             | 49,5             | 6,9                          | 24,5                        |
| 2015 | 13,89            | 204,0             | 48,0             | 6,8                          | 23,5                        |
| 2016 | 13,52            | 205,7             | 46,0             | 6,6                          | 22,4                        |
| 2017 | 13,78            | 207,2             | 46,2             | 6,6                          | 22,3                        |
| 2018 | 14,09            | 208,1             | 46,6             | 6,8                          | 22,4                        |
| 2019 | 13,13            | 209,7             | 46,7             | 6,3                          | 22,3                        |
| 2020 | 14,23            | 211,3             | 46,2             | 6,7                          | 21,9                        |
| 2021 | 14,14            | 212,9             | 48,7             | 6,6                          | 22,9                        |
| 2022 | 20,92            | 202,7             | 52,7             | 10,3                         | 26,0                        |
| 2023 | 20,74            | 207,4             | 55,8             | 10,0                         | 26,9                        |
| 2024 | 20,51            | 212,1             | 57,7             | 9,7                          | 27,2                        |

Famílias: média mensal da carga de casos. População: IBGE (2022 é ano de Censo). Vínculos: RAIS, estoque ativo. Fonte: elaboração própria sobre CGU, IBGE e RAIS.


A desigualdade espacial é igualmente marcante. A Figura 5 ordena os estados pela cobertura em 2024: do Piauí e Maranhão (17,5 famílias por 100 habitantes) a Santa Catarina (2,8) — um gradiente de mais de seis vezes que reproduz o mapa da pobreza brasileira. A relação, contudo, é *estrutural* (de nível), não *dinâmica*: ao correlacionar as *variações* de 2019 a 2024, a associação praticamente desaparece (Figura 6,  $r \approx 0$ ). Isso é coerente com o achado preditivo central — covariáveis de baixa frequência informam o *nível* de longo prazo da carga de casos, não suas flutuações de curto prazo (Seção 10).

**A cobertura do PBF é muito desigual entre estados**  
 Famílias beneficiárias por 100 habitantes, por UF, 2024



**Figura 5 – Cobertura do PBF por UF, 2024.** Famílias beneficiárias por 100 habitantes; em verde, acima da média nacional. O gradiente Norte/Nordeste vs. Sul/Sudeste reproduz a geografia da pobreza.

**A relação é estrutural, não dinâmica: variações de curto prazo não se correlacionam**  
 Variação municipal de 2019 a 2024 (escala log); correlação praticamente nula



**Figura 6 – Variação de caseload vs. emprego, 2019–2024.** A correlação das *variações* é praticamente nula ( $r \approx 0$ ), contrastando com a forte relação em *nível* (Figura 3,  $r = -0,66$ ): a associação é estrutural, não dinâmica.

Três propriedades dos dados condicionam o método e reaparecem na interpretação: (i) a contagem de famílias é regime-robusta e não requer deflação; (ii) há heterogeneidade extrema entre municípios — as cargas variam de centenas a milhões —, com consequência direta sobre a métrica (Seção 8); e (iii) a série é fortemente autocorrelacionada e aproximadamente log-linear

por trechos, ao passo que as covariáveis variam devagar (anualmente) — o que, antecipamos, faz seu valor preditivo emergir só em horizontes longos.

### 3.4 Qualidade e limitações dos dados


Três cautelas acompanham a integração. *Primeira*, a defasagem de publicação: a RAIS de um ano é divulgada no ano seguinte, e as estimativas populacionais são revisadas periodicamente; nosso uso de covariáveis defasadas (equação 5) respeita essa disponibilidade. *Segunda*, a descontinuidade do Censo de 2022, que reduziu a população nacional estimada de 212,9 milhões (2021) para 202,7 milhões (2022) — um degrau visível na Tabela 2 que afeta a *taxa* de cobertura, mas não a contagem de famílias, nosso alvo. *Terceira*, o resíduo do *crosswalk*: 29 municípios (0,5%) não casam por divergência de grafia e são excluídos da amostra multivariada; como o painel univariado é restrito ao mesmo conjunto, a comparação permanece justa, ao custo de uma cobertura de 99,5%. Nenhuma dessas cautelas afeta a contagem de famílias, que é apurada diretamente da fonte primária de pagamentos e não depende de nenhuma das covariáveis.

## 4 MATERIAIS E MÉTODOS: PIPELINE DE DADOS E REPRODUTIBILIDADE

A credibilidade de qualquer resultado empírico repousa sobre a cadeia que produz os dados. Aqui essa cadeia é deliberadamente *aberta e reproduzível*: parte exclusivamente de fontes públicas oficiais, é processada por um pipeline de código aberto e desemboca em modelos implementados do zero. Em princípio, qualquer pessoa, com as mesmas fontes e o mesmo código, reconstrói cada número deste artigo.

### 4.1 Arquitetura medallion

O processamento segue a arquitetura *medallion* [30] — três camadas de refinamento progressivo, *bronze*, *silver* e *gold* — sobre um *lakehouse* aberto (Figura 7). A camada **bronze** ingere os dados crus, sem transformação, preservando a fidelidade à fonte; a **silver** limpa, tipa, normaliza e reconcilia (é onde ocorre o *crosswalk* SIAFI → IBGE da Seção 3); a **gold** entrega agregados prontos para modelagem. O motor de processamento é o Apache Spark [27], que distribui as agregações sobre os bilhões de linhas brutas; o formato de armazenamento é o Delta Lake [28], que confere transações ACID, *schema enforcement* e *time travel* às tabelas; e o catálogo é o Unity Catalog, cujo espaço de nomes de três níveis (catálogo · esquema · tabela) organiza camadas e domínios. Todo o ambiente roda na edição gratuita do Databricks (*Free Edition*) [29] com *warehouse serverless* — isto é, sem custo de infraestrutura, condição para que o experimento seja de fato reproduzível por terceiros.



**Figura 7 – Pipeline reproduzível.** Da fonte pública bruta à previsão: ingestão (bronze), refino (silver), agregação (gold) e modelagem do zero, sobre Apache Spark, Delta Lake e Unity Catalog.

## 4.2 A escala da camada bruta

A camada bruta deste estudo soma **cerca de 4,6 bilhões de linhas** nas duas tabelas principais (Tabela 3): 2.533.885.299 pagamentos do Bolsa Família e 2.060.910.061 vínculos da RAIS. São particionadas por ano, de modo que as agregações podem *podar partições* (*partition pruning*) e varrer apenas os anos necessários — é o que mantém barata, em um *warehouse* gratuito, a mineração de uma tabela de bilhões de linhas. As camadas silver condensam essa escala em painéis tratáveis: o painel municipal de carga de casos, o painel RAIS de 4.173.982 linhas (município × CNAE × ano) e a população municipal de 66.840 células.

**Tabela 3 – Tabelas-fonte e suas escalas**

| Camada                             | Tabela                  | Conteúdo                | Linhas          |
|------------------------------------|-------------------------|-------------------------|-----------------|
| Bronze                             | pbf_pagamentos          | pagamentos PBF/AB (CGU) | 2.533.885.299   |
| Bronze                             | rais_vinculos           | vínculos formais (RAIS) | 2.060.910.061   |
| <i>total bronze (duas tabelas)</i> |                         |                         | ≈ 4.594.795.360 |
| Silver                             | rais_panel              | RAIS mun.×CNAE×ano      | 4.173.982       |
| Silver                             | populacao_municipio_ano | população IBGE mun.×ano | 66.840          |
| Silver                             | painel PBF              | carga de casos mun.×mês | 848.526         |

Contagens lidas dos metadados Delta. Fonte: elaboração própria sobre CGU, IBGE e RAIS.

## 4.3 Governança de dados

As tabelas seguem boas práticas de gestão de dados, no sentido do *Data Management Body of Knowledge* (DAMA-DMBOK) [26]. Quatro controles são centrais. *Catalogação*: cada tabela e coluna carrega metadados descritivos no Unity Catalog, com domínio, granularidade e



proveniência documentados. *Qualidade por construção*: o *schema enforcement* do Delta Lake rejeita escritas que violem o esquema, e a evolução de esquema é versionada. *Integridade transaccional*: as transações ACID e o *time travel* do Delta garantem que cada execução opere sobre um estado consistente e auditável da tabela. *Linhagem e acesso*: o Unity Catalog rastreia a linhagem bronze  $\rightarrow$  silver  $\rightarrow$  gold e governa o acesso por esquema. Essas práticas tornam o pipeline não apenas reproduzível, mas *auditável*: de qualquer número de saída é possível recuar até a linha bruta que o originou.

#### 4.4 Fontes abertas e reprodutibilidade

Todas as três fontes são públicas e oficiais, e nenhuma exige credencial privada: os pagamentos do Bolsa Família estão no Portal da Transparência da CGU [4]; a população, nas estimativas do IBGE [5]; os vínculos formais, na RAIS do PDET/MTE [6]. O pipeline que as ingere e refina é de código aberto,<sup>1</sup> e os modelos são implementados do zero. A reprodutibilidade, portanto, não depende de nenhum dado proprietário nem de infraestrutura paga: é uma propriedade de desenho, não uma promessa.

Todos os números deste artigo são produzidos por código. O painel é minerado da camada bruta de pagamentos e as covariáveis são extraídas das bases de população (IBGE) e emprego (RAIS) e reconciliadas por *crosswalk*; o motor C++17 executa o backtest fora do tempo e a projeção; *scripts* de análise computam os testes de significância e as bandas (*analysis.py*), a identificação causal por Bartik (*bartik\_iv.py*), os benchmarks clássicos, a banda conforme e os testes de MincerZarnowitz e DieboldMariano (*doctoral\_analysis.py*); um teste de unidade (*tests/test\_engine.cpp*) verifica o gradiente; e o *script* de figuras (*build-figures-pbf-forecast*) gera os gráficos a partir dos artefatos versionados (*metrics.json*, *significance.json*, *doctoral\_stats*, *bartik\_iv.json*, *forward\_forecast.csv*, *forward\_band.csv*, *conformal\_band.csv*, *forecast\_h{1,2,3}\_errors\_h\*.csv*, *training\_log.csv*, *covariates\_municipio\_ano.csv*, *muni\_year.csv*). O pipeline é determinístico dados os geradores pseudoaleatórios sementeados: *seed* = 42 na inicialização dos pesos (He) e *seed* = 7 no embaralhamento de minilotes e na separação do conjunto de validação. As escolhas de desenho — janela  $W = 12$  (ciclo anual), arquitetura  $64 \rightarrow 32$  (padrão da literatura, sem busca em grade) e paciência de cinco épocas — foram fixadas *a priori*, por razão de domínio, antes de qualquer avaliação sobre 2025, de modo a não enviesar o desenho ao conjunto de teste.

**Declaração sobre ferramentas de IA.** A implementação do código (o motor C++17, os *scripts* de dados, de análise e de figuras) e a redação deste artigo foram realizadas com assistência do modelo de linguagem Claude Opus 4.8 (Anthropic), sob direção, verificação e revisão dos autores. Essa assistência não compromete a integridade dos resultados, que repousa em duas garantias verificáveis de forma independente: nenhum número foi inventado — todos os valores

---

<sup>1</sup>Este artigo integra a *vertical Bolsa Família* da plataforma aberta de dados públicos brasileiros *Mirante dos Dados*; o pipeline de engenharia de dados e todo o código-fonte são públicos em <https://github.com/leona-rdochalhoub/mirante-dos-dados-br>.

são reproduzíveis a partir dos artefatos de cômputo determinísticos descritos nesta seção —, e toda afirmação conceitual está ancorada nas referências oficiais listadas. Os autores assumem integral responsabilidade pelo conteúdo.

## 5 FUNDAMENTOS

### 5.1 Previsão e a tirania da linha de base ingênua

A previsão de séries temporais é disciplina madura, cujo arcabouço clássico remonta à metodologia de Box e Jenkins para modelos ARIMA [17] e cuja prática contemporânea está sistematizada em Hyndman e Athanasopoulos [18]. Dela herdamos duas disciplinas inegociáveis. A primeira é a avaliação *fora da amostra* e, idealmente, *fora do tempo*: um modelo só demonstra valor se acerta dados posteriores aos do treino. A segunda é bater uma *linha de base ingênua*: para séries com forte componente de passeio aleatório, a previsão ótima de um passo à frente costuma ser o último valor observado — a *persistência*. Um modelo que não a supera não tem valor; e superá-la é, com frequência, surpreendentemente difícil. As competições M de Makridakis, em especial a M4, documentaram sobre cem mil séries que métodos simples frequentemente superam abordagens de aprendizado de máquina puras, e que a complexidade só compensa quando há sinal estruturado a explorar [21]. Tomamos isso como hipótese de trabalho, não dogma.

### 5.2 Medidas de erro e validação temporal

A escolha de métrica não é neutra. Hyndman e Koehler [19] sistematizaram as propriedades das métricas usuais e alertaram para as patologias do erro percentual absoluto (MAPE) quando o alvo se aproxima de zero. Aqui a carga de casos é estritamente positiva e de magnitude considerável, de modo que o MAPE é bem comportado e, por ser invariante de escala, compara honestamente municípios díspares — adotamo-lo como métrica principal, complementado pelo MAE. Quanto a *como* validar: para séries temporais, a validação cruzada aleatória vaza futuro no passado, e a avaliação correta respeita a ordem do tempo, como argumentam Bergmeir e Benítez [20] — o que motiva nossa partição estritamente fora do tempo (Seção 6.5).

### 5.3 Redes neurais como aproximadores de funções

Um perceptron multicamadas (MLP) é uma função paramétrica  $f_{\theta} : \mathbb{R}^d \rightarrow \mathbb{R}$  que compõe transformações afins e não-linearidades. Seu interesse teórico vem dos teoremas de aproximação universal: Cybenko o provou para funções sigmoidais [11] e Hornik, Stinchcombe e White o estenderam a uma classe ampla de não-linearidades [12]. Esses teoremas garantem *expressividade*, mas são silenciosos sobre *aprendizado* e *generalização*: existe uma rede que aproxima a função alvo, o que não diz que a aprenderemos de dados finitos nem que ela generalizará. A história deste artigo mora nessa lacuna. O treino por retropropagação foi popularizado por Rumelhart, Hinton e Williams [10] e é a base do aprendizado profundo moderno [9], [8];

os ingredientes que o tornam estável — ReLU, inicialização sensível à variância, otimizadores adaptativos — são tratados em Goodfellow, Bengio e Courville [8] e, no registro da implementação em C++ de alto desempenho, em Chen e Gupta [7], cujo roteiro seguimos à risca.

#### 5.4 Por que covariáveis exógenas?

Um modelo puramente autorregressivo extrapola o passado da própria série. Funciona enquanto a dinâmica é inercial, mas é cego a mudanças de regime do ambiente. Demografia e mercado de trabalho são, teoricamente, os motores estruturais da elegibilidade: a população define o denominador da demanda, e o emprego formal — cuja relação inversa com a cobertura a Figura 3 documenta — aproxima a informalidade e a vulnerabilidade que elevam a demanda potencial. Incluí-las dá ao preditor estrutura que o histórico recente não contém. Se essa estrutura for de fato não-linear, é também onde a profundidade de uma rede teria, enfim, algo a explorar.

#### 5.5 Modelos globais e aprendizado profundo para previsão

A decisão de treinar *um único* modelo global sobre milhares de séries — em vez de um modelo por município — acompanha uma virada recente da literatura. Hewamalage, Bergmeir e Bandara [22] mostraram, em larga escala, que modelos globais, que aprendem padrões compartilhados entre séries, em geral superam modelos locais quando as séries são numerosas e relacionadas — exatamente o caso de 5.542 trajetórias municipais do mesmo programa. No registro do aprendizado profundo, a vitória do método híbrido de Smyl na competição M4 [23] — combinando suavização exponencial e redes recorrentes — e o modelo probabilístico DeepAR de Salinas *et al.* [24] popularizaram arquiteturas globais; surveys como o de Lim e Zohren [25] mapeiam o campo. Esse corpo de evidências, no entanto, é matizado: os mesmos estudos e as competições M [21] repetidamente encontram que a vantagem do aprendizado profundo só se materializa quando há volume e estrutura suficientes, e que métodos simples permanecem competitivos. Nosso achado — a autorregressão linear global dominando a rede profunda global — é uma instância nítida dessa ressalva, em dados públicos brasileiros: o ingrediente que faltava à profundidade não era arquitetura, mas *informação* (covariáveis), e ainda assim o modelo parcimonioso a usa melhor.

## 6 TAREFA DE PREVISÃO E PROTOCOLO DE AVALIAÇÃO

### 6.1 Definição formal

Para cada município  $c$  e horizonte  $H$ , a tarefa é prever a carga de casos  $f_{c,t}$  no mês  $t$  a partir das observações disponíveis até  $t - H$ . Fixamos a janela em  $W = 12$  meses, de modo que o preditor enxerga um ciclo anual completo. A previsão a  $H$  meses nunca usa informação posterior a  $t - H$ .

## 6.2 Engenharia de atributos univariados

A carga de casos é positiva e de cauda longa; trabalhamos na escala  $\log(1 + x)$ , que comprime a heterogeneidade e estabiliza a variância:  $\ell_{c,t} = \log(1 + f_{c,t})$ . Padronizamos *por município* com média e desvio-padrão calculados *apenas com meses de treino*:

$$s_{c,t} = \frac{\ell_{c,t} - \mu_c}{\sigma_c}, \quad \mu_c = \frac{1}{|\mathcal{T}_c^{\text{tr}}|} \sum_{u \in \mathcal{T}_c^{\text{tr}}} \ell_{c,u}, \quad \sigma_c^2 = \frac{1}{|\mathcal{T}_c^{\text{tr}}|} \sum_{u \in \mathcal{T}_c^{\text{tr}}} (\ell_{c,u} - \mu_c)^2. \quad (3)$$

O vetor univariado tem  $W + 2 = 14$  componentes: doze defasagens padronizadas e dois termos de sazonalidade harmônica do mês-do-ano  $m$  do alvo,

$$\mathbf{x}_{c,t,H}^{\text{uni}} = \left( s_{c,t-H-11}, \dots, s_{c,t-H}; \sin \frac{2\pi m}{12}, \cos \frac{2\pi m}{12} \right) \in \mathbb{R}^{14}, \quad (4)$$

com alvo  $y = s_{c,t}$ . A codificação seno/cosseno coloca o mês sobre o círculo unitário, tornando dezembro e janeiro adjacentes. Para retornar à escala de famílias invertemos as transformações:  $\hat{f}_{c,t} = \exp(\sigma_c \hat{y} + \mu_c) - 1$ .

## 6.3 Covariáveis e sua defasagem causal

Acrescentamos  $\text{NCOV} = 2$  covariáveis municipais anuais — população (IBGE) e vínculos formais ativos (RAIS) —, ambas em escala  $\log(1 + \cdot)$  e padronizadas *globalmente* com estatísticas calculadas sobre anos de treino ( $\leq 2023$ ):

$$\mathbf{g}_{c,\tau} = \left( \frac{\log(1 + \text{pop}_{c,\tau}) - \bar{g}_1}{s_1}, \frac{\log(1 + \text{vinc}_{c,\tau}) - \bar{g}_2}{s_2} \right) \in \mathbb{R}^2. \quad (5)$$

O ano de referência  $\tau$  é o *ano anterior* ao último mês visível  $t - H$ , isto é,  $\tau = \lfloor \text{ano}(t - H) \rfloor - 1$ , e usamos o registro mais recente disponível com  $\text{ano} \leq \tau$ . Essa defasagem de um ano é deliberada: a RAIS de um ano só é publicada no ano seguinte, e populações são estimadas anualmente; tomar  $\tau < \text{ano}(t - H)$  garante que a covariável estaria *de fato disponível* no momento da previsão — nenhuma informação do futuro do alvo entra no modelo. O vetor multivariado é a concatenação  $\mathbf{x}^{\text{mv}} = (\mathbf{x}^{\text{uni}}; \mathbf{g}_{c,\tau}) \in \mathbb{R}^{16}$ .

## 6.4 Modelo global único

Treinamos *um único* modelo global, comum a todos os municípios, em vez de 5.542 modelos locais. A padronização por município coloca todas as trajetórias em escala comum, e o modelo aprende uma vez a *forma* de uma trajetória típica e a transfere para toda parte. A escolha é estatisticamente eficiente e robusta para municípios pequenos, cujas séries individuais seriam curtas demais.

## 6.5 Protocolo de avaliação honesto

Quatro regras impõem honestidade. **(1) Sem vazamento na padronização:**  $\mu_c, \sigma_c$  usam só meses de treino. **(2) Covariáveis defasadas:** ano de referência  $\tau < \text{ano}(t - H)$ , equação (5). **(3) Partição fora do tempo:** alvos com  $t$  anterior a janeiro de 2025 treinam; janeiro a dezembro de 2025 testam ( $\approx 66.504$  previsões por horizonte). **(4) Linha de base forte:** persistência  $\hat{f}_{c,t}^{\text{pers}} = f_{c,t-H}$ . Avaliamos  $H \in \{1, 3, 6, 12\}$  meses, do quase-instantâneo ao horizonte de planejamento orçamentário.

## 6.6 Decisões de desenho

Três escolhas merecem justificativa. A **janela**  $W = 12$  cobre um ciclo anual completo, capturando a sazonalidade sem inflar a dimensão de entrada — janelas maiores aumentariam a variância de estimação sem evidência de ganho, dada a forte autocorrelação de curto alcance da série. O **conjunto de horizontes**  $\{1, 3, 6, 12\}$  amostra o espectro relevante: o passeio-aleatório de um mês, dois horizontes intermediários e o ano fiscal. O **modelo global único** (Seção 5) agrupa força amostral de milhares de séries curtas e é a escolha sustentada pela literatura de modelos globais [22]; a alternativa — 5.542 modelos locais — seria inviável para municípios pequenos e ignoraria a estrutura compartilhada que torna a transferência de aprendizado eficaz.

# 7 MODELOS

Os cinco modelos compartilham os mesmos dados, a mesma perda (erro quadrático médio sobre o alvo padronizado) e a mesma família de otimizador, de modo que qualquer diferença é leitura limpa do efeito da *capacidade* e da *informação* disponível. A Tabela 4 fixa a notação.

**Tabela 4** – Notação

| Símbolo                                           | Significado                                                        |
|---------------------------------------------------|--------------------------------------------------------------------|
| $f_{c,t}$                                         | carga de casos (famílias) do município $c$ no mês $t$              |
| $\ell_{c,t}$                                      | $\log(1 + f_{c,t})$                                                |
| $\mu_c, \sigma_c$                                 | média e desvio-padrão de $\ell_{c,\cdot}$ , só com meses de treino |
| $s_{c,t}$                                         | valor padronizado $(\ell_{c,t} - \mu_c)/\sigma_c$                  |
| $\mathbf{g}_{c,\tau}$                             | covariáveis padronizadas (pop, vínculos) do ano $\tau$             |
| $\mathbf{x}^{\text{uni}}, \mathbf{x}^{\text{mv}}$ | atributos univariado (14) e multivariado (16)                      |
| $H, W$                                            | horizonte de previsão; janela de defasagens (= 12)                 |
| $\mathbf{W}^{(l)}, \mathbf{b}^{(l)}$              | pesos e vieses da camada $l$                                       |
| $\phi$                                            | não-linearidade ReLU, $\phi(u) = \max(0, u)$                       |
| $\eta, \lambda$                                   | taxa de aprendizado e decaimento de peso (AdamW)                   |

## 7.1 Persistência

Sem parâmetros:  $\hat{f} = f_{c,t-H}$ . Piso de comparação e teste da hipótese de passeio aleatório.

## 7.2 Autorregressão linear, perceptron profundo e suas versões com covariáveis


Os quatro modelos aprendidos são instâncias do mesmo MLP, diferindo em profundidade e em entrada. Seja  $L$  o número de camadas de pesos e  $\mathbf{a}^{(0)} = \mathbf{x}$  a entrada. O *passo de avanço* computa, para  $l = 1, \dots, L$ ,

$$\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}, \quad \mathbf{a}^{(l)} = \phi^{(l)}(\mathbf{z}^{(l)}), \quad (6)$$

com ReLU nas camadas ocultas,  $\phi(u) = \max(0, u)$ ,  $\phi'(u) = \mathbb{I}[u > 0]$ , e saída linear,  $\mathbf{a}^{(L)} = \hat{\mathbf{y}}$ . A **autorregressão linear** é  $\text{MLP}(\{14, 1\})$ , sem camada oculta,  $\hat{\mathbf{y}} = \mathbf{w}^\top \mathbf{x}^{\text{uni}} + b$ ; o **perceptron profundo** é  $\text{MLP}(\{14, 64, 32, 1\})$ . As versões **com covariáveis** — *AR linear + cov.* e *MLP profunda + cov.* — têm a mesma topologia interna mas entrada  $\mathbf{x}^{\text{mv}} \in \mathbb{R}^{16}$  (Figura 8).

### A rede com covariáveis: 16 → 64 → 32 → 1

Perceptron multicamadas do zero em C++17 (He · ReLU · AdamW); 2 covariáveis anuais



**Figura 8 – Arquitetura da rede profunda com covariáveis (16 → 64 → 32 → 1).** Aos 14 atributos univariados juntam-se dois nós de covariável (em verde): log da população (IBGE) e log dos vínculos formais (RAIS). He, ReLU, AdamW; tudo do zero em C++17.

## 7.3 Inicialização sensível à variância

Para redes ReLU, He *et al.* [13] mostraram que preservar a variância da ativação exige variância de peso  $2/n_{\text{in}}$ :

$$W_{ij}^{(l)} \sim \mathcal{N}\left(0, \frac{2}{n_{l-1}}\right), \quad b_i^{(l)} = 0, \quad (7)$$

generalização, para ReLU, da inicialização de Glorot e Bengio [14].

## 7.4 Perda e retropropagação

A perda por exemplo é o erro quadrático sobre o alvo padronizado,  $\ell = (\hat{y} - y)^2$ , e  $\mathcal{L} = \frac{1}{N} \sum_i (\hat{y}_i - y_i)^2$ . O gradiente segue por retropropagação [10]. Com saída linear,  $\delta^{(L)} = 2(\hat{y} - y)$ , e

$$\delta^{(l)} = \left( \mathbf{W}^{(l+1)\top} \delta^{(l+1)} \right) \odot \phi'(z^{(l)}), \quad \frac{\partial \ell}{\partial \mathbf{W}^{(l)}} = \delta^{(l)} \mathbf{a}^{(l-1)\top}, \quad \frac{\partial \ell}{\partial \mathbf{b}^{(l)}} = \delta^{(l)}, \quad (8)$$

onde  $\odot$  é o produto de Hadamard. A implementação acumula gradientes ao longo de um minilote e dá um passo de otimização sobre o gradiente médio; o fator 2 é absorvido na taxa de aprendizado.

## 7.5 Otimizador: AdamW

Atualizamos com Adam [15], que adapta o passo por parâmetro a partir de estimativas dos momentos do gradiente. Com  $\mathbf{g}_t$  o gradiente médio do minilote,

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \mathbf{g}_t, \quad \mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2) \mathbf{g}_t^{\odot 2}, \quad (9)$$

$$\widehat{\mathbf{m}}_t = \frac{\mathbf{m}_t}{1 - \beta_1^t}, \quad \widehat{\mathbf{v}}_t = \frac{\mathbf{v}_t}{1 - \beta_2^t}, \quad (10)$$

e o passo, com decaimento de peso *desacoplado* de Loshchilov e Hutter [16],

$$\boldsymbol{\theta}_t = \boldsymbol{\theta}_{t-1} - \eta \frac{\widehat{\mathbf{m}}_t}{\sqrt{\widehat{\mathbf{v}}_t} + \varepsilon} - \eta \lambda \boldsymbol{\theta}_{t-1}. \quad (11)$$

O último termo encolhe os pesos diretamente, recuperando a interpretação de regularização  $L_2$  sob Adam. Usamos  $\beta_1 = 0,9$ ,  $\beta_2 = 0,999$ ,  $\varepsilon = 10^{-8}$ , minilotes de 256. As autorregressões lineares usam cronograma fixo ( $\eta = 10^{-2}$ , sem decaimento, 25 épocas); os perceptrons profundos,  $\eta = 10^{-3}$ ,  $\lambda = 10^{-4}$  e até 60 épocas com parada antecipada.

## 7.6 Parada antecipada

Para conter o sobreajuste dos modelos profundos, retemos 15% do treino como validação e monitoramos o MAE de validação em famílias; com *paciência* de cinco épocas, interrompemos e restauramos os pesos da melhor época (Figura 9) [8]. As autorregressões lineares dispensam o mecanismo.



**Figura 9 – Curva de validação do perceptron profundo ( $H = 12$ ).** O MAE de validação cai, atinge um mínimo e oscila; a parada antecipada seleciona e restaura os pesos da melhor época.

## 7.7 Algoritmo de treino

Reunindo as peças, o treino é o laço do Quadro 1: cada época percorre o treino em minilotes de  $B = 256$ ; acumulam-se gradientes exemplo a exemplo; ao fim do minilote, um passo de AdamW sobre o gradiente médio.

### Quadro 1 – Treino com minilote AdamW e parada antecipada

**entrada:** treino  $\mathcal{D}$ , validação  $\mathcal{V}$  (15%), épocas máx.  $E$ , paciência  $p$   
**inicialize**  $\mathbf{W}$ ,  $\mathbf{b}$  por He (eq. 7);  $\mathbf{m}$ ,  $\mathbf{v} \leftarrow \mathbf{0}$ ;  $t \leftarrow 0$ ;  $\boldsymbol{\theta}^* \leftarrow \boldsymbol{\theta}$   
**para** época = 1, ...,  $E$  **faça**  
    embaralhe  $\mathcal{D}$  e particione em minilotes de tamanho  $B$   
    **para cada** minilote  $\mathcal{B}$ : avanço (eq. 6); acumule grad. (eq. 8);  
         $t \leftarrow t + 1$ ; passo de AdamW (eq. 11); zere acumuladores  
     $\text{mae}_{\text{val}} \leftarrow \text{MAE em } \mathcal{V}$ , em famílias  
    **se** melhora **então** guarde  $\boldsymbol{\theta}^* \leftarrow \boldsymbol{\theta}$  **senão se**  $p$  épocas sem melhora **então pare**  
**retorne**  $\boldsymbol{\theta}^*$

## 7.8 Um passo de treino, em números

Para tornar concreto o maquinário das equações (6)–(11), o Quadro 2 percorre um *único* exemplo da autorregressão linear: avanço, perda, gradiente e o primeiro passo de AdamW de um peso. O exemplo ilustra por que a correção de viés do Adam ( $1 - \beta_1^t$ ) importa nos primeiros passos e como o decaimento de peso desacoplado encolhe o parâmetro independentemente do gradiente.



### Quadro 2 – Um passo de AdamW para um peso (ilustrativo)

Seja, no passo  $t = 1$ , um peso  $w = 0,30$  cuja derivada da perda seja  $g = \partial\ell/\partial w = 0,50$  (média do minilote), com  $\eta = 10^{-2}$ ,  $\beta_1 = 0,9$ ,  $\beta_2 = 0,999$ ,  $\varepsilon = 10^{-8}$ ,  $\lambda = 10^{-4}$ .

$$m_1 = 0,9 \cdot 0 + 0,1 \cdot 0,50 = 0,050, \quad v_1 = 0,999 \cdot 0 + 0,001 \cdot 0,50^2 = 2,5 \times 10^{-4},$$

$$\widehat{m}_1 = \frac{0,050}{1-0,9} = 0,50, \quad \widehat{v}_1 = \frac{2,5 \times 10^{-4}}{1-0,999} = 0,25.$$

$$w \leftarrow w - \eta \frac{\widehat{m}_1}{\sqrt{\widehat{v}_1} + \varepsilon} - \eta\lambda w = 0,30 - 0,01 \cdot \frac{0,50}{0,50} - 0,01 \cdot 10^{-4} \cdot 0,30 \approx 0,290.$$

A correção de viés transforma  $m_1 = 0,05$  em  $\widehat{m}_1 = 0,50$  (sem ela, o primeiro passo seria dez vezes menor); o termo  $-\eta\lambda w$  encolhe  $w$  em  $3 \times 10^{-7}$ , efeito minúsculo por passo mas cumulativo ao longo das épocas.

## 7.9 Complexidade e número de parâmetros

O custo de um avanço é dominado pelos produtos matriz-vetor:  $\text{FLOPs} \approx 2 \sum_l n_{l-1} n_l$ . A Tabela 5 resume a anatomia dos cinco modelos. A contagem de parâmetros explicita o argumento de viés-variância (Seção 12): as autorregressões estimam 15–17 parâmetros; os perceptrons profundos, mais de 3.000. As covariáveis acrescentam apenas dois atributos — custo desprezível, sinal potencialmente grande.

**Tabela 5** – Anatomia dos cinco modelos

| Modelo              | Parâmetros | FLOPs/avanço    | Entrada / regularização            |
|---------------------|------------|-----------------|------------------------------------|
| Persistência        | 0          | 0               | —                                  |
| AR linear           | 15         | 28              | 14 atrib.; fixo                    |
| MLP profunda        | 3.073      | $\approx 5.888$ | 14 atrib.; AdamW + parada antecip. |
| AR linear + cov.    | 17         | 32              | 16 atrib.; fixo                    |
| MLP profunda + cov. | 3.201      | $\approx 6.144$ | 16 atrib.; AdamW + parada antecip. |

Parâmetros da MLP profunda:  $14 \cdot 64 + 64 + 64 \cdot 32 + 32 + 32 \cdot 1 + 1 = 3.073$ ; com covariáveis,  $16 \cdot 64 + \dots = 3.201$ .

Fonte: elaboração própria.

## 7.10 Implementação do zero em C++17

Todo o motor — camadas densas, ReLU, retropropagação, AdamW — é implementado do zero em C++17, usando apenas `<vector>`, `<cmath>`, `<map>` e `<random>`, sem LibTorch, BLAS ou qualquer dependência de aprendizado profundo. Os pesos são armazenados em ordem *row-major* por camada; avanço e retropropagação operam um exemplo por vez, acumulando o gradiente sobre o minilote antes de um passo de Adam. Pedagogicamente alinhada a [7], a escolha torna cada operação inspecionável e o experimento integralmente reproduzível, ao custo de desempenho irrelevante nesta escala. A correção da retropropagação manual é verificada por um teste de unidade que compara o gradiente analítico ao numérico (diferenças finitas):

o erro relativo máximo é de  $7,5 \times 10^{-10}$ , confirmando que cada derivada está corretamente implementada.

## 8 MÉTRICAS E INFERÊNCIA

### 8.1 Métricas de erro

Todas as métricas são computadas *em unidades de famílias*, após a inversão da padronização, sobre as  $\approx 66.504$  previsões retidas de cada horizonte. Para erros  $e_i = \hat{f}_i - f_i$ ,

$$\text{MAE} = \frac{1}{N} \sum_i |e_i|, \quad \text{MAPE} = \frac{100}{N} \sum_i \frac{|e_i|}{f_i}, \quad \text{RMSE} = \sqrt{\frac{1}{N} \sum_i e_i^2}, \quad R^2 = 1 - \frac{\sum_i e_i^2}{\sum_i (f_i - \bar{f})^2}. \quad (12)$$

O  $R^2$  é dominado pela variância *entre* municípios e, por isso, pouco informativo aqui (fica acima de 0,98 para todos); a métrica que separa os modelos é o MAPE, invariante de escala, complementada pelo MAE.

### 8.2 Comparação pareada de modelos

Com  $n \approx 66.504$ , qualquer diferença minúscula é “estatisticamente significativa” a um valor- $p$  desprezível; o valor- $p$  isolado é desinformativo. Reportamos, por par de modelos, pareados no mesmo conjunto: (i) a diferença média de erro absoluto  $\Delta\text{MAE} = \text{MAE}_B - \text{MAE}_A$  (positivo  $\Rightarrow A$  vence), em famílias; (ii) seu IC de 95% por bootstrap pareado, com 2.000 reamostragens [33]; (iii) o valor- $p$  do teste de Wilcoxon [32]; e (iv) a *taxa de vitória*, a fração de previsões em que  $|e_A| \leq |e_B|$ . O bootstrap mede a incerteza da *magnitude*; Wilcoxon, a consistência do *signal*; a taxa de vitória, sua *disseminação*. A lógica de comparar acurácia preditiva por pares remonta a Diebold e Mariano [31].

## 9 RESULTADOS: ACURÁCIA FORA DO TEMPO

A Tabela 6 reúne MAE e MAPE dos cinco modelos nos quatro horizontes; a Figura 10 mostra o núcleo univariado e a Figura 11 traduz tudo em redução de MAE sobre a persistência.


**Tabela 6** – Acurácia fora do tempo por horizonte ( $\approx 66.504$  previsões cada)

| Horizonte | Modelo                  | MAE (fam.)   | MAPE (%)    | vs. persist. |
|-----------|-------------------------|--------------|-------------|--------------|
| 1 mês     | Persistência            | <b>54,6</b>  | 1,94        | —            |
|           | AR linear               | 57,5         | 1,98        | −5%          |
|           | MLP profunda            | 54,9         | 2,04        | −1%          |
|           | AR linear + cov.        | 60,3         | 1,98        | −11%         |
|           | MLP profunda + cov.     | 55,4         | <b>1,97</b> | −2%          |
| 3 meses   | Persistência            | 118,3        | 4,19        | —            |
|           | AR linear               | <b>98,1</b>  | 3,83        | +17%         |
|           | MLP profunda            | 117,5        | 4,24        | +1%          |
|           | AR linear + cov.        | 107,9        | <b>3,82</b> | +9%          |
|           | MLP profunda + cov.     | 125,2        | 4,22        | −6%          |
| 6 meses   | Persistência            | 206,1        | 7,26        | —            |
|           | AR linear               | 150,2        | 5,99        | +27%         |
|           | MLP profunda            | 201,8        | 7,15        | +2%          |
|           | AR linear + cov.        | <b>151,0</b> | <b>5,95</b> | +27%         |
|           | MLP profunda + cov.     | 189,1        | 6,62        | +8%          |
| 12 meses  | Persistência            | 268,8        | 9,92        | —            |
|           | AR linear               | 243,1        | 8,80        | +10%         |
|           | MLP profunda            | 297,1        | 9,89        | −11%         |
|           | <b>AR linear + cov.</b> | <b>223,3</b> | <b>8,62</b> | +17%         |
|           | MLP profunda + cov.     | 298,7        | 9,55        | −11%         |

Em negrito, o melhor de cada bloco. A coluna “vs. persist.” é a redução de MAE sobre a ingênua. Fonte: elaboração própria.

### Erro percentual cresce com o horizonte — e a rede rasa vence

MAPE nas previsões municipais retidas (alvos de 2025), por horizonte




Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

**Figura 10 – MAPE fora da amostra (núcleo univariado).** A um mês a persistência é imbatível; de três meses em diante a autorregressão linear tem o menor erro percentual, e a vantagem cresce com o horizonte.

### Covariáveis elevam o modelo linear; a profundidade segue atrás

Ganho de acurácia (↓ MAE) sobre a ingênua; negativo = pior que repetir o último valor



Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

**Figura 11 – Redução de MAE sobre a persistência, quatro modelos aprendidos.** A autorregressão linear (com e sem covariáveis) lidera; a profundidade fica sistematicamente atrás. Em 12 meses, é o modelo *linear com covariáveis* que mais reduz o erro (+17%).

A leitura é direta. A **um mês**, a persistência tem o menor MAE (54,6); nenhum modelo

aprendido a supera — assinatura empírica de um passeio aleatório. De **três meses** em diante, a autorregressão linear assume a liderança: reduz o MAE em 17%, 27% e 10% (3, 6 e 12 meses) sobre a ingênua. O perceptron profundo melhora pouco e é *dominado* pelo linear em todo horizonte; com ou sem covariáveis, a profundidade não paga. O ponto novo, e o mais relevante, aparece no horizonte de **doze meses**: ali o modelo *linear com covariáveis* é o melhor de todos (+17% vs. +10% do linear univariado), sinal de que demografia e emprego carregam informação estrutural que o histórico recente não contém. A próxima seção isola esse efeito.

## 10 O EFEITO DAS COVARIÁVEIS

A pergunta-chave do estudo multivariado é direta: *adicionar população e emprego formal melhora a previsão?* A Figura 12 responde, mostrando o  $\Delta$ MAE de cada modelo *com* covariáveis contra sua versão univariada, com IC de 95%; a Tabela 7 traz os números.


**Tabela 7** – Efeito das covariáveis:  $\Delta$ MAE (com cov. – univariado), pareado

| <i>H</i> | Comparação                   | $\Delta$ MAE (fam.) | IC 95%         |
|----------|------------------------------|---------------------|----------------|
| 1        | linear+cov vs. linear        | −2,85               | [−5,4; −0,3]   |
|          | deep+cov vs. deep            | −0,50               | [−1,6; +0,5]   |
| 3        | linear+cov vs. linear        | −9,81               | [−12,4; −7,2]  |
|          | deep+cov vs. deep            | −7,70               | [−10,4; −5,2]  |
| 6        | linear+cov vs. linear        | −0,82               | [−2,1; +0,5]   |
|          | <b>deep+cov vs. deep</b>     | <b>+12,71</b>       | [+8,4; +16,7]  |
| 12       | <b>linear+cov vs. linear</b> | <b>+19,76</b>       | [+12,1; +27,5] |
|          | deep+cov vs. deep            | −1,55               | [−5,9; +3,1]   |

$\Delta$ MAE > 0 indica que as covariáveis *ajudam*. IC por bootstrap pareado (2.000 reamostragens). Fonte: elaboração própria.

## Demografia e mercado de trabalho ajudam — sobretudo o modelo linear

Efeito de adicionar população (IBGE) e emprego formal (RAIS), com IC 95%



Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

**Figura 12 – O valor das covariáveis cresce com o horizonte.** ΔMAE de adicionar população e emprego formal, com IC 95%: negativo ou nulo a 1–3 meses, fortemente positivo para o modelo linear em 12 meses (+19,8, IC [+12,1; +27,5]) e para o profundo em 6 meses (+12,7).

O padrão é claro e econômico. A **curto prazo (1–3 meses)**, as covariáveis *não ajudam* e chegam a prejudicar — a dinâmica é dominada pela autocorrelação mensal, e variáveis anuais defasadas apenas adicionam ruído e uma incompatibilidade de frequência. A **seis meses**, ajudam o modelo profundo de forma robusta (+12,7). A **doze meses**, elevam o modelo linear de forma grande e robusta (+19,8, IC estritamente positivo): é justamente onde a autorregressão pura enfraquece e os motores estruturais — quantos habitantes, quantos empregos formais — passam a governar a demanda. O valor de uma covariável de baixa frequência é, portanto, *função do horizonte*: invisível no curto prazo, decisivo no longo. Notavelmente, mesmo alimentada com covariáveis, a rede profunda permanece atrás do modelo linear (Tabela 6): a informação ajuda, mas a forma certa de usá-la continua sendo o modelo parcimonioso.


## 11 SIGNIFICÂNCIA ESTATÍSTICA

A Tabela 8 compara os modelos aprendidos contra a persistência e entre si; a Figura 13 visualiza a vantagem da autorregressão linear com IC; a Figura 14, a taxa de vitória; e a Figura 15, a distribuição completa do erro em seis meses.

**Tabela 8** – Comparações pareadas selecionadas ( $n \approx 66.504$ )


| $H$ | Comparação                    | $\Delta\text{MAE}$ (fam.) | IC 95%         |
|-----|-------------------------------|---------------------------|----------------|
| 3   | AR linear vs. persist.        | +20,18                    | [+17,6; +22,7] |
|     | AR linear vs. deep            | +19,39                    | [+16,8; +22,0] |
| 6   | <b>AR linear vs. persist.</b> | <b>+56,00</b>             | [+49,7; +62,4] |
|     | deep+cov vs. AR linear        | -38,95                    | [-44,7; -33,6] |
| 12  | AR linear vs. persist.        | +25,71                    | [+14,2; +37,9] |
|     | AR linear + cov. vs. persist. | +45,5                     | [+33; +58]     |

$\Delta\text{MAE} > 0$  favorece o primeiro modelo. Todos os testes de Wilcoxon têm  $p < 10^{-30}$ ; a leitura está no IC. A última linha é a soma das vantagens linear vs. persist. (+25,71) e linear+cov vs. linear (+19,76). Fonte: elaboração própria.




Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

**Figura 13 – Vantagem da autorregressão linear sobre a persistência, com IC 95%.** A seis meses o intervalo é estritamente positivo e largo (+56 famílias): vantagem grande e robusta. A doze meses permanece positivo, e as covariáveis o ampliam ainda mais (Seção 10).



**Figura 14 – Taxa de vitória sobre a persistência.** A fração de municípios em que cada modelo vence cresce com o horizonte, atingindo 64% para a autorregressão linear em seis meses: a vantagem se dissemina pela maioria, não vem de poucos atípicos.



**Figura 15 – Distribuição acumulada do erro percentual absoluto ( $H = 6$ ).** As curvas com covariáveis e a do modelo linear ficam à esquerda da persistência em quase toda a faixa: para qualquer limiar de erro, mais municípios o cumprem. Domínio estocástico de primeira ordem aproximado.



## 11.1 Síntese e robustez

A Tabela 9 resume o melhor modelo em cada horizonte e o ganho correspondente. A conclusão é *robusta* a múltiplos critérios: as quatro lentes — MAE, MAPE (Tabela 6), RMSE ( $R^2$ , Apêndice A) e taxa de vitória (Apêndice B) — concordam na ordenação dos modelos em 3, 6 e 12 meses, e os intervalos de confiança das vantagens decisivas são estritamente positivos. Nenhuma das conclusões depende de uma única métrica ou de um único horizonte.

**Tabela 9** – Síntese: melhor modelo por horizonte

| Horizonte | Melhor modelo      | Redução de MAE | Regime                |
|-----------|--------------------|----------------|-----------------------|
| 1 mês     | Persistência       | —              | passeio aleatório     |
| 3 meses   | AR linear          | +17%           | autocorrelação domina |
| 6 meses   | AR linear (+ cov.) | +27%           | ganho máximo da AR    |
| 12 meses  | AR linear + cov.   | +17%           | covariáveis decisivas |

Redução de MAE sobre a persistência. Em 6 meses, AR linear e AR linear + cov. empatam (+27%). Fonte: elaboração própria.


Conclusões inferenciais. (i) A vantagem da autorregressão linear em seis meses é grande, robusta e disseminada (vence 64% dos municípios). (ii) A doze meses a vantagem persiste e é *ampliada pelas covariáveis*: linear+cov supera a persistência por  $\approx +45$  famílias, contra +26 do linear puro. (iii) A profundidade, mesmo com covariáveis, é dominada pela autorregressão linear em 3, 6 e 12 meses (deep+cov vs. linear:  $-27$ ,  $-39$ ,  $-56$  famílias) — a informação ajuda, a capacidade extra não.

## 11.2 Comparação com o arsenal clássico (ETS e SARIMA)

Um cético da literatura de previsão perguntaria: a autorregressão linear global supera não apenas a persistência, mas os métodos estatísticos clássicos? Para responder, ajustamos, sobre a série *nacional* e no mesmo protocolo fora do tempo de 2025, dois benchmarks consagrados: a suavização exponencial de HoltWinters (ETS, com tendência e sazonalidade aditivas) e um SARIMA  $(1, 1, 1)(0, 1, 1)_{12}$ . A Figura 16 mostra o resultado: a autorregressão linear do estudo tem o *menor* MAPE nacional em todos os horizontes, e a margem *cresce* com o horizonte — 4,7% em 12 meses, contra 10,2% do ETS e 10,1% do SARIMA. Mais notável, ETS e SARIMA ficam *abaixo* da própria persistência em horizontes longos: ajustar tendência e sazonalidade a uma série com quebras estruturais (os três regimes do programa) produz extrapolações instáveis. O achado ecoa, mais uma vez, a lição das competições M [21]: sofisticação malcasada com a estrutura do sinal piora, não melhora.

### O modelo do estudo bate o arsenal clássico em todo horizonte

MAPE da série nacional (2025): ETS e SARIMA vs. a autorregressão linear global



Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

**Figura 16 – Benchmarks clássicos.** MAPE da série nacional (2025): a autorregressão linear global do estudo supera ETS e SARIMA em todos os horizontes, e a vantagem cresce com o horizonte.

Dois testes formais complementam o quadro, ambos sobre a série nacional. O teste de MincerZarnowitz não rejeita a hipótese de nãoviés a um mês (estatística de Wald = 0,28), embora a baixa potência de 12 observações nacionais o torne inconclusivo nos horizontes longos. O teste de DieboldMariano [31] entre o modelo linear e a persistência, com correção de pequena amostra de HarveyLeybourneNewbold, fica abaixo do limiar de significância no agregado nacional — reflexo direto das 12 observações —, ao passo que o bootstrap pareado sobre as 66.504 previsões municipais (Seção anterior) tem potência ampla. É a razão de centrarmos a inferência no painel municipal, não no agregado:  $n = 12$  não sustenta um teste de série temporal.

## 12 INTERPRETAÇÃO: QUANDO AJUDAM A PROFUNDIDADE E AS COVARIÁVEIS?

Dois fenômenos pedem explicação: por que a rede mais simples vence a mais profunda, e por que o valor das covariáveis cresce com o horizonte. Ambos seguem da estrutura do sinal e do compromisso entre viés e variância [8], [18].

### 12.1 Por que a profundidade não paga

**A um mês, a série é quase um passeio aleatório.** A melhor previsão de  $f_{c,t}$  a partir de  $f_{c,t-1}$  é aproximadamente o próprio  $f_{c,t-1}$ ; o incremento é dominado por ruído. A persistência é quase ótima, e qualquer parâmetro estimado só adiciona variância. **Num sinal quase log-linear, a autorregressão é o modelo do tamanho certo.** Uma combinação linear de doze defasagens

captura quase toda a estrutura previsível — tendência e persistência — com pouquíssimos parâmetros, e generaliza melhor fora do tempo. **O perceptron profundo gasta capacidade que o sinal não recompensa:** suas camadas ocultas modelam interações não-lineares; quando a estrutura é quase linear, a capacidade extra vira variância (sobreajuste), não redução de viés. A regularização o resgata, mas não o suficiente para alcançar o linear.

## 12.2 Uma leitura formal: viés, variância e horizonte

Para um estimador  $\hat{f}$  de  $f = g(x) + \epsilon$  com ruído de média zero e variância  $\sigma^2$ , o erro quadrático esperado se decompõe como

$$\mathbb{E}[(f - \hat{f})^2] = \underbrace{(g - \mathbb{E}[\hat{f}])^2}_{\text{viés}^2} + \underbrace{\mathbb{E}[(\hat{f} - \mathbb{E}[\hat{f}])^2]}_{\text{variância}} + \underbrace{\sigma^2}_{\text{irreduzível}}. \quad (13)$$

A persistência tem viés alto e variância nula; a autorregressão linear corta o viés com variância pequena; o perceptron profundo reduz mais o viés *em princípio*, mas adiciona variância substancial. O ponto que minimiza (13) *depende do horizonte*: em  $H = 1$ , o termo  $\sigma^2$  domina e vence quem nada estima (persistência); em  $H = 6$ , o viés da persistência explode e a autorregressão acerta o equilíbrio.

## 12.3 Por que o valor das covariáveis cresce com o horizonte

A mesma equação (13) explica o efeito das covariáveis. A informação que uma covariável adiciona reduz o viés *na medida em que ela prediz a parte do alvo que as defasagens não predizem*. A curto prazo, as defasagens já contêm quase tudo: a população de um município há um ano nada acrescenta sobre o próximo mês, e a covariável anual, defasada, apenas injeta variância — daí o  $\Delta\text{MAE}$  negativo em 1–3 meses (Tabela 7). A longo prazo, porém, a autocorrelação se esgota e a previsão precisa de *âncoras estruturais*: quantos habitantes, quanto emprego formal. É aí que a covariável corta viés genuíno, e o  $\Delta\text{MAE}$  se torna grande e positivo em 12 meses. Em suma: o valor de uma covariável de baixa frequência é crescente no horizonte porque é exatamente no longo prazo que o sinal autorregressivo se torna insuficiente.

A lição metodológica — *case a capacidade do modelo e a frequência da informação à estrutura e ao horizonte do problema* — ecoa, em dados públicos brasileiros, o achado das competições de previsão em larga escala [21]: sofisticação não é, por si, acurácia.

# 13 IDENTIFICAÇÃO CAUSAL: O EMPREGO FORMAL REDUZ A DEMANDA POR TRANSFERÊNCIA

As seções anteriores estabeleceram que o emprego formal *prevê* a carga de casos (covariáveis ajudam no longo prazo, Seção 10) e que cobertura e emprego se *associam* negativamente entre municípios (Seção 3). Resta a pergunta causal: o emprego formal *reduz* a demanda por

Bolsa Família, ou ambos apenas refletem um terceiro fator (o nível de desenvolvimento local)? Esta seção a enfrenta com um desenho de identificação *shift-share*.

### 13.1 O instrumento de Bartik

A endogeneidade é clara: municípios mais pobres têm, simultaneamente, menos emprego formal e mais Bolsa Família, de modo que a regressão simples confunde causa e seleção. A estratégia de *shift-share*, ou de Bartik [36], resolve isso construindo um preditor do crescimento do emprego que não depende das condições locais de demanda. Para o município  $c$ , definimos

$$B_c = \sum_s \omega_{c,s,t_0} g_{s,-c}^{t_0 \rightarrow t_1}, \quad (14)$$

onde  $\omega_{c,s,t_0}$  é a *participação* do setor  $s$  no emprego formal do município no ano-base  $t_0$  (2013), e  $g_{s,-c}$  é o crescimento *nacional* do setor  $s$  entre  $t_0$  e  $t_1$ , calculado *excluindo* o próprio município (*leave-one-out*). A intuição: um município especializado em setores que cresceram nacionalmente herda esse crescimento por composição, e essa parcela do crescimento do emprego é plausivelmente exógena às condições locais de pobreza. A identificação repousa na exogeneidade das participações setoriais iniciais condicional aos controles, no sentido de Goldsmith-Pinkham, Sorkin e Swift [37]; com 92 setores CNAE, o instrumento agrega muitos choques setoriais [38].


Estimamos, em primeiras diferenças de longo prazo,

$$\Delta \log(\text{cobertura}_c) = \beta \Delta \log(\text{emprego}_c) + \gamma' w_c + \varepsilon_c, \quad (15)$$

instrumentando  $\Delta \log(\text{emprego}_c)$  por  $B_c$ , com controles  $w_c$  (efeitos fixos de UF e log da população-base) e erropadrão clusterizado por UF. Reportamos duas janelas: 2013–2019 (regime PBF estável, antes do choque do Auxílio Brasil) e 2013–2024 (completa).

### 13.2 Primeiro estágio e efeito causal

O instrumento é forte. Na janela limpa 2013–2019, o primeiro estágio tem coeficiente  $\pi = +1,06$  e estatística  $F = 67,7$  (Figura 17) — muito acima do limiar usual de 10; na janela completa,  $F = 26,3$ . Não há, portanto, problema de instrumento fraco.




**Figura 17 – Primeiro estágio do shift-share.** O instrumento de Bartik (participação setorial inicial  $\times$  crescimento nacional) prevê fortemente o crescimento efetivo do emprego formal municipal, 2013–2019 ( $F = 67,7$ ).

A Tabela 10 e a Figura 18 trazem o resultado central. O efeito causal estimado por variável instrumental (2SLS) é *negativo* nas duas janelas e *maior em magnitude* que o de MQO —  $-0,31$  vs.  $-0,05$  (2013–2019) e  $-0,63$  vs.  $-0,06$  (2013–2024). Esse padrão — IV mais negativo que MQO — é a assinatura de *atenuação*: a regressão simples, contaminada por erro de medida e endogeneidade, *subestima* o efeito do emprego. Na janela completa o efeito é estatisticamente significativo ( $\beta_{IV} = -0,63$ ,  $t = -2,2$ , IC 95%  $[-1,20; -0,06]$ ); na janela pré-choque, o sinal e a magnitude são os mesmos, porém o intervalo cruza zero — mesma evidência, menor potência no regime estável, de menor variação de emprego.

**Tabela 10** – Efeito do emprego formal sobre a cobertura do PBF (2SLS, EP clusterizado por UF)

| Janela                 | MQO $\beta$ | IV $\beta$                | IC 95% (IV)      | F 1º est. |
|------------------------|-------------|---------------------------|------------------|-----------|
| 2013–2019 (pré-choque) | $-0,05$     | $-0,31$                   | $[-0,77; +0,15]$ | 67,7      |
| 2013–2024 (completa)   | $-0,06$     | <b><math>-0,63</math></b> | $[-1,20; -0,06]$ | 26,3      |

$n = 5.211$  municípios, 27 *clusters* (UF). Controles: efeitos fixos de UF e log-população. IV *just-identified* pelo instrumento de Bartik. Fonte: elaboração própria sobre RAIS, CGU e IBGE.



**Figura 18 – Efeito causal vs. MQO.** O efeito 2SLS do emprego formal sobre a cobertura do PBF é negativo e maior em magnitude que o de MQO (atenuação), significativo na janela completa.

### 13.3 Interpretação e cautelas

A leitura é que o emprego formal *causa* redução da dependência do Bolsa Família: criar vínculos formais retira famílias da elegibilidade, não apenas se correlaciona com municípios que já têm menos pobreza. É a contrapartida causal da leitura contracíclica da Seção 3, e dá fundamento estrutural — não apenas preditivo — ao uso do emprego como covariável.

Três cautelas. *Primeira*: a significância vem da janela completa, cujo primeiro estágio, embora forte, inverte de sinal em relação à janela limpa — reflexo do choque estrutural de 2020–2021, que embaralha a previsão setorial; tratamos a estimativa pontual com a correspondente cautela. *Segunda*: a exogeneidade do shift-share é uma hipótese de identificação, não um fato — ela falha se as participações setoriais de 2013 já anteciparem trajetórias de pobreza. *Terceira*: especificações sem efeitos fixos de UF, que exploram variação nacional, são imprecisas demais para inferência. Por isso descrevemos o achado como evidência causal *moderada*, que eleva o  $-0,66$  de associação a efeito plausivelmente causal, ainda que o desenho definitivo — uma descontinuidade de elegibilidade ou um *event study* de fechamentos de planta via CAGED — permaneça como agenda (Seção 16).

## 14 PROJEÇÃO 2026–2028


### 14.1 Procedimento e o porquê de o agregado ser mais fácil

Para projetar, reajustamos os modelos sobre *todas* as janelas observadas e rolamos cada município adiante de forma *recursiva*: cada previsão vira a entrada mais recente da janela seguinte; as covariáveis são mantidas no último ano conhecido (2024), por ainda não observadas no futuro. Note-se que, aqui, usar toda a história (inclusive 2025) para ajustar o modelo e padronizar as séries *não* é vazamento: a projeção prevê 2026–2028, meses genuinamente não observados, e no momento real da previsão toda a série até dezembro de 2025 está, de fato, disponível. O

vazamento é evitado onde importa — na *avaliação* fora do tempo (Seção 6.5), cuja padronização usa exclusivamente meses anteriores ao corte, e de onde vêm todos os números de acurácia e a inferência reportados. Somamos as previsões municipais à trajetória nacional  $\hat{N}_t = \sum_c \hat{f}_{c,t}$ . A incerteza nacional é o MAPE *agregado* de backtest, não a soma dos erros municipais, porque na agregação os erros idiossincráticos largamente se cancelam. Formalmente, para erros  $e_c$  com variância  $\varsigma_c^2$  e correlação  $\rho_{cc'}$ ,

$$\text{Var}\left(\sum_c e_c\right) = \sum_c \varsigma_c^2 + \sum_{c \neq c'} \rho_{cc'} \varsigma_c \varsigma_{c'}; \quad (16)$$

como  $\rho_{cc'}$  é, em média, pequeno, o desvio do agregado cresce como  $\sqrt{m}$  enquanto o agregado cresce como  $m$ , e o erro relativo encolhe  $\sim 1/\sqrt{m_{\text{ef}}}$ . É por isso que o MAPE nacional cai para 1,29% / 2,17% / 3,52% / 4,68% (modelo linear) em 1 / 3 / 6 / 12 meses — muito abaixo dos MAPEs municipais (Tabela 6). A Figura 19 mostra o ajuste nacional sobre 2025, com as covariáveis reduzindo ainda mais o erro agregado de longo prazo (MAPE nacional de 4,49% em 12 meses para o modelo linear com covariáveis).



**Figura 19 – Ajuste nacional na janela de teste ( $H = 6$ ).** A soma das previsões municipais reproduz o agregado observado de 2025 com erro pequeno; os erros municipais cancelam-se na agregação, o que justifica usar o MAPE nacional como banda da projeção.

## 14.2 Propagação de erro na recursão


A projeção a  $k$  meses encadeia  $k$  previsões de um passo, cada uma alimentada pela anterior. Se cada passo introduz um erro  $\eta_t$  aproximadamente de média zero e variância  $\sigma_\eta^2$ , e o operador de um passo tem ganho local  $|a| < 1$  (a série é estacionária em torno de sua tendência na escala padronizada), o erro acumulado após  $k$  passos satisfaz, em primeira ordem,

$$\varepsilon_k \approx \sum_{j=0}^{k-1} a^j \eta_{k-j}, \quad \text{Var}(\varepsilon_k) \approx \sigma_\eta^2 \frac{1 - a^{2k}}{1 - a^2} \xrightarrow{k \rightarrow \infty} \frac{\sigma_\eta^2}{1 - a^2}. \quad (17)$$

Dois efeitos competem. De um lado, a variância do erro *cresce* com o horizonte, mas *satura* (não explode), porque  $|a| < 1$  amortece contribuições antigas. De outro, esse mesmo amortecimento implica *reversão à média*: previsões de longo prazo são puxadas para a média histórica de cada município, o que tende a suavizar trajetórias e pode subestimar movimentos persistentes — é a origem da limitação discutida na Seção 15. A equação (17) explica por que a banda nacional da Figura 20 se alarga de forma decrescente, e não linear, com o horizonte.

### 14.3 Resultados da projeção

A Figura 20 apresenta a série histórica e a projeção até dezembro de 2028; a Tabela 11 resume os marcos. A carga de casos nacional atingiu o **pico em janeiro de 2023** (21.243.010 famílias) e **recua desde então**, em 18.401.764 famílias em dezembro de 2025. Ambos os modelos projetam *consolidação, não crescimento*. A trajetória central (autorregressão linear) leva a  $\approx 15.442.971$  famílias em dezembro de 2028 ( $-16\%$  ante dezembro de 2025); o modelo linear com covariáveis projeta praticamente o mesmo ( $\approx 15.456.747$ ), e o perceptron profundo com covariáveis, um recuo mais brando ( $\approx 15.902.025$ ). A convergência das projeções para a faixa de 15,4–15,9 milhões reforça a robustez da conclusão.



Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

**Figura 20 – Carga de casos nacional, 2013–2025, e projeção 2026–2028, por regime do programa.** A série atingiu o pico em 2022–2023 e recua. A projeção central indica consolidação em torno de 15,4 milhões de famílias até 2028. A banda sombreada é um intervalo *informal*, derivado do MAPE agregado de backtest de 2025 — não um intervalo de confiança frequentista de 95%.




**Tabela 11** – Marcos da carga de casos nacional

| Grandeza                               | Valor (famílias)           |
|----------------------------------------|----------------------------|
| Pico (jan/2023)                        | 21.243.010                 |
| Último observado (dez/2025)            | 18.401.764                 |
| Projeção central (AR linear), dez/2028 | $\approx 15.442.971$       |
| AR linear + cov., dez/2028             | $\approx 15.456.747$       |
| MLP profunda + cov., dez/2028          | $\approx 15.902.025$       |
| Banda informal em dez/2028             | [ 13.999.098; 16.886.844 ] |

Banda *informal* de  $\pm$ MAPE de backtest (não um IC de 95%), de 1,3% (curto) a 9,4% (dez/2028). Como o backtest cobre um único ano (2025) e a recursão amplifica o erro (equação 17), a banda deve ser lida como aproximação conservadora, não como cobertura calibrada. Fonte: elaboração própria.

#### 14.4 Banda calibrada por predição conforme

A banda informal pode ser substituída por uma com *garantia de cobertura*. Aplicamos *predição conforme* dividida [35]: tomamos os erros relativos de *backtest* de 2025 como escores de nãoconformidade e, para cada horizonte, usamos o quantil empírico  $\lceil (n+1)(1-\alpha) \rceil / n$  como meialargura do intervalo. Sob permutabilidade, o intervalo resultante tem cobertura marginal de pelo menos  $1-\alpha$ . A Figura 21 compara as duas bandas: a conforme (90%) é da mesma ordem de grandeza da informal — 3,4% a 9,2% de meialargura relativa, de 1 a 12 meses —, o que valida a banda informal como aproximação razoável, agora com uma alternativa calibrada disponível para uso orçamentário. A pequena amostra de calibração (12 meses de 2025 por horizonte) torna os quantis conformes granulares, limitação que séries de backtest mais longas reduziriam.



Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

**Figura 21 – Banda conforme vs. informal.** Meialargura relativa do intervalo nacional por horizonte: a predição conforme (90%, com garantia de cobertura) é próxima da banda informal de  $\pm$ MAPE.

## 14.5 Leitura fiscal

A implicação é direta. Pela equação (1), com a carga de casos plana ou declinante, o custo futuro é governado pela *alavanca de política* — o valor do benefício —, não por uma demanda em expansão. A parcela *estrutural* do gasto não cresce; eventuais aumentos de custo serão, sob a hipótese de ausência de novo choque institucional, escolhas discricionárias de benefício. E, porque o agregado nacional é previsível com erro inferior a 4,7% em doze meses (e ainda menor com covariáveis), essa parcela pode ser planejada com folga adequada ao ciclo orçamentário.

Para dimensionar o que esse erro significa em reais: a uma referência recente de benefício médio da ordem de R\$ 700 por família, um erro agregado de 4,7% em doze meses sobre  $\approx 18$  milhões de famílias corresponde a um desvio potencial da ordem de R\$ 0,6 bilhão por mês — cerca de R\$ 7 bilhões ao ano — na parcela estrutural do gasto projetado. É essa escala que torna a precisão da projeção fiscalmente relevante, e que justifica buscar bandas calibradas (Seção 16). O cálculo é ilustrativo: o benefício médio é, ele próprio, a alavanca de política, não uma constante.

## 14.6 Do caseload ao custo: como usar a projeção

A projeção é um insumo, não uma resposta final. A equação (1) sugere o procedimento de uso. Tomada a trajetória central da carga de casos  $\hat{N}_t$  e sua banda  $[\hat{N}_t^{\text{lo}}, \hat{N}_t^{\text{hi}}]$ , o custo projetado em  $t$  é  $\hat{C}_t \approx \hat{N}_t \cdot \bar{b}_t$ , onde  $\bar{b}_t$  é o benefício médio — uma escolha de política. A incerteza do custo decompõe-se, então, em duas fontes *ortogonais*: a incerteza *estrutural* (a banda da carga de casos, que este artigo quantifica em  $<9,4\%$  até 2028) e a incerteza *de política* (o valor

do benefício, que o gestor controla). Separá-las é o ganho prático: o planejador pode tratar a primeira como dado — estreito e previsível — e concentrar a deliberação na segunda, que é onde residem tanto a escolha quanto o grosso da variação possível do gasto. A projeção, portanto, não substitui a decisão orçamentária; ela *delimita* a parte da conta que não está em disputa, tornando explícita a parte que está. É essa delimitação, e não um número único de gasto, o produto de política deste trabalho.

## 15 LIMITAÇÕES

A honestidade do exercício exige enumerar suas fronteiras.

**1. Reversão à média na recursão.** A projeção recursiva de múltiplos anos arrasta as previsões à média histórica de cada município; formulações diretas de múltiplos horizontes, ou estado de espaço com tendência amortecida [18], mitigariam o efeito.

**2. Covariáveis congeladas no futuro.** Na projeção, população e emprego formal são mantidos em 2024. Acoplar projeções demográficas oficiais do IBGE e cenários de emprego refinaria o longo prazo — justamente onde as covariáveis mais importam.

**3. Choques de política exógenos.** Um quarto regime institucional não é previsível do histórico; as previsões são condicionais a “nenhum novo choque”. É limitação intrínseca de modelos sem variáveis de política.

**4. Frequência das covariáveis.** População e RAIS são anuais e publicadas com defasagem; sua granularidade temporal grosseira limita o ganho a curto prazo (Seção 10). Séries mensais de mercado de trabalho (p. ex. CAGED) poderiam estender o benefício a horizontes intermediários.

**5. Cobertura da agregação.** A trajetória nacional soma os municípios com janela final completa e covariáveis ( $\approx 99\%$ ); a exclusão dos 29 municípios sem casamento de código introduz viés de cobertura desprezível, mas não nulo.

## 16 EXTENSÕES

Três extensões decorrem naturalmente.

**Mais covariáveis e maior frequência.** Os fluxos de entrada e saída do Cadastro Único, séries mensais de emprego (CAGED) e indicadores de informalidade dariam ao modelo — sobretudo ao profundo — estrutura não-linear adicional a explorar, possivelmente permitindo à profundidade enfim compensar em horizontes intermediários.

**Previsões probabilísticas calibradas.** A banda atual é o MAPE de backtest, substituto razoável porém não calibrado. Regressão quantílica [34] ou predição conforme [35] produziriam intervalos com cobertura teoricamente garantida — um avanço natural para o uso orçamentário.

**Heterogeneidade espacial.** A relação cobertura–emprego (Figura 3) e a desigualdade entre estados (Figura 5) sugerem que modelos com efeitos regionais, covariáveis espaciais ou agrupamento por perfil municipal poderiam capturar dinâmicas locais que o modelo global,

por construção, média. Um caminho natural é hierarquizar a previsão — reconciliar trajetórias municipais, estaduais e nacional — de modo que a soma das partes seja coerente com o todo, técnica madura na literatura de previsão hierárquica.

**Modelagem explícita de regime.** As três faixas institucionais da Figura 20 são, hoje, tratadas como dadas. Incorporar indicadores de regime, ou variáveis de política (limiares de elegibilidade, valor do benefício), permitiria *condicionar* a previsão a cenários de política — transformando o modelo, de puramente preditivo, em ferramenta de simulação contrafactual para o gestor. Essa é, em última análise, a ponte entre a previsão da demanda estrutural, objeto deste artigo, e a equação de custo (1) que a motiva.

Em conjunto, essas extensões partilham um princípio: cada uma adiciona *estrutura* que o modelo univariado global não contém. O presente artigo mostra que a primeira dose de estrutura externa — demografia e emprego — já paga, e onde paga (horizontes longos). A pergunta aberta é se doses adicionais, de maior frequência e granularidade, deslocam enfim a fronteira a favor da profundidade — ou se a parcimônia continua, como aqui, a usar melhor cada nova informação.

## 17 CONCLUSÕES

Seis conclusões emergem.

**Primeira:** a carga de casos do Bolsa Família *atingiu o pico e consolida-se* — de  $\approx 21,2$  milhões de famílias em janeiro de 2023 para 18,4 milhões em dezembro de 2025, com projeção em torno de 15,4–15,9 milhões para 2028. A demanda estrutural não cresce — sob a hipótese, explicitada nas limitações, de ausência de novo choque institucional ou de elegibilidade.

**Segunda:** o *aprendizado supera a ingênua em horizontes de planejamento* — até 27% de redução de MAE em seis meses, de forma robusta —, mas *não* a um mês, quando a série é quase um passeio aleatório.

**Terceira:** o *modelo do tamanho certo vence*. A autorregressão linear domina o perceptron profundo em todo horizonte, mesmo com covariáveis; a profundidade só ajuda quando regularizada, e ainda assim fica atrás.

**Quarta:** as *covariáveis de demografia e emprego carregam sinal real, cujo valor cresce com o horizonte* — negligíveis ou prejudiciais a 1–3 meses, elevam o modelo linear de +10% para +17% de redução de MAE em 12 meses, tornando-o o melhor preditor de longo prazo.

**Quinta:** as *previsões nacionais são estreitas* — MAPE agregado abaixo de 4,7% em doze meses, e ainda menor com covariáveis —, adequadas ao planejamento orçamentário, graças ao cancelamento de erros na agregação.

**Sexta:** a relação  $\text{emprego} \leftrightarrow \text{PBF}$  é *causal*, não apenas associativa. Um instrumento *shift-share* (Bartik) identifica um efeito 2SLS negativo do emprego formal sobre a cobertura do programa, significativo na janela completa ( $-0,63$ ,  $t = -2,2$ ) e maior que o de MQO — criar emprego formal *retira* famílias da elegibilidade. E, em previsão, a autorregressão global *bate o arsenal clássico* (ETS, SARIMA) em todos os horizontes.

**Sétima:** o *custo fiscal* é uma escolha de política, não uma inevitabilidade conduzida pela carga de casos — o ponto de maior relevância para o debate de sustentabilidade.

### 17.1 Método aberto e o sentido das duas perguntas

Registra-se, por fim, o valor da abordagem do zero: ao implementar cada peça explicitamente em C++17, seguindo Chen e Gupta [7], e ao reconciliar três bases públicas oficiais em um único painel, o experimento permanece integralmente auditável. Não há caixa-preta entre os dados públicos e a conclusão — cada número da Tabela 6 pode ser regenerado, e cada figura, reconstruída, a partir do código e dos artefatos versionados (Seção 4.4).

As duas perguntas metodológicas que organizaram o artigo — *quando a profundidade compensa?* e *quanto valem covariáveis, e em que horizonte?* — têm, à luz da equação (13), a mesma resposta de fundo: o que importa não é a capacidade do modelo nem a quantidade de informação *em abstrato*, mas o casamento entre a estrutura do modelo, a estrutura da informação e a estrutura do problema. A profundidade não compensou porque o sinal é quase log-linear; as covariáveis compensaram apenas no longo prazo porque é lá que a autocorrelação se esgota e a estrutura externa passa a importar. Não há, neste domínio, um almoço grátis: há o ajuste certo entre ferramenta e tarefa. É uma lição modesta, mas é a que os dados públicos brasileiros, aqui examinados com rigor, sustentam — e que vale, plausivelmente, muito além da carga de casos de um único programa social.

## APÊNDICE A – MÉTRICAS COMPLETAS

A Tabela 12 reporta RMSE e  $R^2$  dos cinco modelos nos quatro horizontes, complementando o MAE e o MAPE da Tabela 6. O  $R^2$  permanece acima de 0,985 em toda linha — artefato da enorme variância entre municípios —, reforçando que a métrica informativa é o MAPE. O RMSE, mais sensível a grandes erros, ordena os modelos de forma consistente com o MAE: a autorregressão linear (com ou sem covariáveis) tem o menor RMSE em 3, 6 e 12 meses.

**Tabela 12** – Métricas completas por horizonte e modelo

| <i>H</i> | Modelo              | RMSE (fam.) | $R^2$  |
|----------|---------------------|-------------|--------|
| 1        | Persistência        | 412         | 0,9992 |
|          | AR linear           | 365         | 0,9994 |
|          | MLP profunda        | 379         | 0,9993 |
|          | AR linear + cov.    | 507         | 0,9988 |
|          | MLP profunda + cov. | 395         | 0,9993 |
| 3        | Persistência        | 797         | 0,9970 |
|          | AR linear           | 574         | 0,9984 |
|          | MLP profunda        | 784         | 0,9971 |
|          | AR linear + cov.    | 796         | 0,9970 |
|          | MLP profunda + cov. | 958         | 0,9956 |
| 6        | Persistência        | 1.313       | 0,9917 |
|          | AR linear           | 805         | 0,9969 |
|          | MLP profunda        | 1.300       | 0,9919 |
|          | AR linear + cov.    | 805         | 0,9969 |
|          | MLP profunda + cov. | 1.302       | 0,9919 |
| 12       | Persistência        | 1.684       | 0,9864 |
|          | AR linear           | 1.171       | 0,9934 |
|          | MLP profunda        | 1.538       | 0,9887 |
|          | AR linear + cov.    | 1.183       | 0,9933 |
|          | MLP profunda + cov. | 1.642       | 0,9871 |

Fonte: elaboração própria.

## APÊNDICE B – COMPARAÇÕES PAREADAS COMPLETAS

A Tabela 13 reporta todas as seis comparações pareadas de interesse nos quatro horizontes: cada modelo aprendido contra a persistência e entre si, e os dois testes de covariável. Todos os valores- $p$  de Wilcoxon são inferiores a  $10^{-4}$  (em geral  $< 10^{-30}$ ); dado  $n \approx 66.504$ , a leitura relevante está no intervalo de confiança (estritamente positivo  $\Rightarrow$  vantagem robusta) e na taxa de vitória.

**Tabela 13** – Comparações pareadas completas ( $\Delta\text{MAE} > 0$  favorece o primeiro modelo)

| <i>H</i> | Comparação               | $\Delta\text{MAE}$ | IC 95%         | Vit. (%) |
|----------|--------------------------|--------------------|----------------|----------|
| 1        | AR linear vs persist.    | -2,9               | [-4,7; -1,2]   | 48,3     |
|          | MLP prof. vs persist.    | -0,3               | [-1,8; +1,1]   | 49,5     |
|          | AR linear vs MLP prof.   | -2,6               | [-4,1; -1,1]   | 48,0     |
|          | AR lin.+cov vs AR linear | -2,8               | [-5,4; -0,3]   | 51,1     |
|          | MLP+cov vs MLP prof.     | -0,5               | [-1,6; +0,5]   | 52,1     |
|          | MLP+cov vs AR linear     | +2,1               | [+0,5; +3,5]   | 53,0     |
| 3        | AR linear vs persist.    | +20,2              | [+17,6; +22,7] | 58,5     |
|          | MLP prof. vs persist.    | +0,8               | [-1,6; +3,2]   | 53,1     |
|          | AR linear vs MLP prof.   | +19,4              | [+16,8; +22,0] | 56,1     |
|          | AR lin.+cov vs AR linear | -9,8               | [-12,4; -7,2]  | 52,9     |
|          | MLP+cov vs MLP prof.     | -7,7               | [-10,4; -5,2]  | 50,6     |
|          | MLP+cov vs AR linear     | -27,1              | [-31,6; -23,2] | 44,1     |
| 6        | AR linear vs persist.    | +56,0              | [+49,7; +62,4] | 64,2     |
|          | MLP prof. vs persist.    | +4,3               | [+0,5; +8,0]   | 56,4     |
|          | AR linear vs MLP prof.   | +51,7              | [+46,5; +57,3] | 61,5     |
|          | AR lin.+cov vs AR linear | -0,8               | [-2,1; +0,5]   | 53,2     |
|          | MLP+cov vs MLP prof.     | +12,7              | [+8,4; +16,7]  | 59,2     |
|          | MLP+cov vs AR linear     | -39,0              | [-44,7; -33,6] | 41,4     |
| 12       | AR linear vs persist.    | +25,7              | [+14,2; +37,9] | 56,9     |
|          | MLP prof. vs persist.    | -28,3              | [-36,7; -19,6] | 56,3     |
|          | AR linear vs MLP prof.   | +54,1              | [+47,7; +61,3] | 57,9     |
|          | AR lin.+cov vs AR linear | +19,8              | [+12,1; +27,5] | 54,5     |
|          | MLP+cov vs MLP prof.     | -1,5               | [-5,9; +3,1]   | 54,6     |
|          | MLP+cov vs AR linear     | -55,6              | [-64,1; -47,6] | 45,5     |

IC por bootstrap pareado (2.000 reamostragens). Fonte: elaboração própria.

## REFERÊNCIAS

- [1] BRASIL. **Lei n.º 10.836, de 9 de janeiro de 2004**. Cria o Programa Bolsa Família. Diário Oficial da União, Brasília, 2004. Disponível em: [https://www.planalto.gov.br/ccivil\\_03/\\_ato2004-2006/2004/lei/l10.836.htm](https://www.planalto.gov.br/ccivil_03/_ato2004-2006/2004/lei/l10.836.htm). Acesso em: 22 jun. 2026.
- [2] BRASIL. **Lei n.º 14.284, de 29 de dezembro de 2021**. Institui o Programa Auxílio Brasil. Diário Oficial da União, Brasília, 2021. Disponível em: [https://www.planalto.gov.br/ccivil\\_03/\\_ato2019-2022/2021/lei/l14284.htm](https://www.planalto.gov.br/ccivil_03/_ato2019-2022/2021/lei/l14284.htm). Acesso em: 22 jun. 2026.
- [3] BRASIL. **Lei n.º 14.601, de 19 de junho de 2023**. Institui o Programa Bolsa Família. Diário Oficial da União, Brasília, 2023. Disponível em: [https://www.planalto.gov.br/ccivil\\_03/\\_ato2023-2026/2023/lei/l14601.htm](https://www.planalto.gov.br/ccivil_03/_ato2023-2026/2023/lei/l14601.htm). Acesso em: 22 jun. 2026.
- [4] CONTROLADORIA-GERAL DA UNIÃO (CGU). **Portal da Transparência do Governo Federal: Bolsa Família e Auxílio Brasil**. Brasília: CGU. Disponível em: <https://portaldatransparencia.gov.br/beneficios/bolsa-familia>. Acesso em: 22 jun. 2026.
- [5] INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). **Estimativas da população residente para os municípios e para as unidades da federação**. Rio de Janeiro: IBGE. Disponível em: <https://www.ibge.gov.br/estatisticas/sociais/populacao/9103-estimativas-de-populacao.html>. Acesso em: 22 jun. 2026.
- [6] BRASIL. Ministério do Trabalho e Emprego (MTE). **Relação Anual de Informações Sociais (RAIS)**. Programa de Disseminação das Estatísticas do Trabalho (PDET). Brasília: MTE. Disponível em: <https://www.gov.br/trabalho-e-emprego/pt-br/assuntos/estatisticas-trabalho/rais>. Acesso em: 22 jun. 2026.
- [7] CHEN, Bill; GUPTA, Vikash. **Deep Learning with C++: Design and deploy neural networks using CUDA for high-performance AI in C++**. Birmingham: Packt Publishing, 2026. ISBN 978-1-83588-002-9.
- [8] GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. **Deep Learning**. Cambridge, MA: MIT Press, 2016. Disponível em: <https://www.deeplearningbook.org>. Acesso em: 22 jun. 2026.
- [9] LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. Deep learning. **Nature**, v. 521, p. 436–444, 2015. DOI: 10.1038/nature14539.
- [10] RUMELHART, David E.; HINTON, Geoffrey E.; WILLIAMS, Ronald J. Learning representations by back-propagating errors. **Nature**, v. 323, p. 533–536, 1986. DOI: 10.1038/323533a0.
- [11] CYBENKO, George. Approximation by superpositions of a sigmoidal function. **Mathematics of Control, Signals and Systems**, v. 2, n. 4, p. 303–314, 1989. DOI: 10.1007/BF02551274.
- [12] HORNIK, Kurt; STINCHCOMBE, Maxwell; WHITE, Halbert. Multilayer feedforward networks are universal approximators. **Neural Networks**, v. 2, n. 5, p. 359–366, 1989. DOI: 10.1016/0893-6080(89)90020-8.
- [13] HE, Kaiming; ZHANG, Xiangyu; REN, Shaoqing; SUN, Jian. Delving deep into rectifiers: surpassing human-level performance on ImageNet classification. In: **IEEE International Conference on Computer Vision (ICCV)**, 2015. arXiv:1502.01852.
- [14] GLOROT, Xavier; BENGIO, Yoshua. Understanding the difficulty of training deep feed-forward neural networks. In: **AISTATS**, 2010. v. 9, p. 249–256.
- [15] KINGMA, Diederik P.; BA, Jimmy. Adam: a method for stochastic optimization. In: **International Conference on Learning Representations (ICLR)**, 2015. arXiv:1412.6980.



- [16] LOSHCHILOV, Ilya; HUTTER, Frank. Decoupled weight decay regularization. In: **ICLR**, 2019. arXiv:1711.05101.
- [17] BOX, George E. P.; JENKINS, Gwilym M. **Time Series Analysis: Forecasting and Control**. San Francisco: Holden-Day, 1970.
- [18] HYNDMAN, Rob J.; ATHANASOPOULOS, George. **Forecasting: Principles and Practice**. 3. ed. Melbourne: OTexts, 2021. Disponível em: <https://otexts.com/fpp3/>. Acesso em: 22 jun. 2026.
- [19] HYNDMAN, Rob J.; KOEHLER, Anne B. Another look at measures of forecast accuracy. **International Journal of Forecasting**, v. 22, n. 4, p. 679–688, 2006. DOI: 10.1016/j.ijforecast.2006.03.001.
- [20] BERGMEIR, Christoph; BENÍTEZ, José M. On the use of cross-validation for time series predictor evaluation. **Information Sciences**, v. 191, p. 192–213, 2012. DOI: 10.1016/j.ins.2011.12.028.
- [21] MAKRIDAKIS, Spyros; SPILIOTIS, Evangelos; ASSIMAKOPOULOS, Vassilios. The M4 Competition: 100,000 time series and 61 forecasting methods. **International Journal of Forecasting**, v. 36, n. 1, p. 54–74, 2020. DOI: 10.1016/j.ijforecast.2019.04.014.
- [22] HEWAMALAGE, Hansika; BERGMEIR, Christoph; BANDARA, Kasun. Global models for time series forecasting: a simulation study. **Pattern Recognition**, v. 124, 108441, 2022. DOI: 10.1016/j.patcog.2021.108441.
- [23] SMYL, Slawek. A hybrid method of exponential smoothing and recurrent neural networks for time series forecasting. **International Journal of Forecasting**, v. 36, n. 1, p. 75–85, 2020. DOI: 10.1016/j.ijforecast.2019.03.017.
- [24] SALINAS, David; FLUNKERT, Valentin; GASTHAUS, Jan; JANUSCHOWSKI, Tim. DeepAR: probabilistic forecasting with autoregressive recurrent networks. **International Journal of Forecasting**, v. 36, n. 3, p. 1181–1191, 2020. DOI: 10.1016/j.ijforecast.2019.07.001.
- [25] LIM, Bryan; ZOHREN, Stefan. Time-series forecasting with deep learning: a survey. **Philosophical Transactions of the Royal Society A**, v. 379, n. 2194, 20200209, 2021. DOI: 10.1098/rsta.2020.0209.
- [26] DAMA INTERNATIONAL. **DAMA-DMBOK: Data Management Body of Knowledge**. 2. ed. Basking Ridge: Technics Publications, 2017. ISBN 978-1-63462-234-9.
- [27] ZAHARIA, Matei; XIN, Reynold S.; WENDELL, Patrick *et al.* Apache Spark: a unified engine for big data processing. **Communications of the ACM**, v. 59, n. 11, p. 56–65, 2016. DOI: 10.1145/2934664.
- [28] ARMBRUST, Michael; DAS, Tathagata; SUN, Liwen *et al.* Delta Lake: high-performance ACID table storage over cloud object stores. **Proceedings of the VLDB Endowment**, v. 13, n. 12, p. 3411–3424, 2020. DOI: 10.14778/3415478.3415560.
- [29] DATABRICKS. **Databricks Free Edition**. San Francisco: Databricks, 2025. Disponível em: <https://www.databricks.com/learn/free-edition>. Acesso em: 22 jun. 2026.
- [30] DATABRICKS. **What is the medallion lakehouse architecture?** Documentação técnica. San Francisco: Databricks. Disponível em: <https://www.databricks.com/glossary/medallion-architecture>. Acesso em: 22 jun. 2026.
- [31] DIEBOLD, Francis X.; MARIANO, Roberto S. Comparing predictive accuracy. **Journal of Business & Economic Statistics**, v. 13, n. 3, p. 253–263, 1995. DOI: 10.1080/07350015.1995.10
- [32] WILCOXON, Frank. Individual comparisons by ranking methods. **Biometrics Bulletin**, v. 1, n. 6, p. 80–83, 1945. DOI: 10.2307/3001968.

- [33] EFRON, Bradley. Bootstrap methods: another look at the jackknife. **The Annals of Statistics**, v. 7, n. 1, p. 1–26, 1979. DOI: 10.1214/aos/1176344552.
- [34] KOENKER, Roger; BASSETT, Gilbert. Regression quantiles. **Econometrica**, v. 46, n. 1, p. 33–50, 1978. DOI: 10.2307/1913643.
- [35] SHAFER, Glenn; VOVK, Vladimir. A tutorial on conformal prediction. **Journal of Machine Learning Research**, v. 9, p. 371–421, 2008.
- [36] BARTIK, Timothy J. **Who Benefits from State and Local Economic Development Policies?** Kalamazoo: W. E. Upjohn Institute for Employment Research, 1991. DOI: 10.17848/9780585223940.
- [37] GOLDSMITH-PINKHAM, Paul; SORKIN, Isaac; SWIFT, Henry. Bartik instruments: what, when, why, and how. **American Economic Review**, v. 110, n. 8, p. 2586–2624, 2020. DOI: 10.1257/aer.20181047.
- [38] BORUSYAK, Kirill; HULL, Peter; JARAVEL, Xavier. Quasi-experimental shift-share research designs. **The Review of Economic Studies**, v. 89, n. 1, p. 181–213, 2022. DOI: 10.1093/restud/rdab030.