

PREVISÃO DA CARGA DE CASOS DO PROGRAMA BOLSA FAMÍLIA

Redes neurais construídas do zero, covariáveis de demografia e emprego, um benchmark fora do tempo e uma projeção até 2028

Leonardo Chalhoub • Alexandre Maciel Rolim
Luis Fernando Kranz • Jefferson Korte

Todos os autores atuam como **pesquisadores independentes**, Brasil.

Leonardo Chalhoub — Expert Data Engineer; Mestre em Administração (Finanças), UFRGS; graduando em Engenharia de Software, Universidade Estácio de Sá. Rio de Janeiro, RJ. ORCID: 0000-0003-0484-158X.

Alexandre Maciel Rolim — Tecnólogo em Radiologia; Mestre em Proteção Radiológica, IFSC. Florianópolis, SC. ORCID: 0009-0000-3983-4713.

Luis Fernando Kranz — Tecnólogo em Radiologia; Mestre em Administração, UFRGS. Porto Alegre, RS. ORCID: 0009-0009-6015-3141.

Jefferson Korte — Estudante de Ciência da Computação, UTFPR. Curitiba, PR. ORCID: 0009-0006-9466-9830.

Correspondência: Leonardo Chalhoub • leochalhoub@hotmail.com

Quantos núcleos familiares o maior programa de transferência condicionada de renda da América Latina atenderá nos próximos anos, e o que governa essa demanda? Tratamos a carga de casos (o número de famílias beneficiárias) como uma série temporal em painel e a prevemos com redes neurais implementadas inteiramente do zero em C++17. Sobre 5.542 municípios e 156 meses (2013–2025), comparamos modelos univariados (apenas o próprio histórico) a modelos multivariados alimentados por covariáveis anuais de população (IBGE) e de emprego formal (RAIS), sob avaliação rigorosa fora do tempo, e projetamos a trajetória nacional até dezembro de 2028. Dois achados organizam o artigo: a profundidade só compensa quando a estrutura do sinal a recompensa; e as covariáveis de demografia e mercado de trabalho carregam sinal real, cujo valor cresce com o horizonte de previsão.

RESUMO

Este artigo formula a previsão da carga de casos do Programa Bolsa Família — o número de famílias beneficiárias — como um problema de previsão de séries temporais em painel e o resolve com redes neurais construídas inteiramente do zero em C++17, sem bibliotecas de aprendizado profundo. A partir de uma camada bruta de 2.533.885.299 pagamentos do Portal da Transparência da Controladoria-Geral da União (CGU), mineramos um painel município $\times$ mês com 5.542 municípios e 156 meses (2013–2025) e o enriquecemos com duas covariáveis anuais — população residente (IBGE) e emprego formal ativo (RAIS/PDET) —, reconciliadas ao código municipal do painel por um *crosswalk* com 99,5% de cobertura. Treinamos um único modelo global e o avaliamos sob protocolo honesto: padronização com meses de treino apenas (sem vazamento), covariáveis defasadas (sem peeking), partição *fora do tempo* (alvos anteriores a janeiro de 2025 treinam; janeiro a dezembro de 2025 testam, ≈ 66.504 previsões por horizonte) e linha de base ingênua forte (persistência). Comparamos cinco modelos — persistência, autorregressão linear, perceptron multicamadas profundo ($14 \rightarrow 64 \rightarrow 32 \rightarrow 1$) e as versões *com covariáveis* de ambos ($16 \rightarrow \dots$) — em quatro horizontes ($H \in \{1, 3, 6, 12\}$ meses) com MAE, MAPE, RMSE e R^2 , e inferimos significância por bootstrap pareado, teste de Wilcoxon e taxa de vitória. Achados: (i) a um mês a carga de casos é quase um passeio aleatório e nenhum modelo aprendido supera a persistência; (ii) em horizontes de planejamento (6 meses) a autorregressão reduz o MAE em 27% sobre a ingênua, com vantagem grande e robusta; (iii) a profundidade é *dominada* pela autorregressão em todo horizonte, mesmo com covariáveis; (iv) as covariáveis de demografia e emprego carregam sinal real cujo valor *cresce com o horizonte*: irrelevantes ou prejudiciais a curto prazo, elevam o modelo linear em 12 meses de +10% para +17% de redução de MAE, tornando o modelo linear com covariáveis o melhor preditor de longo prazo; (v) a projeção nacional indica que a carga de casos atingiu o pico em 2022–2023 e recua, com erro agregado de backtest inferior a 4,7% em 12 meses. Documentamos ainda uma forte relação estrutural entre cobertura do programa e intensidade de emprego formal nos municípios (correlação log-log de $-0,66$ em 2024). Conclui-se que a demanda estrutural é plana ou declinante e que o custo futuro é governado pelo *valor* do benefício — uma escolha de política —, não por uma carga de casos em expansão.

Palavras-chave: previsão de séries temporais; redes neurais artificiais; perceptron multicamadas; covariáveis exógenas; Programa Bolsa Família; emprego formal; RAIS; demografia; avaliação fora do tempo; C++.

ABSTRACT

This paper frames forecasting the Bolsa Família caseload — the number of beneficiary families — as a panel time-series problem and solves it with neural networks built entirely from scratch in C++17. From a bronze layer of 2.533.885.299 payment records (CGU), we mine a municipality $\times$ month panel of 5.542 municipalities and 156 months (2013–2025) and enrich it with two

annual covariates — resident population (IBGE) and active formal employment (RAIS) — reconciled to the panel’s municipal code by a crosswalk covering 99.5% of municipalities. A single global model is trained and evaluated honestly: leakage-free standardisation, lagged covariates, an out-of-time split (targets before January 2025 train; January to December 2025 test, $\approx 66,504$ forecasts per horizon), and a strong naive baseline. We compare five models — persistence, a linear autoregression, a deep MLP, and the covariate-augmented versions of both — across four horizons, with significance from paired bootstrap, Wilcoxon tests and win rates. We find that at one month no learned model beats persistence; at planning horizons the linear autoregression cuts MAE by 27% over naive; depth is dominated by the linear model everywhere, even with covariates; and the covariates carry real signal whose value grows with the horizon — negligible or harmful in the short run, they lift the 12-month linear model from +10% to +17% MAE reduction. The national projection shows the caseload peaked in 2022–2023 and is declining, with aggregate backtest error below 4.7% at twelve months. We also document a strong structural relationship between program coverage and formal-employment intensity across municipalities (log-log correlation -0.66 in 2024). We conclude that structural demand is flat-to-falling, so future cost is governed by the benefit level — a policy choice.

Keywords: time-series forecasting; artificial neural networks; multilayer perceptron; exogenous covariates; Bolsa Família; formal employment; out-of-time evaluation; C++.

Sumário

1	Introdução	5
1.1	Contribuições	5
1.2	Organização	6
2	O programa e a carga de casos	6
3	Dados	7
3.1	Três fontes	7
3.2	Reconciliação de códigos municipais	7
3.3	Panorama descritivo	8
3.4	Qualidade e limitações dos dados	13
4	Materiais e métodos: pipeline de dados e reprodutibilidade	13
4.1	Arquitetura medallion	13
4.2	A escala da camada bruta	14
4.3	Governança de dados	14
4.4	Fontes abertas e reprodutibilidade	15
5	Fundamentos	15
5.1	Previsão e a tirania da linha de base ingênua	15
5.2	Medidas de erro e validação temporal	16
5.3	Redes neurais como aproximadores de funções	16
5.4	Por que covariáveis exógenas?	16
5.5	Modelos globais e aprendizado profundo para previsão	17
6	Tarefa de previsão e protocolo de avaliação	17
6.1	Definição formal	17
6.2	Engenharia de atributos univariados	17
6.3	Covariáveis e sua defasagem causal	18
6.4	Modelo global único	18
6.5	Protocolo de avaliação honesto	18
6.6	Decisões de desenho	18
7	Modelos	19
7.1	Persistência	19
7.2	Autorregressão linear, perceptron profundo e suas versões com covariáveis	19
7.3	Inicialização sensível à variância	20
7.4	Perda e retropropagação	20
7.5	Otimizador: AdamW	21

7.6	Parada antecipada	21
7.7	Algoritmo de treino	22
7.8	Um passo de treino, em números	22
7.9	Complexidade e número de parâmetros	22
7.10	Implementação do zero em C++17	23
8	Métricas e inferência	23
8.1	Métricas de erro	23
8.2	Comparação pareada de modelos	23
9	Resultados: acurácia fora do tempo	24
10	O efeito das covariáveis	26
11	Significância estatística	27
11.1	Síntese e robustez	30
12	Interpretação: quando ajudam a profundidade e as covariáveis?	30
12.1	Por que a profundidade não paga	30
12.2	Uma leitura formal: viés, variância e horizonte	31
12.3	Por que o valor das covariáveis cresce com o horizonte	31
13	Projeção 2026–2028	31
13.1	Procedimento e o porquê de o agregado ser mais fácil	31
13.2	Propagação de erro na recursão	32
13.3	Resultados da projeção	33
13.4	Leitura fiscal	34
13.5	Do caseload ao custo: como usar a projeção	34
14	Limitações	34
15	Extensões	35
16	Conclusões	36
16.1	Método aberto e o sentido das duas perguntas	36
	Apêndice A – Métricas completas	37
	Apêndice B – Comparações pareadas completas	38
	Referências	39

1 INTRODUÇÃO

A pergunta que este artigo responde é operacional e mensurável: *dado o histórico do maior programa de transferência condicionada de renda da América Latina, qual é a projeção mais defensável do número de famílias beneficiárias nos próximos anos, com que acurácia tal previsão pode ser feita, e que informação — o próprio passado da série, a demografia, o mercado de trabalho — de fato a melhora?* A resposta tem implicação direta de política pública, porque o custo total de um programa de transferência de renda é, em primeira aproximação, o produto de duas grandezas:

$$\text{custo} \approx \underbrace{\text{carga de casos}}_{\text{demanda estrutural}} \times \underbrace{\text{benefício médio}}_{\text{alavanca de política}}. \quad (1)$$

O valor do benefício é uma *escolha* discricionária do gestor; a carga de casos — *caseload*, o número de núcleos familiares na folha de pagamento — é demanda estrutural, governada por dinâmicas demográficas, de mercado de trabalho e de elegibilidade que nenhum decreto altera no curto prazo. Uma previsão crível da carga de casos isola a parcela do gasto futuro que *não* é decisão discricionária. É essa parcela que tratamos aqui.

A escolha de objeto não é trivial. Diferentemente do gasto nominal — que exige deflação e mistura mudanças de preço e de quantidade —, a contagem de famílias é uma grandeza física, robusta a regimes institucionais e que não requer correção monetária. É a base limpa sobre a qual qualquer projeção de custo deve ser erguida. E, por ser uma série genuína — com tendência, sazonalidade e forte autocorrelação —, é também um banco de provas ideal para duas perguntas metodológicas de interesse independente: *quando a profundidade compensa?* e *quanto valem covariáveis exógenas de contexto, e em que horizonte?*

1.1 Contribuições

Este trabalho oferece cinco contribuições.

Primeira, empírica. Construímos, de uma camada bruta de 2.533.885.299 registros, um painel município $\times$ mês de 5.542 municípios e 156 meses (2013–2025) e produzimos com ele uma projeção da carga de casos até dezembro de 2028 cuja incerteza é quantificada por reamostragem fora do tempo, e não assumida.

Segunda, de integração de dados. Enriquecemos o painel com duas covariáveis municipais anuais — população (IBGE) e emprego formal ativo (RAIS/PDET) —, reconciliando três sistemas de codificação municipal distintos (SIAFI, IBGE de 7 e de 6 dígitos) por um *crosstalk* de 99,5% de cobertura, e descrevemos a relação estrutural entre cobertura do programa e mercado de trabalho.

Terceira, metodológica. Implementamos as redes *do zero* em C++17 — inicialização de He, ReLU, retropropagação manual, AdamW — sem qualquer biblioteca de aprendizado profundo, seguindo o roteiro de CHEN e GUPTA [7]. Cada operação aritmética é auditável.

Quarta, inferencial. Submetemos toda comparação a protocolo *honesto*: padronização

sem vazamento, covariáveis defasadas, partição estritamente fora do tempo, e significância por bootstrap, Wilcoxon e taxa de vitória município a município, reconhecendo que, com $n \approx 66.504$ por horizonte, um valor- p isolado é desinformativo.

Quinta, conceitual. Documentamos dois fatos: a *autorregressão linear domina a rede profunda* em todo horizonte, mesmo alimentada com covariáveis; e as covariáveis carregam sinal *cujo valor cresce com o horizonte* — negligível a um mês, decisivo a doze. O modelo do tamanho certo, com a informação certa, generaliza melhor que o modelo de maior capacidade.

1.2 Organização

A Seção 2 situa o programa e a carga de casos. A Seção 3 descreve as três fontes de dados, o *crosswalk* municipal e um panorama descritivo das relações entre caseload, população e emprego. A Seção 4 apresenta os materiais e métodos de engenharia de dados — o pipeline, a governança e a reprodutibilidade. A Seção 5 revisa os fundamentos de previsão e de redes neurais. A Seção 6 formaliza a tarefa e o protocolo. A Seção 7 deriva os cinco modelos, com toda a matemática. A Seção 8 define métricas e inferência. As Seções 9 a 11 apresentam a acurácia, o efeito das covariáveis e sua significância. A Seção 12 interpreta *quando* a profundidade e as covariáveis ajudam. A Seção 13 traz a projeção 2026–2028. As Seções 14 a 16 discutem limitações, extensões e conclusões.

2 O PROGRAMA E A CARGA DE CASOS

O Programa Bolsa Família foi instituído pela Lei n.º 10.836, de 9 de janeiro de 2004 [1], unificando programas de transferência de renda anteriores em uma transferência condicionada à frequência escolar e ao acompanhamento de saúde. Entre 2021 e 2023 passou por duas reconfigurações: foi substituído pelo Auxílio Brasil (Medida Provisória n.º 1.061/2021, convertida na Lei n.º 14.284, de 29 de dezembro de 2021 [2]) e retornou como Bolsa Família (Medida Provisória n.º 1.164/2023, convertida na Lei n.º 14.601, de 19 de junho de 2023 [3]). Essas transições alteraram regras e nomenclatura, mas a grandeza que rastreamos — o número de famílias na folha mês a mês — permanece comparável por ser contagem física, não valor monetário. A Figura 17 exhibe as três faixas institucionais sobre a série completa.

A *carga de casos* é a contagem de núcleos familiares distintos que recebem ao menos uma parcela em um mês de competência — uma medida de *demanda atendida*, que combina demanda potencial, capacidade administrativa de cadastro e política de revisão de elegibilidade. Sua dinâmica responde a forças lentas — transições no mercado de trabalho, fluxos do Cadastro Único, recadastramentos — e a choques institucionais discretos. Essa combinação de inércia forte com saltos ocasionais torna a série ao mesmo tempo previsível em horizontes curtos e vulnerável a rupturas que nenhum modelo univariado pode antecipar (Seção 14).

A leitura econômica da equação (1) orienta o artigo: se a carga de casos for plana ou declinante, a trajetória do custo é governada pela alavanca de política, não pela demanda. Esta-

belecer empiricamente em que regime a série se encontra — crescimento, platô ou recuo — é insumo direto para o planejamento orçamentário.

3 DADOS

3.1 Três fontes

O estudo cruza três bases públicas oficiais (Tabela 1). A primeira é a camada bruta de pagamentos do Bolsa Família do Portal da Transparência da CGU [4], com grão de pagamento $\times$ mês e 2.533.885.299 registros, da qual mineramos a carga de casos municipal,

$$f_{c,t} = |\{ \text{NIS favorecidos distintos em } (c, t) \}|, \quad (2)$$

para cada município c e mês t . A segunda é a estimativa anual de população residente por município do IBGE [5]. A terceira é a Relação Anual de Informações Sociais (RAIS), do Programa de Disseminação das Estatísticas do Trabalho (PDET/MTE) [6] — uma base de 2.060.910.061 vínculos formais (1985–2024) —, de onde extraímos o estoque municipal de vínculos ativos por ano.

Tabela 1 – Fontes, grão e cobertura

Fonte	Conteúdo	Grão	Registros
CGU – Portal da Transparência	pagamentos PBF	pagamento $\times$ mês	2.533.885.299
↪ painel derivado	carga de casos	município $\times$ mês	848.526
RAIS – PDET/MTE	vínculos formais	vínculo $\times$ ano	2.060.910.061
↪ painel derivado	emprego formal/ano	município $\times$ ano	83.537
IBGE	população residente	município $\times$ ano	66.840

Fontes oficiais. Camadas brutas: pagamentos PBF (2.533.885.299) e vínculos RAIS (2.060.910.061, 1985–2024) somam $\approx$ 4,6 bilhões de linhas. O painel PBF cobre 156 meses (2013–2025); as covariáveis usadas, 2010–2024.

3.2 Reconciliação de códigos municipais

As três fontes usam codificações municipais distintas: o painel da CGU identifica municípios pelo código SIAFI de 4–6 dígitos; o IBGE, pelo código de 7 dígitos; a RAIS, pelo código de 6 dígitos (IBGE sem o dígito verificador). Construímos um *crosswalk* SIAFI $\rightarrow$ IBGE por correspondência de (*UF, nome do município normalizado*) — removendo acentuação, caixa e pontuação —, e ligamos o código de 6 dígitos da RAIS truncando o de 7 do IBGE. A correspondência cobre 5.542 de 5.571 municípios (99,5%); os 29 sem casamento — em geral grafias divergentes — são excluídos da amostra multivariada. Para que os modelos univariado e multivariado sejam comparados sobre exatamente os mesmos exemplos, *toda* a análise restringe-se aos municípios com covariáveis disponíveis.

3.3 Panorama descritivo

Antes de modelar, vale ver o que os dados dizem. A Figura 1 indexa as três séries nacionais a 2013: a carga de casos oscila com a política (salta na pandemia, recua na revisão dos cadastros), enquanto população e, sobretudo, emprego formal seguem trajetórias mais suaves e ascendentes. A Figura 2 converte isso em uma *taxa de cobertura* nacional (famílias por 100 habitantes), que subiu, atingiu o pico e recua — o mesmo padrão da carga absoluta, agora normalizado pela demografia.




Figura 1 – Contexto nacional indexado (2013 = 100). A carga de casos é volátil e ligada à política; população e emprego formal crescem de forma mais suave. As três séries não se movem em sincronia — condição para que as covariáveis acrescentem informação.




Figura 2 – Taxa de cobertura nacional. Famílias beneficiárias por 100 habitantes; o pico e o recuo recente persistem após normalizar pela população, indicando que o movimento não é mero efeito demográfico.

A relação mais informativa, porém, é municipal e estrutural. A Figura 3 cruza, para os 5.542 municípios em 2024, a cobertura do programa (famílias por habitante) com a intensidade de emprego formal (vínculos RAIS por habitante). A relação é nitidamente negativa — correlação log-log de $-0,66$ — e a mediana por decil decresce de forma monótona: onde há mais emprego formal *per capita*, há menos dependência do Bolsa Família. É a assinatura empírica do programa como rede de proteção contracíclica, e a razão teórica para esperar que o emprego formal ajude a prever a carga de casos. A Figura 4 mostra o mesmo par em níveis absolutos (escala log-log): caseload e emprego crescem juntos em escala — ambos refletem o tamanho do município —, mas a maioria dos pontos fica acima da paridade, isto é, há mais famílias no PBF do que vínculos formais em muitos municípios pequenos.




Figura 3 – Cobertura do PBF vs. intensidade de emprego formal, municípios em 2024. Relação negativa e monótona (mediana por decil em vermelho); correlação log-log de $-0,66$. Mais emprego formal por habitante associa-se a menor cobertura do programa.




Figura 4 – Carga de casos vs. emprego formal, municípios em 2024 (log-log). As grandezas escalam juntas com o tamanho do município; a linha pontilhada é a paridade 1:1.

A Tabela 2 consolida as três séries em números anuais. Dois fatos saltam. Primeiro, o salto da carga de casos em 2022 — de ≈ 14 para ≈ 21 milhões de famílias —, coincidente com a expansão do Auxílio Brasil. Segundo, a descontinuidade demográfica de 2022, ano do Censo, que revisou a população nacional para baixo; por isso a taxa de cobertura de 2022 combina o salto do numerador com a correção do denominador. O emprego formal, por sua vez, cresce de forma quase monótona, de 48,9 para 57,7 milhões de vínculos (2013–2024).

Tabela 2 – Séries nacionais anuais (2013–2024)

Ano	Famílias (mi)	População (mi)	Vínculos (mi)	Cobertura (fam./100 hab.)	Emprego (vínc./100 hab.)
2013	14,04	200,6	48,9	7,0	24,4
2014	13,95	202,4	49,5	6,9	24,5
2015	13,89	204,0	48,0	6,8	23,5
2016	13,52	205,7	46,0	6,6	22,4
2017	13,78	207,2	46,2	6,6	22,3
2018	14,09	208,1	46,6	6,8	22,4
2019	13,13	209,7	46,7	6,3	22,3
2020	14,23	211,3	46,2	6,7	21,9
2021	14,14	212,9	48,7	6,6	22,9
2022	20,92	202,7	52,7	10,3	26,0
2023	20,74	207,4	55,8	10,0	26,9
2024	20,51	212,1	57,7	9,7	27,2

Famílias: média mensal da carga de casos. População: IBGE (2022 é ano de Censo). Vínculos: RAIS, estoque ativo. Fonte: elaboração própria sobre CGU, IBGE e RAIS.

A desigualdade espacial é igualmente marcante. A Figura 5 ordena os estados pela cobertura em 2024: do Piauí e Maranhão (17,5 famílias por 100 habitantes) a Santa Catarina (2,8) — um gradiente de mais de seis vezes que reproduz o mapa da pobreza brasileira. E a relação não é apenas estática: a Figura 6 mostra que, entre 2019 e 2024, os municípios onde o emprego formal mais cresceu foram os que menos viram a carga de casos subir, confirmando em variação a relação que a Figura 3 mostra em nível.

A cobertura do PBF é muito desigual entre estados

Famílias beneficiárias por 100 habitantes, por UF, 2024




Figura 5 – Cobertura do PBF por UF, 2024. Famílias beneficiárias por 100 habitantes; em verde, acima da média nacional. O gradiente Norte/Nordeste vs. Sul/Sudeste reproduz a geografia da pobreza.

Onde o emprego formal mais cresceu, o caseload cresceu menos

Varição municipal de 2019 a 2024 (escala log); relação negativa




Figura 6 – Variação de caseload vs. emprego, 2019–2024. Municípios onde o emprego formal cresceu mais tiveram menor crescimento da carga de casos — a relação inversa também vale em dinâmica.

Três propriedades dos dados condicionam o método e reaparecem na interpretação: (i) a contagem de famílias é regime-robusta e não requer deflação; (ii) há heterogeneidade extrema

entre municípios — as cargas variam de centenas a milhões —, com consequência direta sobre a métrica (Seção 8); e (iii) a série é fortemente autocorrelacionada e aproximadamente log-linear por trechos, ao passo que as covariáveis variam devagar (anualmente) — o que, antecipamos, faz seu valor preditivo emergir só em horizontes longos.

3.4 Qualidade e limitações dos dados

Três cautelas acompanham a integração. *Primeira*, a defasagem de publicação: a RAIS de um ano é divulgada no ano seguinte, e as estimativas populacionais são revisadas periodicamente; nosso uso de covariáveis defasadas (equação 5) respeita essa disponibilidade. *Segunda*, a descontinuidade do Censo de 2022, que reduziu a população nacional estimada de 212,9 milhões (2021) para 202,7 milhões (2022) — um degrau visível na Tabela 2 que afeta a *taxa* de cobertura, mas não a contagem de famílias, nosso alvo. *Terceira*, o resíduo do *crosswalk*: 29 municípios (0,5%) não casam por divergência de grafia e são excluídos da amostra multivariada; como o painel univariado é restrito ao mesmo conjunto, a comparação permanece justa, ao custo de uma cobertura de 99,5%. Nenhuma dessas cautelas afeta a contagem de famílias, que é apurada diretamente da fonte primária de pagamentos e não depende de nenhuma das covariáveis.

4 MATERIAIS E MÉTODOS: PIPELINE DE DADOS E REPRODUTIBILIDADE

A credibilidade de qualquer resultado empírico repousa sobre a cadeia que produz os dados. Aqui essa cadeia é deliberadamente *aberta e reproduzível*: parte exclusivamente de fontes públicas oficiais, é processada por um pipeline de código aberto e desemboca em modelos implementados do zero. Em princípio, qualquer pessoa, com as mesmas fontes e o mesmo código, reconstrói cada número deste artigo.

4.1 Arquitetura medallion

O processamento segue a arquitetura *medallion* [30] — três camadas de refinamento progressivo, *bronze*, *silver* e *gold* — sobre um *lakehouse* aberto (Figura 7). A camada **bronze** ingere os dados crus, sem transformação, preservando a fidelidade à fonte; a **silver** limpa, tipa, normaliza e reconcilia (é onde ocorre o *crosswalk* SIAFI → IBGE da Seção 3); a **gold** entrega agregados prontos para modelagem. O motor de processamento é o Apache Spark [27], que distribui as agregações sobre os bilhões de linhas brutas; o formato de armazenamento é o Delta Lake [28], que confere transações ACID, *schema enforcement* e *time travel* às tabelas; e o catálogo é o Unity Catalog, cujo espaço de nomes de três níveis (catálogo · esquema · tabela) organiza camadas e domínios. Todo o ambiente roda na edição gratuita do Databricks (*Free Edition*) [29] com *warehouse serverless* — isto é, sem custo de infraestrutura, condição para que o experimento seja de fato reproduzível por terceiros.




Figura 7 – Pipeline reproduzível. Da fonte pública bruta à previsão: ingestão (bronze), refino (silver), agregação (gold) e modelagem do zero, sobre Apache Spark, Delta Lake e Unity Catalog.

4.2 A escala da camada bruta

A camada bruta deste estudo soma **cerca de 4,6 bilhões de linhas** nas duas tabelas principais (Tabela 3): 2.533.885.299 pagamentos do Bolsa Família e 2.060.910.061 vínculos da RAIS. São particionadas por ano, de modo que as agregações podem *podar partições* (*partition pruning*) e varrer apenas os anos necessários — é o que mantém barata, em um *warehouse* gratuito, a mineração de uma tabela de bilhões de linhas. As camadas silver condensam essa escala em painéis tratáveis: o painel municipal de carga de casos, o painel RAIS de 4.173.982 linhas (município × CNAE × ano) e a população municipal de 66.840 células.

Tabela 3 – Tabelas-fonte e suas escalas

Camada	Tabela	Conteúdo	Linhas
Bronze	pbf_pagamentos	pagamentos PBF/AB (CGU)	2.533.885.299
Bronze	rais_vinculos	vínculos formais (RAIS)	2.060.910.061
<i>total bronze (duas tabelas)</i>			≈ 4.594.795.360
Silver	rais_panel	RAIS mun.×CNAE×ano	4.173.982
Silver	populacao_municipio_ano	população IBGE mun.×ano	66.840
Silver	painel PBF	carga de casos mun.×mês	848.526

Contagens lidas dos metadados Delta. Fonte: elaboração própria sobre CGU, IBGE e RAIS.

4.3 Governança de dados

As tabelas seguem boas práticas de gestão de dados, no sentido do *Data Management Body of Knowledge* (DAMA-DMBOK) [26]. Quatro controles são centrais. *Catalogação*: cada tabela e coluna carrega metadados descritivos no Unity Catalog, com domínio, granularidade e

proveniência documentados. *Qualidade por construção*: o *schema enforcement* do Delta Lake rejeita escritas que violem o esquema, e a evolução de esquema é versionada. *Integridade transacional*: as transações ACID e o *time travel* do Delta garantem que cada execução opere sobre um estado consistente e auditável da tabela. *Linhagem e acesso*: o Unity Catalog rastreia a linhagem bronze $\rightarrow$ silver $\rightarrow$ gold e governa o acesso por esquema. Essas práticas tornam o pipeline não apenas reproduzível, mas *auditável*: de qualquer número de saída é possível recuar até a linha bruta que o originou.

4.4 Fontes abertas e reprodutibilidade

Todas as três fontes são públicas e oficiais, e nenhuma exige credencial privada: os pagamentos do Bolsa Família estão no Portal da Transparência da CGU [4]; a população, nas estimativas do IBGE [5]; os vínculos formais, na RAIS do PDET/MTE [6]. O pipeline que as ingere e refina é de código aberto,¹ e os modelos são implementados do zero. A reprodutibilidade, portanto, não depende de nenhum dado proprietário nem de infraestrutura paga: é uma propriedade de desenho, não uma promessa.

Todos os números deste artigo são produzidos por código. O painel é minerado da camada bruta de pagamentos e as covariáveis são extraídas das bases de população (IBGE) e emprego (RAIS) e reconciliadas por *crosswalk*; o motor C++17 executa o backtest fora do tempo e a projeção; um *script* de análise computa os testes de significância e as bandas; e o *script* de figuras (`build-figures-pbf-forecast.py`) gera todos os gráficos a partir dos artefatos versionados (`metrics.json`, `significance.json`, `forward_forecast.csv`, `forward_band.csv`, `forecast_h{1,3,6,12}.csv`, `errors_h*.csv`, `training_log.csv`, `covariates_municipio_ano.csv`, `muni_year.csv`). O pipeline é determinístico dado o gerador pseudoaleatório semeado (`seed = 42`).

Declaração sobre ferramentas de IA. Nenhuma afirmação substantiva, número ou citação deste artigo foi gerada por modelos de linguagem. Todos os valores provêm dos artefatos de cômputo descritos; toda afirmação conceitual está ancorada nas referências oficiais.

5 FUNDAMENTOS

5.1 Previsão e a tirania da linha de base ingênua

A previsão de séries temporais é disciplina madura, cujo arcabouço clássico remonta à metodologia de Box e Jenkins para modelos ARIMA [17] e cuja prática contemporânea está sistematizada em Hyndman e Athanasopoulos [18]. Dela herdamos duas disciplinas inegociáveis. A primeira é a avaliação *fora da amostra* e, idealmente, *fora do tempo*: um modelo só demonstra valor se acerta dados posteriores aos do treino. A segunda é bater uma *linha de base*

¹Este artigo integra a *vertical Bolsa Família* da plataforma aberta de dados públicos brasileiros *Mirante dos Dados*; o pipeline de engenharia de dados e todo o código-fonte são públicos em <https://github.com/leona-rdochalhoub/mirante-dos-dados-br>.

ingênua: para séries com forte componente de passeio aleatório, a previsão ótima de um passo à frente costuma ser o último valor observado — a *persistência*. Um modelo que não a supera não tem valor; e superá-la é, com frequência, surpreendentemente difícil. As competições M de Makridakis, em especial a M4, documentaram sobre cem mil séries que métodos simples frequentemente superam abordagens de aprendizado de máquina puras, e que a complexidade só compensa quando há sinal estruturado a explorar [21]. Tomamos isso como hipótese de trabalho, não dogma.

5.2 Medidas de erro e validação temporal

A escolha de métrica não é neutra. Hyndman e Koehler [19] sistematizaram as propriedades das métricas usuais e alertaram para as patologias do erro percentual absoluto (MAPE) quando o alvo se aproxima de zero. Aqui a carga de casos é estritamente positiva e de magnitude considerável, de modo que o MAPE é bem comportado e, por ser invariante de escala, compara honestamente municípios díspares — adotamo-lo como métrica principal, complementado pelo MAE. Quanto a *como* validar: para séries temporais, a validação cruzada aleatória vaza futuro no passado, e a avaliação correta respeita a ordem do tempo, como argumentam Bergmeir e Benítez [20] — o que motiva nossa partição estritamente fora do tempo (Seção 6.5).

5.3 Redes neurais como aproximadores de funções

Um perceptron multicamadas (MLP) é uma função paramétrica $f_{\theta} : \mathbb{R}^d \rightarrow \mathbb{R}$ que compõe transformações afins e não-linearidades. Seu interesse teórico vem dos teoremas de aproximação universal: Cybenko o provou para funções sigmoidais [11] e Hornik, Stinchcombe e White o estenderam a uma classe ampla de não-linearidades [12]. Esses teoremas garantem *expressividade*, mas são silenciosos sobre *aprendizado* e *generalização*: existe uma rede que aproxima a função alvo, o que não diz que a aprenderemos de dados finitos nem que ela generalizará. A história deste artigo mora nessa lacuna. O treino por retropropagação foi popularizado por Rumelhart, Hinton e Williams [10] e é a base do aprendizado profundo moderno [9], [8]; os ingredientes que o tornam estável — ReLU, inicialização sensível à variância, otimizadores adaptativos — são tratados em Goodfellow, Bengio e Courville [8] e, no registro da implementação em C++ de alto desempenho, em Chen e Gupta [7], cujo roteiro seguimos à risca.

5.4 Por que covariáveis exógenas?

Um modelo puramente autorregressivo extrapola o passado da própria série. Funciona enquanto a dinâmica é inercial, mas é cego a mudanças de regime do ambiente. Demografia e mercado de trabalho são, teoricamente, os motores estruturais da elegibilidade: a população define o denominador da demanda, e o emprego formal — cuja relação inversa com a cobertura a Figura 3 documenta — aproxima a informalidade e a vulnerabilidade que elevam a demanda potencial. Incluí-las dá ao preditor estrutura que o histórico recente não contém. Se essa estrutura for de fato não-linear, é também onde a profundidade de uma rede teria, enfim, algo a

explorar.

5.5 Modelos globais e aprendizado profundo para previsão

A decisão de treinar *um único* modelo global sobre milhares de séries — em vez de um modelo por município — acompanha uma virada recente da literatura. Hewamalage, Bergmeir e Bandara [22] mostraram, em larga escala, que modelos globais, que aprendem padrões compartilhados entre séries, em geral superam modelos locais quando as séries são numerosas e relacionadas — exatamente o caso de 5.542 trajetórias municipais do mesmo programa. No registro do aprendizado profundo, a vitória do método híbrido de Smyl na competição M4 [23] — combinando suavização exponencial e redes recorrentes — e o modelo probabilístico DeepAR de Salinas *et al.* [24] popularizaram arquiteturas globais; surveys como o de Lim e Zohren [25] mapeiam o campo. Esse corpo de evidências, no entanto, é matizado: os mesmos estudos e as competições M [21] repetidamente encontram que a vantagem do aprendizado profundo só se materializa quando há volume e estrutura suficientes, e que métodos simples permanecem competitivos. Nosso achado — a autorregressão linear global dominando a rede profunda global — é uma instância nítida dessa ressalva, em dados públicos brasileiros: o ingrediente que faltava à profundidade não era arquitetura, mas *informação* (covariáveis), e ainda assim o modelo parcimonioso a usa melhor.

6 TAREFA DE PREVISÃO E PROTOCOLO DE AVALIAÇÃO

6.1 Definição formal

Para cada município c e horizonte H , a tarefa é prever a carga de casos $f_{c,t}$ no mês t a partir das observações disponíveis até $t - H$. Fixamos a janela em $W = 12$ meses, de modo que o preditor enxerga um ciclo anual completo. A previsão a H meses nunca usa informação posterior a $t - H$.

6.2 Engenharia de atributos univariados

A carga de casos é positiva e de cauda longa; trabalhamos na escala $\log(1 + x)$, que comprime a heterogeneidade e estabiliza a variância: $\ell_{c,t} = \log(1 + f_{c,t})$. Padronizamos *por município* com média e desvio-padrão calculados *apenas com meses de treino*:

$$s_{c,t} = \frac{\ell_{c,t} - \mu_c}{\sigma_c}, \quad \mu_c = \frac{1}{|\mathcal{T}_c^{\text{tr}}|} \sum_{u \in \mathcal{T}_c^{\text{tr}}} \ell_{c,u}, \quad \sigma_c^2 = \frac{1}{|\mathcal{T}_c^{\text{tr}}|} \sum_{u \in \mathcal{T}_c^{\text{tr}}} (\ell_{c,u} - \mu_c)^2. \quad (3)$$

O vetor univariado tem $W + 2 = 14$ componentes: doze defasagens padronizadas e dois termos de sazonalidade harmônica do mês-do-ano m do alvo,

$$\mathbf{x}_{c,t,H}^{\text{uni}} = \left(s_{c,t-H-11}, \dots, s_{c,t-H}; \sin \frac{2\pi m}{12}, \cos \frac{2\pi m}{12} \right) \in \mathbb{R}^{14}, \quad (4)$$

com alvo $y = s_{c,t}$. A codificação seno/cosseno coloca o mês sobre o círculo unitário, tornando dezembro e janeiro adjacentes. Para retornar à escala de famílias invertemos as transformações: $\hat{f}_{c,t} = \exp(\sigma_c \hat{y} + \mu_c) - 1$.

6.3 Covariáveis e sua defasagem causal

Acrescentamos $\text{NCOV} = 2$ covariáveis municipais anuais — população (IBGE) e vínculos formais ativos (RAIS) —, ambas em escala $\log(1+\cdot)$ e padronizadas *globalmente* com estatísticas calculadas sobre anos de treino (≤ 2023):

$$\mathbf{g}_{c,\tau} = \left(\frac{\log(1 + \text{pop}_{c,\tau}) - \bar{g}_1}{s_1}, \frac{\log(1 + \text{vinc}_{c,\tau}) - \bar{g}_2}{s_2} \right) \in \mathbb{R}^2. \quad (5)$$

O ano de referência τ é o *ano anterior* ao último mês visível $t - H$, isto é, $\tau = \lfloor \text{ano}(t - H) \rfloor - 1$, e usamos o registro mais recente disponível com $\text{ano} \leq \tau$. Essa defasagem de um ano é deliberada: a RAIS de um ano só é publicada no ano seguinte, e populações são estimadas anualmente; tomar $\tau < \text{ano}(t - H)$ garante que a covariável estaria *de fato disponível* no momento da previsão — nenhuma informação do futuro do alvo entra no modelo. O vetor multivariado é a concatenação $\mathbf{x}^{\text{mv}} = (\mathbf{x}^{\text{uni}}; \mathbf{g}_{c,\tau}) \in \mathbb{R}^{16}$.

6.4 Modelo global único

Treinamos *um único* modelo global, comum a todos os municípios, em vez de 5.542 modelos locais. A padronização por município coloca todas as trajetórias em escala comum, e o modelo aprende uma vez a *forma* de uma trajetória típica e a transfere para toda parte. A escolha é estatisticamente eficiente e robusta para municípios pequenos, cujas séries individuais seriam curtas demais.

6.5 Protocolo de avaliação honesto

Quatro regras impõem honestidade. **(1) Sem vazamento na padronização:** μ_c, σ_c usam só meses de treino. **(2) Covariáveis defasadas:** ano de referência $\tau < \text{ano}(t - H)$, equação (5). **(3) Partição fora do tempo:** alvos com t anterior a janeiro de 2025 treinam; janeiro a dezembro de 2025 testam (≈ 66.504 previsões por horizonte). **(4) Linha de base forte:** persistência $\hat{f}_{c,t}^{\text{pers}} = f_{c,t-H}$. Avaliamos $H \in \{1, 3, 6, 12\}$ meses, do quase-instantâneo ao horizonte de planejamento orçamentário.

6.6 Decisões de desenho

Três escolhas merecem justificativa. A **janela** $W = 12$ cobre um ciclo anual completo, capturando a sazonalidade sem inflar a dimensão de entrada — janelas maiores aumentariam a variância de estimação sem evidência de ganho, dada a forte autocorrelação de curto alcance da série. O **conjunto de horizontes** $\{1, 3, 6, 12\}$ amostra o espectro relevante: o passeio-aleatório de um mês, dois horizontes intermediários e o ano fiscal. O **modelo global único** (Seção 5)

agrupa força amostral de milhares de séries curtas e é a escolha sustentada pela literatura de modelos globais [22]; a alternativa — 5.542 modelos locais — seria inviável para municípios pequenos e ignoraria a estrutura compartilhada que torna a transferência de aprendizado eficaz.

7 MODELOS

Os cinco modelos compartilham os mesmos dados, a mesma perda (erro quadrático médio sobre o alvo padronizado) e a mesma família de otimizador, de modo que qualquer diferença é leitura limpa do efeito da *capacidade* e da *informação* disponível. A Tabela 4 fixa a notação.

Tabela 4 – Notação

Símbolo	Significado
$f_{c,t}$	carga de casos (famílias) do município c no mês t
$\ell_{c,t}$	$\log(1 + f_{c,t})$
μ_c, σ_c	média e desvio-padrão de $\ell_{c,\cdot}$, só com meses de treino
$s_{c,t}$	valor padronizado $(\ell_{c,t} - \mu_c)/\sigma_c$
$g_{c,\tau}$	covariáveis padronizadas (pop, vínculos) do ano τ
$\mathbf{x}^{\text{uni}}, \mathbf{x}^{\text{mv}}$	atributos univariado (14) e multivariado (16)
H, W	horizonte de previsão; janela de defasagens (= 12)
$\mathbf{W}^{(l)}, \mathbf{b}^{(l)}$	pesos e vieses da camada l
ϕ	não-linearidade ReLU, $\phi(u) = \max(0, u)$
η, λ	taxa de aprendizado e decaimento de peso (AdamW)

7.1 Persistência

Sem parâmetros: $\hat{f} = f_{c,t-H}$. Piso de comparação e teste da hipótese de passeio aleatório.

7.2 Autorregressão linear, perceptron profundo e suas versões com covariáveis

Os quatro modelos aprendidos são instâncias do mesmo MLP, diferindo em profundidade e em entrada. Seja L o número de camadas de pesos e $\mathbf{a}^{(0)} = \mathbf{x}$ a entrada. O *passo de avanço* computa, para $l = 1, \dots, L$,

$$\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}, \quad \mathbf{a}^{(l)} = \phi^{(l)}(\mathbf{z}^{(l)}), \quad (6)$$

com ReLU nas camadas ocultas, $\phi(u) = \max(0, u)$, $\phi'(u) = \mathbb{I}[u > 0]$, e saída linear, $\mathbf{a}^{(L)} = \hat{\mathbf{y}}$. A **autorregressão linear** é $\text{MLP}(\{14, 1\})$, sem camada oculta, $\hat{\mathbf{y}} = \mathbf{w}^\top \mathbf{x}^{\text{uni}} + b$; o **perceptron profundo** é $\text{MLP}(\{14, 64, 32, 1\})$. As versões **com covariáveis** — *AR linear + cov.* e *MLP profunda + cov.* — têm a mesma topologia interna mas entrada $\mathbf{x}^{\text{mv}} \in \mathbb{R}^{16}$ (Figura 8).

A rede com covariáveis: 16 → 64 → 32 → 1

Perceptron multicamadas do zero em C++17 (He · ReLU · AdamW); 2 covariáveis anuais




Figura 8 – Arquitetura da rede profunda com covariáveis (16 → 64 → 32 → 1). Aos 14 atributos univariados juntam-se dois nós de covariável (em verde): log da população (IBGE) e log dos vínculos formais (RAIS). He, ReLU, AdamW; tudo do zero em C++17.

7.3 Inicialização sensível à variância

Para redes ReLU, He *et al.* [13] mostraram que preservar a variância da ativação exige variância de peso $2/n_{\text{in}}$:

$$W_{ij}^{(l)} \sim \mathcal{N}\left(0, \frac{2}{n_{l-1}}\right), \quad b_i^{(l)} = 0, \quad (7)$$

generalização, para ReLU, da inicialização de Glorot e Bengio [14].

7.4 Perda e retropropagação

A perda por exemplo é o erro quadrático sobre o alvo padronizado, $\ell = (\hat{y} - y)^2$, e $\mathcal{L} = \frac{1}{N} \sum_i (\hat{y}_i - y_i)^2$. O gradiente segue por retropropagação [10]. Com saída linear, $\delta^{(L)} = 2(\hat{y} - y)$, e

$$\delta^{(l)} = \left(\mathbf{W}^{(l+1)\top} \delta^{(l+1)} \right) \odot \phi'(z^{(l)}), \quad \frac{\partial \ell}{\partial \mathbf{W}^{(l)}} = \delta^{(l)} \mathbf{a}^{(l-1)\top}, \quad \frac{\partial \ell}{\partial \mathbf{b}^{(l)}} = \delta^{(l)}, \quad (8)$$

onde $\odot$ é o produto de Hadamard. A implementação acumula gradientes ao longo de um mini-lote e dá um passo de otimização sobre o gradiente médio; o fator 2 é absorvido na taxa de aprendizado.

7.5 Otimizador: AdamW

Atualizamos com Adam [15], que adapta o passo por parâmetro a partir de estimativas dos momentos do gradiente. Com $\mathbf{g}_t$ o gradiente médio do minilote,

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \mathbf{g}_t, \quad \mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2) \mathbf{g}_t^{\odot 2}, \quad (9)$$

$$\widehat{\mathbf{m}}_t = \frac{\mathbf{m}_t}{1 - \beta_1^t}, \quad \widehat{\mathbf{v}}_t = \frac{\mathbf{v}_t}{1 - \beta_2^t}, \quad (10)$$

e o passo, com decaimento de peso *desacoplado* de Loshchilov e Hutter [16],

$$\boldsymbol{\theta}_t = \boldsymbol{\theta}_{t-1} - \eta \frac{\widehat{\mathbf{m}}_t}{\sqrt{\widehat{\mathbf{v}}_t} + \varepsilon} - \eta \lambda \boldsymbol{\theta}_{t-1}. \quad (11)$$

O último termo encolhe os pesos diretamente, recuperando a interpretação de regularização L_2 sob Adam. Usamos $\beta_1 = 0,9$, $\beta_2 = 0,999$, $\varepsilon = 10^{-8}$, minilotes de 256. As autorregressões lineares usam cronograma fixo ($\eta = 10^{-2}$, sem decaimento, 25 épocas); os perceptrons profundos, $\eta = 10^{-3}$, $\lambda = 10^{-4}$ e até 60 épocas com parada antecipada.

7.6 Parada antecipada

Para conter o sobreajuste dos modelos profundos, retemos 15% do treino como validação e monitoramos o MAE de validação em famílias; com *paciência* de cinco épocas, interrompemos e restauramos os pesos da melhor época (Figura 9) [8]. As autorregressões lineares dispensam o mecanismo.




Figura 9 – Curva de validação do perceptron profundo ($H = 12$). O MAE de validação cai, atinge um mínimo e oscila; a parada antecipada seleciona e restaura os pesos da melhor época.

7.7 Algoritmo de treino

Reunindo as peças, o treino é o laço do Quadro 1: cada época percorre o treino em minilotes de $B = 256$; acumulam-se gradientes exemplo a exemplo; ao fim do minilote, um passo de AdamW sobre o gradiente médio.

Quadro 1 – Treino com minilote AdamW e parada antecipada

entrada: treino $\mathcal{D}$, validação $\mathcal{V}$ (15%), épocas máx. E , paciência p
 inicialize $\mathbf{W}, \mathbf{b}$ por He (eq. 7); $\mathbf{m}, \mathbf{v} \leftarrow \mathbf{0}$; $t \leftarrow 0$; $\boldsymbol{\theta}^* \leftarrow \boldsymbol{\theta}$
para época = 1, ..., E **faça**
 embaralhe $\mathcal{D}$ e particione em minilotes de tamanho B
 para cada minilote $\mathcal{B}$: avanço (eq. 6); acumule grad. (eq. 8);
 $t \leftarrow t + 1$; passo de AdamW (eq. 11); zere acumuladores
 $\text{mae}_{\text{val}} \leftarrow \text{MAE em } \mathcal{V}$, em famílias
 se melhora **então** guarde $\boldsymbol{\theta}^* \leftarrow \boldsymbol{\theta}$ **senão se** p épocas sem melhora **então pare**
retorne $\boldsymbol{\theta}^*$

7.8 Um passo de treino, em números

Para tornar concreto o maquinário das equações (6)–(11), o Quadro 2 percorre um *único* exemplo da autorregressão linear: avanço, perda, gradiente e o primeiro passo de AdamW de um peso. O exemplo ilustra por que a correção de viés do Adam ($1 - \beta_1^t$) importa nos primeiros passos e como o decaimento de peso desacoplado encolhe o parâmetro independentemente do gradiente.

Quadro 2 – Um passo de AdamW para um peso (ilustrativo)

Seja, no passo $t = 1$, um peso $w = 0,30$ cuja derivada da perda seja $g = \partial \ell / \partial w = 0,50$ (média do minilote), com $\eta = 10^{-2}$, $\beta_1 = 0,9$, $\beta_2 = 0,999$, $\varepsilon = 10^{-8}$, $\lambda = 10^{-4}$.

$$m_1 = 0,9 \cdot 0 + 0,1 \cdot 0,50 = 0,050, \quad v_1 = 0,999 \cdot 0 + 0,001 \cdot 0,50^2 = 2,5 \times 10^{-4},$$

$$\widehat{m}_1 = \frac{0,050}{1-0,9} = 0,50, \quad \widehat{v}_1 = \frac{2,5 \times 10^{-4}}{1-0,999} = 0,25.$$

$$w \leftarrow w - \eta \frac{\widehat{m}_1}{\sqrt{\widehat{v}_1} + \varepsilon} - \eta \lambda w = 0,30 - 0,01 \cdot \frac{0,50}{0,50} - 0,01 \cdot 10^{-4} \cdot 0,30 \approx 0,290.$$

A correção de viés transforma $m_1 = 0,05$ em $\widehat{m}_1 = 0,50$ (sem ela, o primeiro passo seria dez vezes menor); o termo $-\eta \lambda w$ encolhe w em 3×10^{-7} , efeito minúsculo por passo mas cumulativo ao longo das épocas.

7.9 Complexidade e número de parâmetros

O custo de um avanço é dominado pelos produtos matriz-vetor: FLOPs $\approx 2 \sum_l n_{l-1} n_l$. A Tabela 5 resume a anatomia dos cinco modelos. A contagem de parâmetros explicita o argumento de viés-variância (Seção 12): as autorregressões estimam 15–17 parâmetros; os perceptrons profundos, mais de 3.000. As covariáveis acrescentam apenas dois atributos — custo

desprezível, sinal potencialmente grande.

Tabela 5 – Anatomia dos cinco modelos

Modelo	Parâmetros	FLOPs/avanço	Entrada / regularização
Persistência	0	0	—
AR linear	15	28	14 atrib.; fixo
MLP profunda	3.073	≈5.888	14 atrib.; AdamW + parada antecip.
AR linear + cov.	17	32	16 atrib.; fixo
MLP profunda + cov.	3.201	≈6.144	16 atrib.; AdamW + parada antecip.

Parâmetros da MLP profunda: $14 \cdot 64 + 64 + 64 \cdot 32 + 32 + 32 \cdot 1 + 1 = 3.073$; com covariáveis, $16 \cdot 64 + \dots = 3.201$.

Fonte: elaboração própria.

7.10 Implementação do zero em C++17

Todo o motor — camadas densas, ReLU, retropropagação, AdamW — é escrito à mão em C++17, usando apenas `<vector>`, `<cmath>`, `<map>` e `<random>`, sem LibTorch, BLAS ou qualquer dependência de aprendizado profundo. Os pesos são armazenados em ordem *row-major* por camada; avanço e retropropagação operam um exemplo por vez, acumulando o gradiente sobre o minilote antes de um passo de Adam. Pedagogicamente alinhada a [7], a escolha torna cada operação inspecionável e o experimento integralmente reproduzível, ao custo de desempenho irrelevante nesta escala.

8 MÉTRICAS E INFERÊNCIA

8.1 Métricas de erro

Todas as métricas são computadas *em unidades de famílias*, após a inversão da padronização, sobre as ≈66.504 previsões retidas de cada horizonte. Para erros $e_i = \hat{f}_i - f_i$,

$$\text{MAE} = \frac{1}{N} \sum_i |e_i|, \quad \text{MAPE} = \frac{100}{N} \sum_i \frac{|e_i|}{f_i}, \quad \text{RMSE} = \sqrt{\frac{1}{N} \sum_i e_i^2}, \quad R^2 = 1 - \frac{\sum_i e_i^2}{\sum_i (f_i - \bar{f})^2}. \quad (12)$$

O R^2 é dominado pela variância *entre* municípios e, por isso, pouco informativo aqui (fica acima de 0,98 para todos); a métrica que separa os modelos é o MAPE, invariante de escala, complementada pelo MAE.

8.2 Comparação pareada de modelos

Com $n \approx 66.504$, qualquer diferença minúscula é “estatisticamente significativa” a um valor- p desprezível; o valor- p isolado é desinformativo. Reportamos, por par de modelos, pareados no mesmo conjunto: (i) a diferença média de erro absoluto $\Delta\text{MAE} = \text{MAE}_B - \text{MAE}_A$

(positivo $\Rightarrow A$ vence), em famílias; (ii) seu IC de 95% por bootstrap pareado, com 2.000 reamostragens [33]; (iii) o valor- p do teste de Wilcoxon [32]; e (iv) a *taxa de vitória*, a fração de previsões em que $|e_A| \leq |e_B|$. O bootstrap mede a incerteza da *magnitude*; Wilcoxon, a consistência do *signal*; a taxa de vitória, sua *disseminação*. A lógica de comparar acurácia preditiva por pares remonta a Diebold e Mariano [31].

9 RESULTADOS: ACURÁCIA FORA DO TEMPO

A Tabela 6 reúne MAE e MAPE dos cinco modelos nos quatro horizontes; a Figura 10 mostra o núcleo univariado e a Figura 11 traduz tudo em redução de MAE sobre a persistência.


Tabela 6 – Acurácia fora do tempo por horizonte (≈ 66.504 previsões cada)

Horizonte	Modelo	MAE (fam.)	MAPE (%)	vs. persist.
1 mês	Persistência	54,6	1,94	—
	AR linear	57,5	1,98	−5%
	MLP profunda	54,9	2,04	−1%
	AR linear + cov.	60,3	1,98	−11%
	MLP profunda + cov.	55,4	1,97	−2%
3 meses	Persistência	118,3	4,19	—
	AR linear	98,1	3,83	+17%
	MLP profunda	117,5	4,24	+1%
	AR linear + cov.	107,9	3,82	+9%
	MLP profunda + cov.	125,2	4,22	−6%
6 meses	Persistência	206,1	7,26	—
	AR linear	150,2	5,99	+27%
	MLP profunda	201,8	7,15	+2%
	AR linear + cov.	151,0	5,95	+27%
	MLP profunda + cov.	189,1	6,62	+8%
12 meses	Persistência	268,8	9,92	—
	AR linear	243,1	8,80	+10%
	MLP profunda	297,1	9,89	−11%
	AR linear + cov.	223,3	8,62	+17%
	MLP profunda + cov.	298,7	9,55	−11%

Em negrito, o melhor de cada bloco. A coluna “vs. persist.” é a redução de MAE sobre a ingênua. Fonte: elaboração própria.

Erro percentual cresce com o horizonte — e a rede rasa vence

MAPE nas previsões municipais retidas (alvos de 2025), por horizonte




Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

Figura 10 – MAPE fora da amostra (núcleo univariado). A um mês a persistência é imbatível; de três meses em diante a autorregressão linear tem o menor erro percentual, e a vantagem cresce com o horizonte.

Covariáveis elevam o modelo linear; a profundidade segue atrás

Ganho de acurácia (↓ MAE) sobre a ingênua; negativo = pior que repetir o último valor



Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

Figura 11 – Redução de MAE sobre a persistência, quatro modelos aprendidos. A autorregressão linear (com e sem covariáveis) lidera; a profundidade fica sistematicamente atrás. Em 12 meses, é o modelo *linear com covariáveis* que mais reduz o erro (+17%).

A leitura é direta. A **um mês**, a persistência tem o menor MAE (54,6); nenhum modelo

aprendido a supera — assinatura empírica de um passeio aleatório. De **três meses** em diante, a autorregressão linear assume a liderança: reduz o MAE em 17%, 27% e 10% (3, 6 e 12 meses) sobre a ingênua. O perceptron profundo melhora pouco e é *dominado* pelo linear em todo horizonte; com ou sem covariáveis, a profundidade não paga. O ponto novo, e o mais relevante, aparece no horizonte de **doze meses**: ali o modelo *linear com covariáveis* é o melhor de todos (+17% vs. +10% do linear univariado), sinal de que demografia e emprego carregam informação estrutural que o histórico recente não contém. A próxima seção isola esse efeito.


10 O EFEITO DAS COVARIÁVEIS

A pergunta-chave do estudo multivariado é direta: *adicionar população e emprego formal melhora a previsão?* A Figura 12 responde, mostrando o Δ MAE de cada modelo *com* covariáveis contra sua versão univariada, com IC de 95%; a Tabela 7 traz os números.

Tabela 7 – Efeito das covariáveis: Δ MAE (com cov. – univariado), pareado

<i>H</i>	Comparação	Δ MAE (fam.)	IC 95%
1	linear+cov vs. linear	−2,85	[−5,4; −0,3]
	deep+cov vs. deep	−0,50	[−1,6; +0,5]
3	linear+cov vs. linear	−9,81	[−12,4; −7,2]
	deep+cov vs. deep	−7,70	[−10,4; −5,2]
6	linear+cov vs. linear	−0,82	[−2,1; +0,5]
	deep+cov vs. deep	+12,71	[+8,4; +16,7]
12	linear+cov vs. linear	+19,76	[+12,1; +27,5]
	deep+cov vs. deep	−1,55	[−5,9; +3,1]

Δ MAE > 0 indica que as covariáveis *ajudam*. IC por bootstrap pareado (2.000 reamostragens). Fonte: elaboração própria.



Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

Figura 12 – O valor das covariáveis cresce com o horizonte. Δ MAE de adicionar população e emprego formal, com IC 95%: negativo ou nulo a 1–3 meses, fortemente positivo para o modelo linear em 12 meses (+19,8, IC [+12,1; +27,5]) e para o profundo em 6 meses (+12,7).

O padrão é claro e econômico. A **curto prazo (1–3 meses)**, as covariáveis *não ajudam* e chegam a prejudicar — a dinâmica é dominada pela autocorrelação mensal, e variáveis anuais defasadas apenas adicionam ruído e uma incompatibilidade de frequência. A **seis meses**, ajudam o modelo profundo de forma robusta (+12,7). A **doze meses**, elevam o modelo linear de forma grande e robusta (+19,8, IC estritamente positivo): é justamente onde a autorregressão pura enfraquece e os motores estruturais — quantos habitantes, quantos empregos formais — passam a governar a demanda. O valor de uma covariável de baixa frequência é, portanto, *função do horizonte*: invisível no curto prazo, decisivo no longo. Notavelmente, mesmo alimentada com covariáveis, a rede profunda permanece atrás do modelo linear (Tabela 6): a informação ajuda, mas a forma certa de usá-la continua sendo o modelo parcimonioso.


11 SIGNIFICÂNCIA ESTATÍSTICA

A Tabela 8 compara os modelos aprendidos contra a persistência e entre si; a Figura 13 visualiza a vantagem da autorregressão linear com IC; a Figura 14, a taxa de vitória; e a Figura 15, a distribuição completa do erro em seis meses.

Tabela 8 – Comparações pareadas selecionadas ($n \approx 66.504$)


H	Comparação	ΔMAE (fam.)	IC 95%
3	AR linear vs. persist.	+20,18	[+17,6; +22,7]
	AR linear vs. deep	+19,39	[+16,8; +22,0]
6	AR linear vs. persist.	+56,00	[+49,7; +62,4]
	deep+cov vs. AR linear	-38,95	[-44,7; -33,6]
12	AR linear vs. persist.	+25,71	[+14,2; +37,9]
	AR linear + cov. vs. persist.	+45,5	[+33; +58]

$\Delta\text{MAE} > 0$ favorece o primeiro modelo. Todos os testes de Wilcoxon têm $p < 10^{-30}$; a leitura está no IC. A última linha é a soma das vantagens linear vs. persist. (+25,71) e linear+cov vs. linear (+19,76). Fonte: elaboração própria.




Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

Figura 13 – Vantagem da autorregressão linear sobre a persistência, com IC 95%. A seis meses o intervalo é estritamente positivo e largo (+56 famílias): vantagem grande e robusta. A doze meses permanece positivo, e as covariáveis o ampliam ainda mais (Seção 10).



Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

Figura 14 – Taxa de vitória sobre a persistência. A fração de municípios em que cada modelo vence cresce com o horizonte, atingindo 64% para a autorregressão linear em seis meses: a vantagem se dissemina pela maioria, não vem de poucos atípicos.



Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

Figura 15 – Distribuição acumulada do erro percentual absoluto ($H = 6$). As curvas com covariáveis e a do modelo linear ficam à esquerda da persistência em quase toda a faixa: para qualquer limiar de erro, mais municípios o cumprem. Domínio estocástico de primeira ordem aproximado.

11.1 Síntese e robustez

A Tabela 9 resume o melhor modelo em cada horizonte e o ganho correspondente. A conclusão é *robusta* a múltiplos critérios: as quatro lentes — MAE, MAPE (Tabela 6), RMSE (R^2 , Apêndice A) e taxa de vitória (Apêndice B) — concordam na ordenação dos modelos em 3, 6 e 12 meses, e os intervalos de confiança das vantagens decisivas são estritamente positivos. Nenhuma das conclusões depende de uma única métrica ou de um único horizonte.

Tabela 9 – Síntese: melhor modelo por horizonte

Horizonte	Melhor modelo	Redução de MAE	Regime
1 mês	Persistência	—	passeio aleatório
3 meses	AR linear	+17%	autocorrelação domina
6 meses	AR linear (+ cov.)	+27%	ganho máximo da AR
12 meses	AR linear + cov.	+17%	covariáveis decisivas

Redução de MAE sobre a persistência. Em 6 meses, AR linear e AR linear + cov. empatam (+27%). Fonte: elaboração própria.

Conclusões inferenciais. (i) A vantagem da autorregressão linear em seis meses é grande, robusta e disseminada (vence 64% dos municípios). (ii) A doze meses a vantagem persiste e é *ampliada pelas covariáveis*: linear+cov supera a persistência por $\approx +45$ famílias, contra +26 do linear puro. (iii) A profundidade, mesmo com covariáveis, é dominada pela autorregressão linear em 3, 6 e 12 meses (deep+cov vs. linear: -27 , -39 , -56 famílias) — a informação ajuda, a capacidade extra não.

12 INTERPRETAÇÃO: QUANDO AJUDAM A PROFUNDIDADE E AS COVARIÁVEIS?

Dois fenômenos pedem explicação: por que a rede mais simples vence a mais profunda, e por que o valor das covariáveis cresce com o horizonte. Ambos seguem da estrutura do sinal e do compromisso entre viés e variância [8], [18].

12.1 Por que a profundidade não paga

A um mês, a série é quase um passeio aleatório. A melhor previsão de $f_{c,t}$ a partir de $f_{c,t-1}$ é aproximadamente o próprio $f_{c,t-1}$; o incremento é dominado por ruído. A persistência é quase ótima, e qualquer parâmetro estimado só adiciona variância. **Num sinal quase log-linear, a autorregressão é o modelo do tamanho certo.** Uma combinação linear de doze defasagens captura quase toda a estrutura previsível — tendência e persistência — com pouquíssimos parâmetros, e generaliza melhor fora do tempo. **O perceptron profundo gasta capacidade que o sinal não recompensa:** suas camadas ocultas modelam interações não-lineares; quando a estrutura é quase linear, a capacidade extra vira variância (sobreajuste), não redução de viés. A

regularização o resgata, mas não o suficiente para alcançar o linear.

12.2 Uma leitura formal: viés, variância e horizonte

Para um estimador $\hat{f}$ de $f = g(x) + \epsilon$ com ruído de média zero e variância σ^2 , o erro quadrático esperado se decompõe como

$$\mathbb{E}[(f - \hat{f})^2] = \underbrace{(g - \mathbb{E}[\hat{f}])^2}_{\text{viés}^2} + \underbrace{\mathbb{E}[(\hat{f} - \mathbb{E}[\hat{f}])^2]}_{\text{variância}} + \underbrace{\sigma^2}_{\text{irreduzível}}. \quad (13)$$

A persistência tem viés alto e variância nula; a autorregressão linear corta o viés com variância pequena; o perceptron profundo reduz mais o viés *em princípio*, mas adiciona variância substancial. O ponto que minimiza (13) *depende do horizonte*: em $H = 1$, o termo σ^2 domina e vence quem nada estima (persistência); em $H = 6$, o viés da persistência explode e a autorregressão acerta o equilíbrio.

12.3 Por que o valor das covariáveis cresce com o horizonte

A mesma equação (13) explica o efeito das covariáveis. A informação que uma covariável adiciona reduz o viés *na medida em que ela prediz a parte do alvo que as defasagens não predizem*. A curto prazo, as defasagens já contêm quase tudo: a população de um município há um ano nada acrescenta sobre o próximo mês, e a covariável anual, defasada, apenas injeta variância — daí o ΔMAE negativo em 1–3 meses (Tabela 7). A longo prazo, porém, a autocorrelação se esgota e a previsão precisa de *âncoras estruturais*: quantos habitantes, quanto emprego formal. É aí que a covariável corta viés genuíno, e o ΔMAE se torna grande e positivo em 12 meses. Em suma: o valor de uma covariável de baixa frequência é crescente no horizonte porque é exatamente no longo prazo que o sinal autorregressivo se torna insuficiente.

A lição metodológica — *case a capacidade do modelo e a frequência da informação à estrutura e ao horizonte do problema* — ecoa, em dados públicos brasileiros, o achado das competições de previsão em larga escala [21]: sofisticação não é, por si, acurácia.

13 PROJEÇÃO 2026–2028

13.1 Procedimento e o porquê de o agregado ser mais fácil

Para projetar, reajustamos os modelos sobre *todas* as janelas observadas e rolamos cada município adiante de forma *recursiva*: cada previsão vira a entrada mais recente da janela seguinte; as covariáveis são mantidas no último ano conhecido (2024), por ainda não observadas no futuro. Somamos as previsões municipais à trajetória nacional $\hat{N}_t = \sum_c \hat{f}_{c,t}$. A incerteza nacional é o MAPE *agregado* de backtest, não a soma dos erros municipais, porque na agregação os erros idiossincráticos largamente se cancelam. Formalmente, para erros e_c com variância ς_c^2

e correlação $\rho_{cc'}$,

$$\text{Var}\left(\sum_c e_c\right) = \sum_c s_c^2 + \sum_{c \neq c'} \rho_{cc'} s_c s_{c'}; \quad (14)$$

como $\rho_{cc'}$ é, em média, pequeno, o desvio do agregado cresce como $\sqrt{m}$ enquanto o agregado cresce como m , e o erro relativo encolhe $\sim 1/\sqrt{m_{\text{ef}}}$. É por isso que o MAPE nacional cai para 1,29% / 2,17% / 3,52% / 4,68% (modelo linear) em 1 / 3 / 6 / 12 meses — muito abaixo dos MAPEs municipais (Tabela 6). A Figura 16 mostra o ajuste nacional sobre 2025, com as covariáveis reduzindo ainda mais o erro agregado de longo prazo (MAPE nacional de 4,49% em 12 meses para o modelo linear com covariáveis).




Figura 16 – Ajuste nacional na janela de teste ($H = 6$). A soma das previsões municipais reproduz o agregado observado de 2025 com erro pequeno; os erros municipais cancelam-se na agregação, o que justifica usar o MAPE nacional como banda da projeção.

13.2 Propagação de erro na recursão

A projeção a k meses encadeia k previsões de um passo, cada uma alimentada pela anterior. Se cada passo introduz um erro η_t aproximadamente de média zero e variância σ_η^2 , e o operador de um passo tem ganho local $|a| < 1$ (a série é estacionária em torno de sua tendência na escala padronizada), o erro acumulado após k passos satisfaz, em primeira ordem,

$$\varepsilon_k \approx \sum_{j=0}^{k-1} a^j \eta_{k-j}, \quad \text{Var}(\varepsilon_k) \approx \sigma_\eta^2 \frac{1 - a^{2k}}{1 - a^2} \xrightarrow{k \rightarrow \infty} \frac{\sigma_\eta^2}{1 - a^2}. \quad (15)$$


Dois efeitos competem. De um lado, a variância do erro *cresce* com o horizonte, mas *satura* (não explode), porque $|a| < 1$ amortece contribuições antigas. De outro, esse mesmo amortecimento implica *reversão à média*: previsões de longo prazo são puxadas para a média histórica de cada município, o que tende a suavizar trajetórias e pode subestimar movimentos persistentes — é a origem da limitação discutida na Seção 14. A equação (15) explica por que a banda nacional da Figura 17 se alarga de forma decrescente, e não linear, com o horizonte.

13.3 Resultados da projeção

A Figura 17 apresenta a série histórica e a projeção até dezembro de 2028; a Tabela 10 resume os marcos. A carga de casos nacional atingiu o **pico em janeiro de 2023** (21.243.010 famílias) e **recua desde então**, em 18.401.764 famílias em dezembro de 2025. Ambos os modelos projetam *consolidação, não crescimento*. A trajetória central (autorregressão linear) leva a $\approx 15.442.971$ famílias em dezembro de 2028 (-16% ante dezembro de 2025); o modelo linear com covariáveis projeta praticamente o mesmo ($\approx 15.456.747$), e o perceptron profundo com covariáveis, um recuo mais brando ($\approx 15.902.025$). A convergência das projeções para a faixa de 15,4–15,9 milhões reforça a robustez da conclusão.

A carga de casos do Bolsa Família atingiu o pico e recua

Famílias beneficiárias por mês, 2013–2025, e projeção 2026–2028, por regime do programa



Fonte: elaboração própria sobre microdados do Portal da Transparência (CGU), população (IBGE) e RAIS (PDET/MTE); modelos treinados em C++17.

Figura 17 – Carga de casos nacional, 2013–2025, e projeção 2026–2028, por regime do programa.

A série atingiu o pico em 2022–2023 e recua. A projeção central indica consolidação em torno de 15,4 milhões de famílias até 2028. A banda sombreada é o intervalo de 95% derivado do MAPE agregado de backtest.

Tabela 10 – Marcos da carga de casos nacional

Grandeza	Valor (famílias)
Pico (jan/2023)	21.243.010
Último observado (dez/2025)	18.401.764
Projeção central (AR linear), dez/2028	$\approx 15.442.971$
AR linear + cov., dez/2028	$\approx 15.456.747$
MLP profunda + cov., dez/2028	$\approx 15.902.025$
Banda de 95% em dez/2028	[13.999.098; 16.886.844]

Banda nacional de $\pm$ MAPE de backtest, de 1,3% (curto) a 9,4% (dez/2028). Fonte: elaboração própria.

13.4 Leitura fiscal

A implicação é direta. Pela equação (1), com a carga de casos plana ou declinante, o custo futuro é governado pela *alavanca de política* — o valor do benefício —, não por uma demanda em expansão. A parcela *estrutural* do gasto não cresce; eventuais aumentos de custo serão, sob a hipótese de ausência de novo choque institucional, escolhas discricionárias de benefício. E, porque o agregado nacional é previsível com erro inferior a 4,7% em doze meses (e ainda menor com covariáveis), essa parcela pode ser planejada com folga adequada ao ciclo orçamentário.

13.5 Do caseload ao custo: como usar a projeção

A projeção é um insumo, não uma resposta final. A equação (1) sugere o procedimento de uso. Tomada a trajetória central da carga de casos $\hat{N}_t$ e sua banda $[\hat{N}_t^{\text{lo}}, \hat{N}_t^{\text{hi}}]$, o custo projetado em t é $\hat{C}_t \approx \hat{N}_t \cdot \bar{b}_t$, onde $\bar{b}_t$ é o benefício médio — uma escolha de política. A incerteza do custo decompõe-se, então, em duas fontes *ortogonais*: a incerteza *estrutural* (a banda da carga de casos, que este artigo quantifica em $<9,4\%$ até 2028) e a incerteza *de política* (o valor do benefício, que o gestor controla). Separá-las é o ganho prático: o planejador pode tratar a primeira como dado — estreito e previsível — e concentrar a deliberação na segunda, que é onde residem tanto a escolha quanto o grosso da variação possível do gasto. A projeção, portanto, não substitui a decisão orçamentária; ela *delimita* a parte da conta que não está em disputa, tornando explícita a parte que está. É essa delimitação, e não um número único de gasto, o produto de política deste trabalho.

14 LIMITAÇÕES

A honestidade do exercício exige enumerar suas fronteiras.

1. Reversão à média na recursão. A projeção recursiva de múltiplos anos arrasta as previsões à média histórica de cada município; formulações diretas de múltiplos horizontes, ou estado de espaço com tendência amortecida [18], mitigariam o efeito.

2. Covariáveis congeladas no futuro. Na projeção, população e emprego formal são mantidos em 2024. Acoplar projeções demográficas oficiais do IBGE e cenários de emprego

refinaria o longo prazo — justamente onde as covariáveis mais importam.

3. Choques de política exógenos. Um quarto regime institucional não é previsível do histórico; as previsões são condicionais a “nenhum novo choque”. É limitação intrínseca de modelos sem variáveis de política.

4. Frequência das covariáveis. População e RAIS são anuais e publicadas com defasagem; sua granularidade temporal grosseira limita o ganho a curto prazo (Seção 10). Séries mensais de mercado de trabalho (p. ex. CAGED) poderiam estender o benefício a horizontes intermediários.

5. Cobertura da agregação. A trajetória nacional soma os municípios com janela final completa e covariáveis ($\approx 99\%$); a exclusão dos 29 municípios sem casamento de código introduz viés de cobertura desprezível, mas não nulo.

15 EXTENSÕES

Três extensões decorrem naturalmente.

Mais covariáveis e maior frequência. Os fluxos de entrada e saída do Cadastro Único, séries mensais de emprego (CAGED) e indicadores de informalidade dariam ao modelo — sobretudo ao profundo — estrutura não-linear adicional a explorar, possivelmente permitindo à profundidade enfim compensar em horizontes intermediários.

Previsões probabilísticas calibradas. A banda atual é o MAPE de backtest, substituto razoável porém não calibrado. Regressão quantílica [34] ou predição conforme [35] produziriam intervalos com cobertura teoricamente garantida — um avanço natural para o uso orçamentário.

Heterogeneidade espacial. A relação cobertura–emprego (Figura 3) e a desigualdade entre estados (Figura 5) sugerem que modelos com efeitos regionais, covariáveis espaciais ou agrupamento por perfil municipal poderiam capturar dinâmicas locais que o modelo global, por construção, média. Um caminho natural é hierarquizar a previsão — reconciliar trajetórias municipais, estaduais e nacional — de modo que a soma das partes seja coerente com o todo, técnica madura na literatura de previsão hierárquica.

Modelagem explícita de regime. As três faixas institucionais da Figura 17 são, hoje, tratadas como dadas. Incorporar indicadores de regime, ou variáveis de política (limiares de elegibilidade, valor do benefício), permitiria *condicionar* a previsão a cenários de política — transformando o modelo, de puramente preditivo, em ferramenta de simulação contrafactual para o gestor. Essa é, em última análise, a ponte entre a previsão da demanda estrutural, objeto deste artigo, e a equação de custo (1) que a motiva.

Em conjunto, essas extensões partilham um princípio: cada uma adiciona *estrutura* que o modelo univariado global não contém. O presente artigo mostra que a primeira dose de estrutura externa — demografia e emprego — já paga, e onde paga (horizontes longos). A pergunta aberta é se doses adicionais, de maior frequência e granularidade, deslocam enfim a fronteira a favor da profundidade — ou se a parcimônia continua, como aqui, a usar melhor cada nova informação.

16 CONCLUSÕES

Seis conclusões emergem.

Primeira: a carga de casos do Bolsa Família *atingiu o pico e consolida-se* — de $\approx 21,2$ milhões de famílias em janeiro de 2023 para 18,4 milhões em dezembro de 2025, com projeção em torno de 15,4–15,9 milhões para 2028. A demanda estrutural não cresce.

Segunda: o *aprendizado supera a ingênua em horizontes de planejamento* — até 27% de redução de MAE em seis meses, de forma robusta —, mas *não* a um mês, quando a série é quase um passeio aleatório.

Terceira: o *modelo do tamanho certo vence*. A autorregressão linear domina o perceptron profundo em todo horizonte, mesmo com covariáveis; a profundidade só ajuda quando regularizada, e ainda assim fica atrás.

Quarta: as *covariáveis de demografia e emprego carregam sinal real, cujo valor cresce com o horizonte* — negligíveis ou prejudiciais a 1–3 meses, elevam o modelo linear de +10% para +17% de redução de MAE em 12 meses, tornando-o o melhor preditor de longo prazo.

Quinta: as *previsões nacionais são estreitas* — MAPE agregado abaixo de 4,7% em doze meses, e ainda menor com covariáveis —, adequadas ao planejamento orçamentário, graças ao cancelamento de erros na agregação.

Sexta: o *custo fiscal é uma escolha de política*, não uma inevitabilidade conduzida pela carga de casos — o ponto de maior relevância para o debate de sustentabilidade.

16.1 Método aberto e o sentido das duas perguntas

Registra-se, por fim, o valor da abordagem do zero: ao implementar cada peça à mão em C++17, seguindo Chen e Gupta [7], e ao reconciliar três bases públicas oficiais em um único painel, o experimento permanece integralmente auditável. Não há caixa-preta entre os dados públicos e a conclusão — cada número da Tabela 6 pode ser regenerado, e cada figura, reconstruída, a partir do código e dos artefatos versionados (Seção 4.4).

As duas perguntas metodológicas que organizaram o artigo — *quando a profundidade compensa?* e *quanto valem covariáveis, e em que horizonte?* — têm, à luz da equação (13), a mesma resposta de fundo: o que importa não é a capacidade do modelo nem a quantidade de informação *em abstrato*, mas o casamento entre a estrutura do modelo, a estrutura da informação e a estrutura do problema. A profundidade não compensou porque o sinal é quase log-linear; as covariáveis compensaram apenas no longo prazo porque é lá que a autocorrelação se esgota e a estrutura externa passa a importar. Não há, neste domínio, um almoço grátis: há o ajuste certo entre ferramenta e tarefa. É uma lição modesta, mas é a que os dados públicos brasileiros, aqui examinados com rigor, sustentam — e que vale, plausivelmente, muito além da carga de casos de um único programa social.

APÊNDICE A – MÉTRICAS COMPLETAS

A Tabela 11 reporta RMSE e R^2 dos cinco modelos nos quatro horizontes, complementando o MAE e o MAPE da Tabela 6. O R^2 permanece acima de 0,985 em toda linha — artefato da enorme variância entre municípios —, reforçando que a métrica informativa é o MAPE. O RMSE, mais sensível a grandes erros, ordena os modelos de forma consistente com o MAE: a autorregressão linear (com ou sem covariáveis) tem o menor RMSE em 3, 6 e 12 meses.

Tabela 11 – Métricas completas por horizonte e modelo

<i>H</i>	Modelo	RMSE (fam.)	R^2
1	Persistência	412	0,9992
	AR linear	365	0,9994
	MLP profunda	379	0,9993
	AR linear + cov.	507	0,9988
	MLP profunda + cov.	395	0,9993
3	Persistência	797	0,9970
	AR linear	574	0,9984
	MLP profunda	784	0,9971
	AR linear + cov.	796	0,9970
	MLP profunda + cov.	958	0,9956
6	Persistência	1.313	0,9917
	AR linear	805	0,9969
	MLP profunda	1.300	0,9919
	AR linear + cov.	805	0,9969
	MLP profunda + cov.	1.302	0,9919
12	Persistência	1.684	0,9864
	AR linear	1.171	0,9934
	MLP profunda	1.538	0,9887
	AR linear + cov.	1.183	0,9933
	MLP profunda + cov.	1.642	0,9871

Fonte: elaboração própria.

APÊNDICE B – COMPARAÇÕES PAREADAS COMPLETAS

A Tabela 12 reporta todas as seis comparações pareadas de interesse nos quatro horizontes: cada modelo aprendido contra a persistência e entre si, e os dois testes de covariável. Todos os valores- p de Wilcoxon são inferiores a 10^{-4} (em geral $< 10^{-30}$); dado $n \approx 66.504$, a leitura relevante está no intervalo de confiança (estritamente positivo $\Rightarrow$ vantagem robusta) e na taxa de vitória.

Tabela 12 – Comparações pareadas completas ($\Delta\text{MAE} > 0$ favorece o primeiro modelo)

<i>H</i>	Comparação	ΔMAE	IC 95%	Vit. (%)
1	AR linear vs persist.	-2,9	[-4,7; -1,2]	48,3
	MLP prof. vs persist.	-0,3	[-1,8; +1,1]	49,5
	AR linear vs MLP prof.	-2,6	[-4,1; -1,1]	48,0
	AR lin.+cov vs AR linear	-2,8	[-5,4; -0,3]	51,1
	MLP+cov vs MLP prof.	-0,5	[-1,6; +0,5]	52,1
	MLP+cov vs AR linear	+2,1	[+0,5; +3,5]	53,0
3	AR linear vs persist.	+20,2	[+17,6; +22,7]	58,5
	MLP prof. vs persist.	+0,8	[-1,6; +3,2]	53,1
	AR linear vs MLP prof.	+19,4	[+16,8; +22,0]	56,1
	AR lin.+cov vs AR linear	-9,8	[-12,4; -7,2]	52,9
	MLP+cov vs MLP prof.	-7,7	[-10,4; -5,2]	50,6
	MLP+cov vs AR linear	-27,1	[-31,6; -23,2]	44,1
6	AR linear vs persist.	+56,0	[+49,7; +62,4]	64,2
	MLP prof. vs persist.	+4,3	[+0,5; +8,0]	56,4
	AR linear vs MLP prof.	+51,7	[+46,5; +57,3]	61,5
	AR lin.+cov vs AR linear	-0,8	[-2,1; +0,5]	53,2
	MLP+cov vs MLP prof.	+12,7	[+8,4; +16,7]	59,2
	MLP+cov vs AR linear	-39,0	[-44,7; -33,6]	41,4
12	AR linear vs persist.	+25,7	[+14,2; +37,9]	56,9
	MLP prof. vs persist.	-28,3	[-36,7; -19,6]	56,3
	AR linear vs MLP prof.	+54,1	[+47,7; +61,3]	57,9
	AR lin.+cov vs AR linear	+19,8	[+12,1; +27,5]	54,5
	MLP+cov vs MLP prof.	-1,5	[-5,9; +3,1]	54,6
	MLP+cov vs AR linear	-55,6	[-64,1; -47,6]	45,5

IC por bootstrap pareado (2.000 reamostragens). Fonte: elaboração própria.

REFERÊNCIAS

- [1] BRASIL. **Lei n.º 10.836, de 9 de janeiro de 2004**. Cria o Programa Bolsa Família. Diário Oficial da União, Brasília, 2004. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2004-2006/2004/lei/l10.836.htm. Acesso em: 22 jun. 2026.
- [2] BRASIL. **Lei n.º 14.284, de 29 de dezembro de 2021**. Institui o Programa Auxílio Brasil. Diário Oficial da União, Brasília, 2021. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2019-2022/2021/lei/l14284.htm. Acesso em: 22 jun. 2026.
- [3] BRASIL. **Lei n.º 14.601, de 19 de junho de 2023**. Institui o Programa Bolsa Família. Diário Oficial da União, Brasília, 2023. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2023-2026/2023/lei/l14601.htm. Acesso em: 22 jun. 2026.
- [4] CONTROLADORIA-GERAL DA UNIÃO (CGU). **Portal da Transparência do Governo Federal: Bolsa Família e Auxílio Brasil**. Brasília: CGU. Disponível em: <https://portaldatransparencia.gov.br/beneficios/bolsa-familia>. Acesso em: 22 jun. 2026.
- [5] INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). **Estimativas da população residente para os municípios e para as unidades da federação**. Rio de Janeiro: IBGE. Disponível em: <https://www.ibge.gov.br/estatisticas/sociais/populacao/9103-estimativas-de-populacao.html>. Acesso em: 22 jun. 2026.
- [6] BRASIL. Ministério do Trabalho e Emprego (MTE). **Relação Anual de Informações Sociais (RAIS)**. Programa de Disseminação das Estatísticas do Trabalho (PDET). Brasília: MTE. Disponível em: <https://www.gov.br/trabalho-e-emprego/pt-br/assuntos/estatisticas-trabalho/rais>. Acesso em: 22 jun. 2026.
- [7] CHEN, Bill; GUPTA, Vikash. **Deep Learning with C++: Design and deploy neural networks using CUDA for high-performance AI in C++**. Birmingham: Packt Publishing, 2026. ISBN 978-1-83588-002-9.
- [8] GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. **Deep Learning**. Cambridge, MA: MIT Press, 2016. Disponível em: <https://www.deeplearningbook.org>. Acesso em: 22 jun. 2026.
- [9] LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. Deep learning. **Nature**, v. 521, p. 436–444, 2015. DOI: 10.1038/nature14539.
- [10] RUMELHART, David E.; HINTON, Geoffrey E.; WILLIAMS, Ronald J. Learning representations by back-propagating errors. **Nature**, v. 323, p. 533–536, 1986. DOI: 10.1038/323533a0.
- [11] CYBENKO, George. Approximation by superpositions of a sigmoidal function. **Mathematics of Control, Signals and Systems**, v. 2, n. 4, p. 303–314, 1989. DOI: 10.1007/BF02551274.
- [12] HORNIK, Kurt; STINCHCOMBE, Maxwell; WHITE, Halbert. Multilayer feedforward networks are universal approximators. **Neural Networks**, v. 2, n. 5, p. 359–366, 1989. DOI: 10.1016/0893-6080(89)90020-8.
- [13] HE, Kaiming; ZHANG, Xiangyu; REN, Shaoqing; SUN, Jian. Delving deep into rectifiers: surpassing human-level performance on ImageNet classification. In: **IEEE International Conference on Computer Vision (ICCV)**, 2015. arXiv:1502.01852.
- [14] GLOROT, Xavier; BENGIO, Yoshua. Understanding the difficulty of training deep feed-forward neural networks. In: **AISTATS**, 2010. v. 9, p. 249–256.
- [15] KINGMA, Diederik P.; BA, Jimmy. Adam: a method for stochastic optimization. In: **International Conference on Learning Representations (ICLR)**, 2015. arXiv:1412.6980.

- [16] LOSHCHILOV, Ilya; HUTTER, Frank. Decoupled weight decay regularization. In: **ICLR**, 2019. arXiv:1711.05101.
- [17] BOX, George E. P.; JENKINS, Gwilym M. **Time Series Analysis: Forecasting and Control**. San Francisco: Holden-Day, 1970.
- [18] HYNDMAN, Rob J.; ATHANASOPOULOS, George. **Forecasting: Principles and Practice**. 3. ed. Melbourne: OTexts, 2021. Disponível em: <https://otexts.com/fpp3/>. Acesso em: 22 jun. 2026.
- [19] HYNDMAN, Rob J.; KOEHLER, Anne B. Another look at measures of forecast accuracy. **International Journal of Forecasting**, v. 22, n. 4, p. 679–688, 2006. DOI: 10.1016/j.ijforecast.2006.03.001.
- [20] BERGMEIR, Christoph; BENÍTEZ, José M. On the use of cross-validation for time series predictor evaluation. **Information Sciences**, v. 191, p. 192–213, 2012. DOI: 10.1016/j.ins.2011.12.028.
- [21] MAKRIDAKIS, Spyros; SPILIOTIS, Evangelos; ASSIMAKOPOULOS, Vassilios. The M4 Competition: 100,000 time series and 61 forecasting methods. **International Journal of Forecasting**, v. 36, n. 1, p. 54–74, 2020. DOI: 10.1016/j.ijforecast.2019.04.014.
- [22] HEWAMALAGE, Hansika; BERGMEIR, Christoph; BANDARA, Kasun. Global models for time series forecasting: a simulation study. **Pattern Recognition**, v. 124, 108441, 2022. DOI: 10.1016/j.patcog.2021.108441.
- [23] SMYL, Slawek. A hybrid method of exponential smoothing and recurrent neural networks for time series forecasting. **International Journal of Forecasting**, v. 36, n. 1, p. 75–85, 2020. DOI: 10.1016/j.ijforecast.2019.03.017.
- [24] SALINAS, David; FLUNKERT, Valentin; GASTHAUS, Jan; JANUSCHOWSKI, Tim. DeepAR: probabilistic forecasting with autoregressive recurrent networks. **International Journal of Forecasting**, v. 36, n. 3, p. 1181–1191, 2020. DOI: 10.1016/j.ijforecast.2019.07.001.
- [25] LIM, Bryan; ZOHREN, Stefan. Time-series forecasting with deep learning: a survey. **Philosophical Transactions of the Royal Society A**, v. 379, n. 2194, 20200209, 2021. DOI: 10.1098/rsta.2020.0209.
- [26] DAMA INTERNATIONAL. **DAMA-DMBOK: Data Management Body of Knowledge**. 2. ed. Basking Ridge: Technics Publications, 2017. ISBN 978-1-63462-234-9.
- [27] ZAHARIA, Matei; XIN, Reynold S.; WENDELL, Patrick *et al.* Apache Spark: a unified engine for big data processing. **Communications of the ACM**, v. 59, n. 11, p. 56–65, 2016. DOI: 10.1145/2934664.
- [28] ARMBRUST, Michael; DAS, Tathagata; SUN, Liwen *et al.* Delta Lake: high-performance ACID table storage over cloud object stores. **Proceedings of the VLDB Endowment**, v. 13, n. 12, p. 3411–3424, 2020. DOI: 10.14778/3415478.3415560.
- [29] DATABRICKS. **Databricks Free Edition**. San Francisco: Databricks, 2025. Disponível em: <https://www.databricks.com/learn/free-edition>. Acesso em: 22 jun. 2026.
- [30] DATABRICKS. **What is the medallion lakehouse architecture?** Documentação técnica. San Francisco: Databricks. Disponível em: <https://www.databricks.com/glossary/medallion-architecture>. Acesso em: 22 jun. 2026.
- [31] DIEBOLD, Francis X.; MARIANO, Roberto S. Comparing predictive accuracy. **Journal of Business & Economic Statistics**, v. 13, n. 3, p. 253–263, 1995. DOI: 10.1080/07350015.1995.10
- [32] WILCOXON, Frank. Individual comparisons by ranking methods. **Biometrics Bulletin**, v. 1, n. 6, p. 80–83, 1945. DOI: 10.2307/3001968.

- [33] EFRON, Bradley. Bootstrap methods: another look at the jackknife. **The Annals of Statistics**, v. 7, n. 1, p. 1–26, 1979. DOI: 10.1214/aos/1176344552.
- [34] KOENKER, Roger; BASSETT, Gilbert. Regression quantiles. **Econometrica**, v. 46, n. 1, p. 33–50, 1978. DOI: 10.2307/1913643.
- [35] SHAFER, Glenn; VOVK, Vladimir. A tutorial on conformal prediction. **Journal of Machine Learning Research**, v. 9, p. 371–421, 2008.